AGENT MEMORY SYSTEMS · COURSE 32/32 · REVIEW CARDS

智能体记忆系统
核心概念与易混淆知识卡

24 组关键概念对照 · 结课速查 · 从原理到独立判断

观察事件 → 提取候选 → 维护有效状态 → 检索证据 → 理解与规划 → 执行并核验

记住这条主线：保存了 ≠ 找得回；找得回 ≠ 用得对；用得对 ≠ 真正执行；工具调用了 ≠ 目标已达成。

最易混淆 · 01—12

01	模型权重 ≠ 会话外部记忆
02	本轮上下文 ≠ 完整聊天历史
03	RAG流程 ≠ 记忆生命周期
04	工作记忆 ≠ 短期时长
05	情景经历 ≠ 可复用事实
06	操作步骤 ≠ 执行权限
07	记忆事实 ≠ 向量索引
08	Embedding ≠ Q/K/V ≠ KV Cache
09	高相似 ≠ 真实 / 有效
10	检索触发 ≠ 检索结果 ≠ 使用
11	ANN近邻 ≠ 历史证据真值
12	检索分数 ≠ 任务完成率

最易混淆 · 13—24

13	事件 ≠ 断言 ≠ 有效状态
14	发生时间 ≠ 生效时间 ≠ 获知时间
15	来源可查 ≠ 可信 ≠ 获准
16	新增 ≠ 更正 ≠ 失效
17	降权 ≠ 真实删除
18	摘要 ≠ 巩固 ≠ 原文
19	上下文 ≠ Checkpoint ≠ 长期记忆
20	权威库 ≠ 索引 ≠ 缓存
21	功能 ≠ 存储表示 ≠ 归属
22	规划 ≠ 工具派发 ≠ 环境成功
23	记忆错 ≠ 模型错 ≠ 评分错
24	记得更多 ≠ 更可靠

检查记忆：
谁说的？何时有效？属于哪个项目？原始证据在哪里？

检查行动：
是谁授权的？控制器真的执行了吗？环境结果验收了吗？

检查研究：
是记忆、检索、推理还是工具故障？质量提升的成本是多少？

系统边界：三组关键概念对照

重点概念 01—03
32讲课程的复习提要

模型参数知识 ≠ 外部记忆

CARD 01 · 第01—03讲

模型参数是训练后保留在权重中的统计规律；外部记忆是运行中可写入、检索、修订的记录。

容易混淆 模型会回答某项通用技术，并不等于它记住了昨日这项科研任务的最新决定。

贯穿案例 昨天研究者决定暂停P项目收费调用；不应期待模型仅靠参数知道。

记忆锚点：跨会话的具体状态需要可持续的外部记录与核验。

遮住答案后自问：模型知道通用技术，为什么未必知道昨天的项目决定?

当前上下文 ≠ 聊天记录

CARD 02 · 第02—03讲

上下文是本轮实际送给模型看的Token；聊天记录是应用保存的历史事件。

容易混淆 历史页面上看得到一句话，并不代表当前LLM请求包含这句话。

贯穿案例 30天前的决策仍在聊天日志中，但未被装入本轮上下文。

记忆锚点：保存、检索、装入上下文是三个操作。

遮住答案后自问：历史页面有这句话，为何模型这一轮仍可能答错?

知识库 / RAG ≠ 智能体记忆

CARD 03 · 第03、08讲

知识库是可查询的信息集合；RAG是“检索后辅助生成”的流程；Agent记忆还要管理个人/任务经历的写入、更新与过期。

容易混淆 接入向量知识库或RAG，并不自动拥有持续可靠的长期记忆。

贯穿案例 搜索论文是RAG；核对旧提议已被用户否决，涉及时间、来源与记忆状态。

记忆锚点：RAG可以是记忆系统的读取部件，不是完整生命周期。

遮住答案后自问：用RAG找到了论文，为什么还没完成长期记忆管理?

记忆分类：三组关键概念对照

重点概念 04—06
32讲课程的复习提要

工作记忆 ≠ 短期记忆

CARD 04 · 第10讲

工作记忆按功能定义：当前任务正在操作的信息；短期记忆按保留时长定义。

容易混淆 把某些资料放在短时缓存中，并不一定意味着它正被当前任务主动使用。

贯穿案例 当前目标、分解步骤属于工作记忆；短暂保存但未用到的对话片段不必是。

记忆锚点：功能分类和时间分类是不同的坐标轴。

遮住答案后自问： “工作”和“短期”，到底分别按什么标准分类？

情景记忆 ≠ 语义记忆

CARD 05 · 第10、11、15讲

情景记忆记“某次经历发生了什么”；语义记忆记“经核验、可跨事件复用的事实与关系”。

容易混淆 一次工具失败的记录，不能直接抽象为“这种工具总是失败”。

贯穿案例 D09发生504属于情景；经多次证据分析才总结出的接口限制属于语义。

记忆锚点：从事件到知识需要抽象、来源和核验。

遮住答案后自问： “当时出过一次错”怎样才可能成为可复用知识？

程序性记忆 ≠ 已掌握技能 / 执行许可

CARD 06 · 第10、24、26讲

程序性记忆可保存“如何做”的步骤或经验；真正技能要在环境中验证，执行权限另由控制器检查。

容易混淆 记住一份“调用API的操作步骤”，不等于获得经费批准或调用成功。

贯穿案例 科研助手有排障SOP，但P项目暂停付费时不得因此执行收费请求。

记忆锚点：知道步骤、能做成、获准做，是三种不同判断。

遮住答案后自问：保存了排障SOP，为什么仍不能擅自调用收费API?

表示与检索：三组关键概念对照

重点概念 07—09
32讲课程的复习提要

记忆条目 ≠ 数据库存储 ≠ 搜索索引

CARD 07 · 第09、17、20讲

记忆条目表达事实/事件/状态；数据库保存记录；索引（向量、全文、图）是方便找到记录的派生视图。

容易混淆 向量相似搜索得到一条记录，不代表它的索引副本是权威状态。

贯穿案例 关系库已更新“暂停”，向量索引暂未刷新，仍可能搜到过时的“可调用”。

记忆锚点：权威状态和可检索视图的责任要分开。

遮住答案后自问：向量索引里是旧数据，应该回哪里确认当前状态?

Embedding ≠ Q/K/V ≠ KV Cache

CARD 08 · 第05—07讲

Embedding将内容映射为可比较的向量；Q/K/V是Transformer注意力计算中的投影；KV Cache缓存生成中复用的内部状态。

容易混淆 KV Cache不是跨会话、可独立维护的长期情景记忆库。

贯穿案例 向量库用Embedding找语义近邻；模型内部用Q/K/V处理已装入的上下文。

记忆锚点：这三者都含向量，却处于不同的计算环节。

遮住答案后自问：Embedding、Q/K/V、KV Cache分别服务哪个环节?

语义相似 ≠ 事实正确 / 当前有效

CARD 09 · 第07、14、18讲

余弦相似度衡量向量方向接近程度，不核实主张真假、否定词、时间范围或授权状态。

容易混淆 “建议做实验”和“禁止做实验”可能语义相关，却在操作意义上相反。

贯穿案例 检索出旧的高相似付费建议，仍要查当前项目、时间与批准者。

记忆锚点：相关性排名之后，还要回源和做状态检查。

遮住答案后自问：语义相似的“批准”和“未批准”，怎样最终区分?

索引与排序：三组关键概念对照

重点概念 10—12
32讲课程的复习提要

触发检索 ≠ 找回候选 ≠ 正确利用

CARD 10 · 第21—24讲

触发是决定“要不要查”；召回是“查到什么”；排序/选择是“给模型看哪些”；利用是“模型如何推理”。

容易混淆 只要检索Top-5中有正确记录，最终答案也可能用错。

贯穿案例 检索到D12暂停，但模型仍执行D04旧提议，是利用/控制问题，不一定是召回问题。

记忆锚点：故障定位要沿整条流水线拆开。

遮住答案后自问：候选里已有正确证据但模型答错，错误可能在哪一步？

Flat精确搜索 ≠ HNSW / IVF / PQ

CARD 11 · 第18讲

Flat逐个比对向量，通常是精确基线；HNSW通过分层邻居图加速；IVF先找分区；PQ用码本压缩向量。

容易混淆 更小或更快的索引，不保证得到正确历史事实；PQ压缩率也不等于整个数据库压缩率。

贯穿案例 百万向量搜索可用ANN减少候选，但重要权威决定还得回源核验。

记忆锚点：召回、时延、占用与维护是可比较的不同维度。

遮住答案后自问：什么情况下要牺牲一点召回，换取更低的索引成本？

Precision@K ≠ Recall@K ≠ 任务成功率

CARD 12 · 第22—24、31讲

Precision@K问取回的K条里有多少相关；Recall@K问全部相关证据取回多少；任务成功衡量最后行动是否达标。

容易混淆 检索10条中8条相关（高Precision），但漏了唯一“最新暂停”证据，也可能失败。

贯穿案例 模型找到证据却未核实执行结果，检索分数再好也不是最终任务完成。

记忆锚点：检索、问答、工具与环境要分别度量。

遮住答案后自问：如果只漏了一条关键否定证据，哪个指标可能揭示？

时间与证据：三组关键概念对照

重点概念 13—15
32讲课程的复习提要

原始事件 ≠ 候选主张 ≠ 当前状态

CARD 13 · 第11、14、16讲

事件保存“谁在何时说/做了什么”；候选主张是从事件中提取的断言；当前状态是经过范围和时间核验后的有效视图。

容易混淆 记录“AI建议扩样”的真实事件，不代表“扩样已获批准”是真的。

贯穿案例 D04是AI提议；D12用户暂停才决定P当前授权状态。

记忆锚点：事件可为真，事件中表达的主张仍可能未经证实。

遮住答案后自问：说过一件事，是否就意味着那句话本身是真事实?

事件时间 ≠ 有效时间 ≠ 系统获知时间

CARD 14 · 第14、30讲

事件时间是活动发生时；有效时间是事实对业务生效的时段；系统获知时间是记录被系统接收的时刻。

容易混淆 D14才录入，不代表D12才生效的决定自动改成D14生效。

贯穿案例 D12用户暂停P，D14系统读取记录；问“D13当时生效什么”和“D13系统已知什么”答案可不同。

记忆锚点：理解历史需要双时间甚至多时间视角。

遮住答案后自问：事实D12生效而D14才录入，历史查询应怎样回答?

有来源 ≠ 可信 ≠ 获得授权

CARD 15 · 第16、24讲

来源追溯表示证据从哪里来；可信度表示支持程度；权限决定某主体能否执行某项操作。

容易混淆 三个Agent重复引用同一博客，不是三份独立证据；真实论文也不构成用户付费授权。

贯穿案例 来源可查的旧决策仍可能过期；高可信的操作方法也可能未经批准。

记忆锚点：出处、真伪、适用范围和执行许可分开核验。

遮住答案后自问：三个AI说法相同，如何判断是三份还是一份证据?

更新与遗忘：三组关键概念对照

重点概念 16—18
32讲课程的复习提要

新增 ≠ 合并 ≠ 更正 ≠ 失效

CARD 16 · 第14—15、25讲

新增是新事实；合并处理重复/相关记录；更正修复过去的错误；失效标记过去正确、现在不再有效。

容易混淆 把旧错误覆盖成新版本，会丢掉“系统曾误知什么”的关键证据。

贯穿案例 过去允许、现在禁止属于状态变化；过去记录写错则是对历史认识的更正。

记忆锚点：新旧关系和版本应保留，不能静默覆盖。

遮住答案后自问：过去正确但现在失效，与过去写错是同一种变化吗?

检索降权 ≠ 业务遗忘 ≠ 物理删除

CARD 17 · 第25讲

降权只改变搜索排序；业务失效令信息不再作为当前事实；物理删除还涉及原文、索引、缓存和备份策略。

容易混淆 按遗忘曲线降低一条信息的权重，不会让法律/预算/安全约束自动失效。

贯穿案例 旧的“暂停付费”决定即使很久不被提起，也不能仅因时间久而失效。

记忆锚点：删除必须明确作用域和副本传播，不能靠降低相似度冒充。

遮住答案后自问：时间衰减降低排名，是否意味着授权限制被解除?

摘要压缩 ≠ 记忆巩固 ≠ 原文历史

CARD 18 · 第13、15讲

摘要以较少Token表达内容；巩固把相关经历整合为知识；原文历史保留可核对的事件与来源。

容易混淆 “未批准的建议”被摘要成“批准方案”，即使摘要简洁也变成了记忆污染。

贯穿案例 D09日志→D18原因核验→故障诊断经验：每一步都要留来源与版本。

记忆锚点：重要否定、时间、数字与证据指针优先保真。

遮住答案后自问：摘要省了Token，为什么可能破坏最终判断?

生命周期：三组关键概念对照

重点概念 19—21
32讲课程的复习提要

当前上下文 ≠ Checkpoint ≠ 长期记忆

CARD 19 · 第04、20、28讲

当前上下文供模型本轮阅读；Checkpoint保留某条任务线程的运行状态用于恢复；长期记忆保存跨任务可复用的信息。

容易混淆 线程恢复成功，不代表下一段新对话会自动知道该项目所有历史。

贯穿案例 运行中断后继续步骤靠检查点；跨月保留项目结论靠长期记忆。

记忆锚点：两者可协同，但存储用途不同。

遮住答案后自问：什么用于中断恢复？什么用于跨任务记住用户决定？

权威状态 ≠ 派生索引 ≠ 缓存

CARD 20 · 第09、20、25讲

权威状态用于回答当前有效业务结论；索引用于快速找候选；缓存用于减少重复读取延迟。

容易混淆 缓存命中不保证最新，索引未同步不代表权威状态未更新。

贯穿案例 数据库v12已更新暂停，向量索引v10仍指旧提议；关键决策回权威数据核对。

记忆锚点：检索速度和状态一致性需要分别设计。

遮住答案后自问：索引没有刷新，是否就代表权威库也没有更新？

功能 / 时长 / 表示 / 归属：四条轴

CARD 21 · 第10、17、20、32讲

功能：工作/情景/语义/程序；时长：临时/长期；表示：文本/结构化/向量/图；归属：用户/线程/项目/共享。

容易混淆 不能说“向量记忆是第五种功能记忆”，也不能说“一种功能必须配一种数据库”。

贯穿案例 一条长期情景记忆可用文本保存，也可建立向量索引并归入某个项目。

记忆锚点：多维分类可组合，不能混成一张互斥分类表。

遮住答案后自问：一条向量记忆能不能同时属于长期情景记忆？

行动与评估：三组关键概念对照

重点概念 22—24
32讲课程的复习提要

模型规划 ≠ 工具调用 ≠ 环境完成

CARD 22 · 第04、24讲

规划是提出步骤；工具调用要经过参数/权限校验并实际派发；环境完成由独立结果或权威状态核验。

容易混淆 模型文字中写“我已执行”，不等于工具有调用Trace或目标已经达成。

贯穿案例 API返回HTTP 200不一定等于业务完成；504也不必然等于下游完全没执行。

记忆锚点：建议、实际执行和成功验收都要有独立证据。

遮住答案后自问：“我已经调用了工具”最少还缺哪些外部证据?

记忆失败 ≠ 推理失败 ≠ 工具 / 评分失败

CARD 23 · 第24、31—32讲

遗漏正确记录是召回问题；已读到却误解是模型利用问题；错误参数、环境故障或Gold/评分错误属于不同责任层。

容易混淆 不能把所有Agent失败笼统解释成“记忆系统不可靠”。

贯穿案例 最新暂停已在输入中，但代理越权调用：调查控制器，而非只增加检索条数。

记忆锚点：先定位故障层，再讨论改进方法。

遮住答案后自问：如果Gold标签错了，能否归咎于模型记忆错误?

更多记忆 / 更复杂架构 ≠ 更高可靠性

CARD 24 · 第20、26、31—32讲

长期性能取决于写入质量、检索、时间有效性、推理行动与成本；多余记忆可能增加冲突、延迟和误用风险。

容易混淆 多加一个向量库或图数据库不是天然科研创新，也不保证任务成功率提高。

贯穿案例 简单项目状态表能解决的问题，不必默认升级为完整图记忆架构。

记忆锚点：以真实任务效果、成本、失败边界评估架构增量。

遮住答案后自问：在加图数据库前，最应该先证明什么?

INDEPENDENT RECONSTRUCTION · FINAL RECALL

最后一页：你能独立重建吗？

不看前面的卡片，用下面这个虚构科研项目重走“记忆→证据→决策”全过程。

贯穿案例：D04 → D12 → D18 → D26 → D30

D04：AI建议为 P 项目增加付费调用；这是一次“建议”事件，不是批准。

D12：研究者要求暂停 P 项目新增付费调用；形成当前有效的项目约束。

D18：通过网关日志复核D09的504错误；新增故障解释，并保留原始日志。

D26：研究者仅授权 Q 项目一次有界调用；作用域不能扩展到 P。

D30：用户询问“P项目现在可以恢复付费吗？”——正确判断需查权威状态与授权，而非只看语义最相似的旧提议。

五个不可跳过的判断门槛

一、辨来源。是用户决定、AI建议、工具回执、论文事实，还是派生摘要？

二、辨时间。事件发生时间、有效时间、系统获知时间是否不同？

三、辨作用域。P项目与Q项目是否混在一起？一次许可是否已被消耗？

四、辨证据。是否回到可核实的原始记录？多个Agent是否复述同一来源？

五、辨责任。错在记忆写入、检索、理解、计划、控制器、工具还是评分？

六、辨取舍。新增向量/图/反思模块是否带来可验证收益，并覆盖维护成本？

十秒检索前自检

1. 这次必须读历史吗？
2. 有没有当前生效的硬约束？
3. 是否必须使用最新来源？
4. 关键原文能否回溯？

十秒行动前自检

1. 建议是否被误记成批准？
2. 工具参数与预算是否有效？
3. 执行回执是否可验证？
4. 未核实事项是否明确标注？

复习方式：先看第1页速查，再每次选择3张对照卡，用自己的话解释区别，最后回到第32讲的系统总图。涉及科研结论与具体产品版本时，以原始论文、官方文档和实际轨迹为准。本卡为课程理论复习材料，不是额外实验结果。