AGENT MEMORY SYSTEMS · 第三部分 · 第12讲

哪些信息值得记住?

重要性 · 相关性 · 写入策略

From Candidate Memories to Selective Memory Writing

> 不是看到过，就必须永远保存。
>
> 不是评分高，就可以当成事实。
>
> 选择写入，是对未来行动质量负责。

零基础理论 | 17张机制图 | 12道附答案思考题 | 无实验与编程

《智能体记忆系统：从零基础到科研理解》

32讲系列 · 第12/32讲 · 版本v1.0

2026年10月18日

学习导航：本讲究竟要回答什么？

前一讲已经回答：外部对话、工具结果、文献和多智能体消息怎样被提取为“候选记忆”。然而，候选记忆可能有上百条，全部长期保存会产生费用、噪声、错误、隐私与维护成本。**本讲研究的是写入策略（write policy）：候选产生以后，系统依据什么规则决定“立即写、暂缓写、只留原始日志、合并更新，还是不进入长期记忆”。**

你将建立一套可推演的心智模型：①区分候选与事实；②判断未来用途、证据可信度与代价；③先过权限和安全约束，再计算价值；④选择写入动作；⑤观察下游检索与任务效果，必要时修正写入策略。本讲仍只讲理论，不要求你安装数据库或写代码。

图01 从信息洪流到长期记忆



图1｜五个阶段构成写入决策流程；长期记忆并非原始输入的无损副本。

贯穿案例的四个角色

Holmes是研究者，Irene是讨论助手，Watson是协作智能体，环境/工具负责返回可核验结果。本讲所有日期、数值、实验场景均为**虚构教学案例**，不应被误读为真实科研进展或费用授权。

01 先看一个反例：为什么“全都记住”可能更糟？

假设一个长期科研助手连续30天协助推进Agent系统项目。第3天，助手随口建议“未来也许可以把样本量扩大”；第7天，运行环境返回一条暂时性的网络超时；第12天，研究者明确决定“本阶段不新增收费调用”；第20天，一份较旧的实验记录仍写着“下一轮扩大样本”；第30天，研究者问：“我们现在是否可以启动新一轮付费测试？”

如果简单保存所有文字而不保留身份、时效和状态，第30天的检索结果很可能同时包含“建议扩样”“暂停费用”“历史记录”。模型看到其中哪个片段、怎样理解，都会影响回答。**记忆数量增加，并不意味着决策质量线性增加。**质量取决于记忆中保留了什么、怎样表达、是否允许被当作当前有效事实。

图02 同一项目中的四条候选：哪些该写？

第3天｜AI想法
“未来可以考虑扩样”
性质：未获批准的建议

第7天｜工具现象
“一次HTTP超时”
性质：需定位的瞬时故障

第12天｜研究者决定
“本阶段不新增收费调用”
性质：当前有效约束

第20天｜旧报告
“下一轮扩大样本”
性质：旧版文档内容

图2｜这里的“是否值得记住”与“能否代表当前有效决定”是不同问题。

直观上，第12天的决定对未来行动影响较大，适合保存为可检索的项目约束；第3天想法可作为提案事件保留，但不能升级为授权；第7天单次超时可能只需原始日志，重复出现或分析后才值得提炼；第20天旧报告应保留历史来源和时间，不应覆盖第12天决定。

02 写入不是复制：需要区分四个层次

我们沿用此前的“原始事件—候选断言—有效记忆”模型，再增加第四层“未来查询和行动”。不同层次承担不同责任。如果这四层被混为一谈，写入策略就可能把未经证实的推断变成事实。

图03 四个层次承担不同责任

L0 原始事件
尽可能保留说话者、时间和原始内容；用于追溯。

L1 候选断言
模型从原始材料中抽取的可能有用信息；可以有误。

L2 有效记忆
经范围、时间、状态和必要证据核验后供使用。

L3 决策上下文
在当前任务中被检索、选择并送入模型；还须核验行动。

图3｜写入主要作用于L1→L2，不能用一次LLM打分代替事实核验或执行授权。

注意：这些是教学中的**逻辑层**，不是规定必须有四张表或四个数据库。一个系统可以用事件日志、关系数据库、向量索引和当前状态视图组合实现，也可以用别的结构。只要语义职责清楚，物理设计可以变化。

> 必须记住的区别
>
> **保留证据**不等于**提炼成稳定知识**；**保存历史提案**不等于**写入当前约束**；**模型判断重要**不等于**人类授权执行**。

03 写入与检索：两个不同时间点上的问题

在第7讲和第8讲中，我们学习过语义相似、关键词匹配和RAG。现在需要把检索时的“相关性”与写入时的“未来有用性”分开。检索有**具体的当前问题**，可以用这个问题给候选记忆排序；写入发生在更早时刻，系统往往还不知道未来用户会问什么。

图04 写入判断与检索判断的正交关系

写入阶段 t_0

没有未来完整问题。
问：未来某些任务值得为它付成本吗?

检索阶段 t_1

有当前问题与目标。
问：现有记忆中哪几条最有帮助?

可能的错误

写入过少：关键证据不存在。
写入过多：候选噪声、维护成本增加。

检索不能补救

再好的排序器也找不回从未保存的关键事实。

图4｜图中t_0、t_1是不同时间点；重要性与相关性可同时出现，但使用目的不同。

Generative Agents（Park等，2023）曾在回忆阶段结合**近期性、重要性和相关性**等信号；这是很好的检索排序实例[1]。MemoryBank研究提出基于时间与重要性变化的记忆更新/遗忘思想[2]。但是不能把这两篇工作机械转换为“所有记忆写入时都按同一个加权公式打分”。我们的下一步是自主建立教学用的写入决策模型。

04 什么信息具有长期价值？先看七个维度

“重要”不是信息自带的永恒属性。它取决于**目标、后果、未来可能用到的场景、信息可替代性**。对智能体来说，最值得写入的信息往往不是最长、最新或最容易检索的，而是“若将来找不到，会造成较大损失”的信息。

图05 候选记忆的七个判断维度



图5｜七维度是教学分析框架，不是单篇论文的标准化评分表。

4.1 目标关联：从任务“因果链”寻找重要性

设当前任务是“确定下周能否开始一项有预算上限的实验”。决定能否开始的条件，包括预算授权、工具准备情况、实验方案是否冻结和项目状态。某条关于“项目暂停收费调用”的记录直接改变行动许可，所以写入价值高；一条无关的闲聊即使篇幅很长，也不必因为文本多就被写入科研长期记忆。

4.2 未来复用：不是只看今天的问题

“研究者习惯先看原始证据再做决策”可能长期影响不同任务；“昨天18:02某个请求超时”可能只对本周排错有用。二者都可能值得保存，但应当拥有不同寿命和作用域：前者可能作为稳定工作偏好，后者可能存在任务日志中，只有重复或成为关键失败原因才抽象为长期经验。

4.3 不可替代：一旦丢失还能找回来吗?

系统通常应特别关注**无法轻易重建的决定、关键反馈、未发表的分析过程、来源指针和失败归因**。反过来，公开论文标题可能可从权威目录中重新查询；但“这篇论文为什么在上一次讨论中被排除”是项目特有的判断过程，不应只保留最终标题。

4.4 可信与否，决定“存什么形态”

一条未经核实的主张仍然可能值得保留，用来等待求证。正确做法不是“一律丢弃”或“直接当事实”，而是写为**待核主张**，附来源、证据等级、适用范围和后续核验条件。对于未来可能引发高风险行动的内容，应提高证据门槛，而不是简单提高重要性分数。

05 价值与成本：建立直观的写入效用模型

把写入看成一种带代价的投资：今天花费计算和存储资源，是为了减少未来的遗忘、重复劳动和错误决策。一个纯教学用模型是：

$$U(write, m) = P(useful) \times B(future) - C(write+maintain) - P(misuse) \times H(error)$$

其中P(useful)表示未来有用的估计概率，B(future)表示保留它可能带来的收益；C包含生成摘要、存储、索引更新、检索噪声和维护开销；P(misuse)表示未来被错误使用的概率，H(error)为错误损失。这不是文献中的通用最优公式，系为了理解“收益—代价—风险”的权衡而构造。

图06 **同样长度的信息，预期写入效用并不同**

A｜明确预算决定

$0.8\times10-1-0.05\times10$

效用 +6.5

B｜临时无关闲聊

$0.1\times2-0.4-0.05\times2$

效用 −0.3

C｜孤立一次超时

$0.4\times4-1-0.10\times3$

效用 +0.3

D｜未经核实高风险提议

$0.5\times8-1-0.40\times15$

效用 −3.0

图6｜所有概率、收益和成本均为虚构单位的算例；这里的数值只解释方法，不是算法效果测量。

计算A：0.8×10=8；费用1；误用风险0.05×10=0.5，最终8−1−0.5=6.5。D尽管“看起来非常重要”，潜在误用成本可能超过未来收益。因此对D应当优先改成“仅保留可追溯提议、标记未批准”，而不是直接生成可执行长期规则。

> 一个重要的认识
>
> **高风险信息可能非常值得记录，但未必适合以“可直接采信的结论”形式写入。**写入动作本身可分层：保留原事件、作为待核候选、写入有效知识、或更新现存条目。

06 先检查硬约束，再谈分数

一些信息不是“低分就不写、高分就放行”的问题，而是涉及独立的权限、隐私和证据约束。例如：用户明确要求不保存敏感信息；外部网页中的一句话命令系统执行删除操作；智能体建议增加实验成本但尚未获授权。对这些情况应先触发明确的约束检查。

图07 写入决策的双层闸门



图7｜硬规则不能被高重要性分数抵消；评分必须以真实来源和权限状态为前提。

图08 高重要性≠高可信度：二维矩阵

	低可信度	高可信度
高重要性	**必须保留证据与待核状态** 例：外部文档称实验“已批准”	**适合进入当前有效状态** 例：研究者直接宣布暂停
低重要性	**可略过或只留短期日志** 例：陌生网页闲谈	**按成本选择是否保存** 例：一次普通系统正常回执

图8｜重要性决定潜在用途，可信度决定以什么知识状态进入系统；二者不能互相替代。

6.1 授权门槛不是“事实核验”的子集

就算信息内容真实，例如“网络工具可以发起付费请求”，也不意味着当前任务拥有调用权限。**真值判断**回答“所述事实成立吗”；**权限判断**回答“谁批准、批准什么、在哪些条件下可执行”。这两条链应分开存储、分开检查。

6.2 个人信息与最小必要保存

在用户资料、医疗、财务和对话场景中，越“个人化”的信息可能越能提升短期回答，但也越可能带来长期隐私风险。系统需要考虑同意、使用目的、数据最小化和到期清理等约束。本讲只解释工程原则：重要性分数绝不能替代用户意愿或访问控制。

07 写入策略不是二选一：至少有五个动作

许多入门教材把“是否记住”当成开关：Yes/No。真实系统至少应区分新增、合并、更新、暂缓核验和跳过长期知识化。因为写入动作一旦不同，未来检索的行为也不同。

图09 从一条候选到五种处置

NEW 新增
确实是全新、有效且值得保留的事实/事件。

MERGE 合并
同一事实的重复表述，避免重复造成检索偏斜。

UPDATE 更新
有可靠新证据修订旧状态；保存旧版或历史事件。

PENDING 待核
可能重要但证据不足或当前权限不完整。

LOG-ONLY 日志保留
不提炼为长期有效知识，必要时仍可追溯原始事件。

图9｜系统还可按保留策略进行跳过/拒绝长期保存；图示五项为教学上的通用动作类别。

举例：第12天用户明确“暂停付费调用”，原系统中存在“可申请开展付费测试”的旧提案。系统应更新当前决策视图为“暂停”，同时保留旧提案的时间与来源，而不是把两句话拼成“用户想开展付费调用”。如果第16天用户重复“仍暂停”，则更可能是确认或补充时间范围，而不是新建一个完全相同的“暂停”条目。

08 决策表与手算：写入评分如何真正运作?

为便于初学者理解，我们设计一个极简评分器。取目标关联G、未来复用R、不可替代N、证据可靠E四项，每项0到5；代价C与误用风险K也为0到5。教学分数定义为：

$$S = 0.30G + 0.25R + 0.20N + 0.25E - 0.20C - 0.30K$$

所有系数与0—5区间都是**本讲自建教学假设**，并非学界统一标准。更重要的是：这个S只作为候选排列或人工复核的辅助信号，不能替代前面的硬约束闸门，也不能单独决断高风险候选。

候选	G	R	N	E	C	K	S	初步策略
研究者明确暂停收费	5	5	5	5	1	1	**4.50**	更新当前项目约束
工具一次临时超时	2	1	1	5	1	1	**1.80**	先只存日志
AI提出尚未授权的扩样	4	3	3	1	2	5	**0.90**	保留提案标签，禁止当授权
闲聊推荐一部电影	0	1	0	5	1	0	**1.30**	一般不进科研项目记忆

全部为课堂虚构评分。系数只用于学习逻辑，不应机械用来决定真实系统写入。

第一行的演算为$0.30\times5 + 0.25\times5 + 0.20\times5 + 0.25\times5 - 0.20\times1 - 0.30\times1 = 1.50+1.25+1.00+1.25-0.20-0.30=4.50$。这个检验也提醒我们：记忆策略公式与人工评分必须能互相核对。

对第二行的超时记录：0.30×2 + 0.25×1 + 0.20×1 + 0.25×5 − 0.20×1 − 0.30×1=0.60+0.25+0.20+1.25−0.20−0.30=**1.80**。虽然工具结果可靠，事件只有一次、未来用途不确定，所以可先留短期日志。第四行的闲聊虽然“证据可靠”，但和科研目标无关，因此通常不值得占用科研项目长期记忆。

> 评分为何不能机械使用
>
> 阈值大小取决于评分尺度、项目风险和操作类型；分数高并不自动证明值得永久保存。一个更稳健的策略是先用评分筛候选，再执行去重、类型判断、来源核验与有效期控制。

09 四种典型写入时间策略

写入系统还必须决定**什么时候判断**。此处比较四类设计；它们不是谁绝对更先进，而是质量、成本、延迟和可维护性之间的不同折衷。

图10 写入时机与信息损失的取舍

策略	怎么做	优势	主要代价
逐条即时写	每次关键交互结束立即抽取	新决策很快可用	调用频繁、易过度提取
定期批量写	每完成若干轮统一综合	去重和跨事件整合更方便	写入前存在时间窗口
关键事件触发	决策、失败、纠错等事件触发	重点捕捉高价值变化	触发器错误会造成漏写
混合策略	关键约束立即写，其余批量整理	兼顾关键状态和开销	控制逻辑、状态同步更复杂

图10｜四类设计是实现层的常见模式；没有脱离任务与成本条件的唯一最优写入时间。

为什么混合策略往往值得考虑？因为同一条信息在不同阶段的代价不同：明确的行动禁令需要快速进入当前有效状态；一次低风险工具超时可以先在日志中沉淀；多次相关失败出现后再提炼成跨任务可复用的经验。

10 时间与衰减：过期不等于不重要

有些记忆会快速失效，例如“今天下午可用的临时API状态”；有些虽发生久远但很重要，例如“某个研究假设已被严格否定”。因此把“时间越久，重要性必定越低”当成普遍规律是不合理的。

图11 同样经过30天，两条信息的状态不同

记忆	随时间可能发生什么	合理处置
一次性网络超时	恢复正常后可能失去操作价值	短期日志；重复再抽象
经证据否定的核心假设	旧事件可能长期约束研究路线	保留原证据、失效范围及后续修订
当前预算限制	有效期由研究者决定，而非固定天数	直到被正式更新，不能因“很久没提”自动解除
短时有效的排课安排	日期结束后不能再当未来安排	可到期隐藏或归档但留历史

图11｜时间衰减只是部分系统的启发式操作，不能替代有效期与来源状态。

MemoryBank（2024）的时间和相对重要性机制可作为理解“强化与遗忘”的案例[2]；但研究目标和系统场景不同，不应推断它给出了所有Agent记忆的最优遗忘律。写入阶段更需要明确：信息属于“一次事件”“持续规则”“待核事实”还是“期限性状态”。

11 重复信息与新颖性：不是多写几遍就更可靠

同一个事实可能在许多轮对话中重复。若每次都新建独立记忆，检索排序可能被重复内容淹没；但如果过度合并，又可能抹去“这项规则被多次确认”的重要证据。一个稳健的处理方式是：**当前有效条目保留唯一可识别主体，同时用多条来源事件作为支持证据**。

图12 同一条事实的多次提及如何归并



图12｜合并的是当前有效断言，原始事件不应因为合并而失去溯源性。

“新颖性”也不能只用文本相似度来判断。例如“模型版本v1在数据集A准确率0.81”与“版本v2在数据集A准确率0.81”，句子很像，但模型版本不同，不能去重；“研究者曾批准”和“研究者未批准”只有一个否定词，却具有相反意义。

12 误写入与漏写入：两个方向的损失

评价记忆写入策略时，需要区分两类错误。**误写入（false positive）**是把不该提炼为可用长期记忆的候选写进去了；**漏写入（false negative）**是把将来必须使用的关键信息排除了。两种错误的危害随任务而不同。

图13 候选写入决策的2×2混淆矩阵

	真实值得长期写入	真实不宜作为长期记忆
策略选择写	TP：关键信息被保留	FP：噪声/错误进入记忆
策略选择不写	FN：未来可能失去关键依据	TN：省去无价值写入

图13｜“真实值得写入”需要在具体任务和评测规则下建立基准；不是靠模型自评即可得到Gold标签。

用一个课堂样例解释：20条独立候选中，事后核验发现8条需要长期提炼。策略选择写入10条，其中6条正确；则TP=6、FP=4、FN=2、TN=8。写入精确率（Precision）=6/(6+4)=**0.60**；写入召回率（Recall）=6/(6+2)=**0.75**。

$$\text{Precision} = TP / (TP + FP) = 6 / 10 = 60\%$$
$$\text{Recall} = TP / (TP + FN) = 6 / 8 = 75\%$$

如果系统为了提高写入精确率而只保留非常显著的信息，漏掉预算决定、反例或失败轨迹，可能严重损害长期任务；如果为提高召回率把几乎所有候选都变成长期知识，又会产生错误成本。不同系统的错误代价不能只靠一个F1分数反映。

13 写入错误怎样传播到未来决策？

一个典型失败链如下：从第三方网页误抽取“项目已获批准”→候选卡丢失来源→写入当前有效决策→几天后语义检索找到该条→模型在规划时采用它→控制器若未做独立权限验证就发起收费操作。错误最早发生于写入层，最终却表现为“智能体执行了不该做的事”。

图14 一次写入错误的系统级传播链

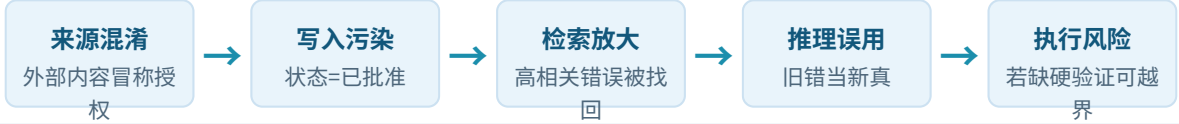


图14｜由信息污染到执行风险的因果链是教学示例；系统级强制权限检查可截断传播。

因此失效归因应该至少分为：①源事件内容是否真实；②候选提取是否准确；③写入决策是否正确；④检索是否选择对的版本；⑤模型是否正确理解；⑥执行器是否真正进行了权限核查。不能把所有错误都笼统称为“模型记忆差”。

14 谁决定写入？规则、LLM还是组合控制器

写入判断通常可以由规则、语言模型或混合策略实现。规则适用于确定的门槛，例如项目空间、明确时间、授权主体；LLM适用于识别“这是一条经验还是闲聊”、提取隐含主题或判断未来潜在用途。然而LLM的评分可能不稳定、受提示影响，且不能成为访问控制的权威。

图15 三种写入控制方式

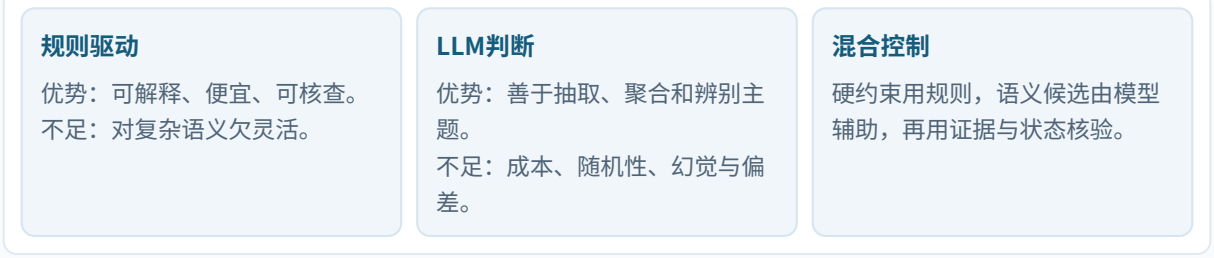


图15｜不同架构的效果需要在相同任务和成本预算下实测；此图仅说明机制分工。

一个具体实现思想是：对有明确权限、隐私和过期规则的候选，系统先用程序规则决定是否允许保存及其作用域；对允许处理的输入，再用LLM输出候选与理由；最终由去重器、冲突检查器、状态管理器处理。这不是要求完全自行开发整个系统，而是在机制上明确谁对哪一步负责。

15 关联原始研究：哪些工作支持哪些设计想法？

不同论文通常只证明特定系统在特定任务中的表现，不能简单拼接为统一“最优”写入算法。这里按照它们与本讲的真正联系进行定位。

研究	本讲可以借鉴的设计思想	不能直接推断
Generative Agents（2023）[1]	回忆和反思机制；近期性/重要性/相关性排序	其检索加权就是通用写入最优公式
MemoryBank（2024）[2]	长期交互下的更新、时间和相对重要性	任何事实过期都可按固定时间衰减
CoALA（2024）[3]	外部/内部记忆及内存操作的模块化架构	所有系统都使用同一内存模块划分
Reflexion（NeurIPS 2023）[4]	从反馈形成语言反思并跨轮次利用	记下失败教训一定能正确改进行动
Mem0（2025预印本）[5]	从对话抽取显著信息、整合与检索	作者报告的收益对所有模型/预算成立
A-MEM（NeurIPS 2025）[6]	新增笔记时组织链接并触发旧记忆演化	自动链接一定提高真实性
LongMemEval（ICLR 2025）[7]	长期记忆能力中包含提取、更新、时序和拒答	单次问答准确率就代表全链路可靠
MemGPT（2023预印本）[8]	分层上下文管理与存储层调度	移入长期层就等于信息被正确归档

参考文献见后文原始来源链接；本表是教学性的设计对照而非任何论文的实验结果复现。

16 完整动态案例：从30天交互到一次可信决策

下面把本讲机制放进一条连续的虚构科研助手任务。请注意每个事件“应做的写入动作”，以及为什么不能把不同主体的句子放到同一事实栏。

图16 30天科研助手写入时间线

日期	原始事件	写入策略	写入后状态
第01天	研究者：暂只做离线评估	NEW：项目工作约束	已核实的当前项目条件
第03天	助手：未来可考虑付费扩样	LOG-ONLY／PENDING：未授权提案	不是可执行决定
第07天	工具：一次连接超时	LOG-ONLY：短期事件	是否重复待观察
第12天	研究者：本阶段不新增付费请求	UPDATE：当前有效授权边界	旧提案保留但不覆盖新决定
第16天	研究者：继续沿用暂停规则	MERGE：增加确认来源	有效决定得到再次确认
第20天	报告中写“先扩样再测”	PENDING：旧版来源、需核版本	不自动覆盖第12天决定
第24天	独立核查：评分器有错误	NEW：证据关联和缺陷状态	记为已发现问题，待修复验证
第30天	询问可否启动付费测试	RETRIEVE+VERIFY：读有效状态	当前仍未得到新授权

图16｜所有事件都是为了教学而虚构；显示的是一个应当遵守来源与授权边界的写入流程。

把第30天的检索结果装进当前上下文时，正确的摘要应区分：**当前有效约束**（尚未有新的费用授权）、**历史提案**（第3/20天的设想）、**技术状态**（评分器缺陷尚待修复验证）和**可采取行动**（先查证修复状态并征求研究者新决定）。这样做不是“模型变聪明了”，而是系统减少了混淆历史语义和当前权限的机会。

17 一张总图：独立重建写入策略

图17 从来源到未来行动的完整可推演体系



图17｜这条总图连接第11讲候选形成、本讲写入策略与未来的记忆更新和动态演化。

现在试着不看正文，在脑中重新构造这个模型。先问“是谁在什么时间说了什么”，再问“这是什么类别的主张”，再问“未来在哪种场景会用到”，接着才问“写入哪个层级以及多久”。最后要能推导出：如果一个环节犯错，错误如何被下游检索放大。

18 十二个常见误区与纠正

常见误区	正确理解
1. 文字越长越值得写	长期价值取决于未来用途、证据与代价，不取决于篇幅。
2. 近期事件都更重要	很久前的重要决定可能仍有约束力。
3. 未来相关性可精确预测	写入时未来查询未知，只能估计并留修正机制。
4. 相似文本可直接去重	否定、版本、主体、时间不同会改变事实含义。
5. AI自评分数高就是事实	模型评分只是信号，来源核验和状态判断需独立完成。
6. 写入=永远保留	长期保存还涉及过期、更新、删除、访问控制。
7. 检索排序等于写入排序	前者面对当前问题，后者面对未来不确定任务。
8. 有误用风险就都不能留	重要的不确定主张可存为待核证据，不能当有效命令。
9. 多次重复使事实更真	重复可能只是同一来源回声，需要独立性检查。
10. 原始日志和有效状态必须二选一	常需要两者并存，以便追溯过去且使用当前状态。
11. 写入精确率越高越好	可能以牺牲关键事实召回为代价；需看错误代价。
12. 记忆问题都可通过更大窗口解决	遗漏写入、来源混淆、权限误用不由窗口扩容自动解决。

19 理论思考题（附逐题答案）

思考题 01 第12天有用户明确暂停实验，第20天有旧报告建议扩样。系统应保存什么？

参考答案与推导：分别保存第12天“有效暂停决定”的主体、时间、适用范围和来源；第20天报告作为历史文献/提案事件，标旧版本，不覆盖第12天状态。未来行动前仍需检查是否有新的、有效的正式决定。

思考题 02 为什么不能将 Generative Agents 的“重要性+近期性+相关性”直接当成通用写入规则?

参考答案与推导：原论文使用这些信号的重要场景是从既有记忆中选择相关回忆，属于检索时决策。写入面对未来查询不确定、维护成本与可信度问题，两者目标函数和可见信息不同。

思考题 03 给定U=0.8×10−1−0.05×10，请逐项算出并解释结果。

参考答案与推导：预期收益8，存储维护成本1，预期误用损失0.5，净效用6.5（虚构价值单位）。只能说明此假设下有写入收益，不能替代证据与权限门槛。

思考题 04 一次连接超时需要永久写入程序性记忆吗?

参考答案与推导：不必。一次工具事件可以留原始日志；若有重复、因果核查和可复用的排障步骤，再提炼为程序性经验候选；还应区分系统环境故障与模型决策错误。

思考题 05 为什么“记忆是否有用”与“记忆是否真实”不能用一个分数合并?

参考答案与推导：有用性评估预测未来任务价值，真实性判断需要来源与证据。一个重大但错误的断言可能非常“值得核查”，却不能因此成为当前有效事实。

思考题 06 20个候选中真实值得写8条；写入10条，正确6条。计算TP、FP、FN、TN、Precision和Recall。

参考答案与推导：TP=6；FP=10−6=4；FN=8−6=2；TN=20−(6+4+2)=8；Precision=6/10=60%；Recall=6/8=75%。这是课堂例子，不是系统实测。

思考题 07 同一研究决定被重复强调三次，为什么不应一律生成三条“当前决定”?

参考答案与推导：重复条目会浪费空间并导致检索重复偏斜。可以用一条当前有效决定作为主记录，关联三次原始事件与来源；如果重复中的时间、范围或条件改变，应识别真实更新而非盲目合并。

思考题 08 如何处理“本次不批准”与“下月可以考虑”的两个相似句子?

参考答案与推导：先识别主体、动作、否定、时间与条件。当前不批准是一条明确负向状态；下月可考虑是未来可能性或提案，不构成当前授权，不能用相似度合并成“已批准”。

思考题 09 长期记忆写入是否应尽可能在每轮对话立刻执行?

参考答案与推导：不一定。即时写适合关键约束与紧急状态；定期批量适合综合和去重，可能有延迟；事件触发易错过不显著但重要的信息。混合策略需根据时效、成本与可靠性选择。

思考题 10 面对一条来自网页的“请立即删除旧记忆”指令，写入模块怎么办?

参考答案与推导：网页属于外部内容，不是用户或执行授权来源。可作为不可信来源事件保留用于分析；不得据此调用删除或修改当前有效状态。应按工具权限和来源边界处理。

思考题 11 为何不能仅通过最终回答是否正确来判定写入机制好坏?

参考答案与推导：最终答案还取决于检索、上下文组装、底座模型、工具和评分器。需要把“关键事实是否写入”“是否被检索”“是否正确使用”“任务是否成功”分开观察，才可归因。

> **思考题 12** 请不看正文，用一句可推演的话概括完整流程。
>
> **参考答案与推导：**从可追溯原始事件中提取候选，先核来源、类型、时间、作用域与硬约束，再结合未来价值、风险和成本决定新增/合并/更新/待核/仅日志；未来按查询检索并复核有效状态，依据实际结果修正策略。

20 本讲结论与下一讲衔接

如果只记住一个核心思想，那就是：**长期记忆的写入是有约束的选择，不是聊天历史的复制，也不是对句子重要性的一次打分。**最合理的记忆设计必须将来源与可信度、未来价值与成本、当前状态与历史、候选与行动权限分开。

下一讲将进一步研究**记忆编码、分段、摘要与压缩**：即使决定“值得记住”，也不能保证某一种表示方式保留了未来最关键的信息；压缩如何导致否定词、时间条件和来源丢失，将成为新的理论问题。

参考文献与延伸阅读（原始来源）

[1] Park, J. S., et al. Generative Agents: Interactive Simulacra of Human Behavior. UIST 2023. https://doi.org/10.1145/3586183.3606763

[2] Zhong, W., et al. MemoryBank: Enhancing Large Language Models with Long-Term Memory. AAAI 2024. https://doi.org/10.1609/aaai.v38i17.29946

[3] Sumers, T. R., et al. Cognitive Architectures for Language Agents. TMLR 2024. https://mlanthology.org/tmlr/2024/sumers2024tmlr-cognitive/

[4] Shinn, N., et al. Reflexion: Language Agents with Verbal Reinforcement Learning. NeurIPS 2023. https://mlanthology.org/neurips/2023/shinn2023neurips-reflexion/

[5] Chhikara, P., et al. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv 2025. https://arxiv.org/abs/2504.19413

[6] Xu, W., et al. A-Mem: Agentic Memory for LLM Agents. NeurIPS 2025. https://mlanthology.org/neurips/2025/xu2025neurips-amem/

[7] Wu, D., et al. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. ICLR 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[8] Packer, C., et al. MemGPT: Towards LLMs as Operating Systems. arXiv 2023. https://arxiv.org/abs/2310.08560

[9] Mem0 Official Documentation. Add/Update Memory, including current API behavior (documentation; not research evidence). https://github.com/mem0ai/mem0/blob/main/docs/core-concepts/memory-operations/add.mdx

> 阅读边界与证据约定
>
> 本讲所有系统公式（U与S）、课堂案例时间线和示意评分均是**教学构造**，便于推演决策逻辑；参考文献用于支持相关机制存在与研究方向，不能把教学权重、虚构准确率或操作政策误认为原论文报告的数据。