第五部分 · 记忆的检索与利用机制

什么时候应该检索记忆？

主动触发、被动检索与记忆选择

Retrieval Triggering · Query Routing · Decision Policy

> 需要历史时，准确找到关键证据。
> 不需要历史时，避免无意义检索。
> 真正重要时，以有效状态和来源核验决策。

零基础理论课 · 14张机制原理图 · 12道思考题与详细答案

v1.0 | 2026-10-18 | 纯理论，无实验

第21讲｜什么时候应该检索记忆？

《智能体记忆系统：从零基础到科研理解》 · 第21/32讲 · 第五部分：记忆的检索与利用机制

副标题：主动触发、被动检索与记忆选择——让过去的信息在恰当时刻进入当前决策

这一讲要解决的根本问题： 智能体已经有了长期记忆，也建立了文本、结构化、向量和图等检索入口，是否应该每次回答前都检索？什么时候不检索反而更好？谁来决定检索？检索后得到的旧信息与当前有效状态冲突怎么办？

阅读约定： 本讲只进行理论学习，不安排编程、软件配置或实验操作。D01—D30科研助手、所有概率、毫秒、Token、货币与评分值均为**专门构造的教学示例**；研究论文的真实机制与我们为了讲课提出的抽象模型会明确区分。图中的箭头表示可以用来理解的处理步骤，不意味着所有系统都必须使用同一种实现。

本讲的学习目标与知识地图

学完本讲，应能够独立解释：①记忆检索的**触发**与第18讲的**索引搜索**为什么是两个不同层次；②始终检索、按规则检索、由模型提出检索、分阶段自适应检索有何区别；③什么时候历史记忆可以帮助，什么时候它会引入噪声与过时错误；④如何拆解“查询意图—检索目标—证据类型—结果核验—决策执行”；⑤如何从期望收益和错误代价理解是否检索；⑥能手工计算两道简化成本题；⑦如何区分检索准确率、触发决策准确率和最终任务成功；⑧面对跨30天科研助手的连续事件，独立作出检索、跳过检索或先查权威状态的判断。



图1 · 检索是一个受控决策链，而不是只调用一次向量搜索

> **本讲总原则：** “能够检索”是存储系统的能力；“知道什么时候值得检索”是控制策略的能力；“检索后不被旧信息误导”是证据核验和行动控制的能力。三者不能互相代替。

一、从一个悖论开始：记忆越多，为什么可能反而做得越差？

想象一位连续工作30天的科研智能体。它积累了数百条会议记录、研究方案、工具日志、论文笔记和错误反思。某天用户问：**“3加5等于多少？”** 系统若先从几百条科研记忆中取回大量历史，不但没有帮助，还增加计算成本、挤占上下文，并可能把不相干的实验数字混进回答。

同一天，用户又问：**“此前为什么暂停那个付费实验，现在能恢复吗？”** 若智能体完全不检索历史，便无法核对当时的决定、限制条件和是否存在后续授权。此时跳过检索可能产生严重错误。

这两问背后的模型可能是同一个，记忆库也没有变化，**不同的是当前任务对过去信息的依赖程度、错误的后果，以及正确证据位于何处**。因此，检索并非“每次越多越好”的机械动作，而是一个随任务变化的策略决策。



图2 · 只有任务的历史依赖与后果变化，检索策略就可能反转

1.1 “检索触发”与“检索算法”不是同一个问题

前面几讲讲BM25、Embedding、向量近邻、图遍历。它们主要回答：**已经决定要找了，怎样找到候选?** 本讲研究的是前一个关口：**眼前这道题究竟要不要找？为什么现在找？找什么？什么时候停?**

例如：

- **是否触发**：用户问的是数学常识，还是之前的项目决定?
- **如何构造查询**：搜索“暂停收费”还是搜索“最新有效许可、项目范围、截止时间”？
- **选择来源**：是查对话总结、结构化决策，还是查工具原始回执?
- **检索后验收**：相似文本是否真的由用户授权？是否仍然有效?
- **停止或升级**：找不到可信依据时，是继续搜索、明确无法确定，还是请用户决定?

如果把这些环节全部压缩为“向量Top-5”，系统便没有真正解决检索控制问题。

1.2 检索动作发生在哪里?

可以把智能体控制循环理解为：接收问题→观察任务及当前上下文→判断信息是否足够→必要时调取记忆→核对来源与状态→推理/规划→工具行动→获得反馈。注意，模型可能**建议**检索，控制器也可能依据明确规则**强制**检索；这并不是同一个主体所做的决定。

二、什么信号说明“现在可能需要回忆”？

我们先区分三类需求：**不需要过去、过去可能有帮助、必须核验过去或最新有效状态**。这种分法是本讲的教学决策框架，不是某篇论文已经证明普适的三分类。



图3 · Skip / Optional / Required 三类情形（本课程教学抽象）

2.1 明确要求历史的触发信号

用户说“之前”“上次”“我们讨论过”“继续那个任务”“根据上次失败”“按照已经批准的方案”时，通常明确要求跨会话信息。此时如果当前上下文没有完整可靠依据，就应考虑从对应项目与时间段检索。

但**出现“之前”二字并不保证一定应该检索长期存储**：如果这项内容已经在本轮完整上下文中，重复检索的边际价值可能很小。反过来，没有这些词也不代表不需要历史。例如“继续执行项目”隐含着任务进度与既有约束。

2.2 隐含需要历史的触发信号

用户说“帮我调整剩余计划”。看似只是一句新要求，实际需要知道**已经完成什么、还有什么、之前为何改变计划**。缺少这些历史，很容易把已完成步骤重新安排，或无视失败经验。

类似情况还有：根据长期偏好推荐、比较两次研究决定、回答某个项目的当前状态、补做上次中断的步骤、总结多天变化。系统需要识别**任务依赖结构**，而不仅是做关键词匹配。

2.3 高后果和强约束场景

当问题涉及权限、付费、外部操作、隐私敏感数据、实际环境最新状态等，通常需要额外核对权威信息。要强调的是：**这可能首先需要查“当前有效的结构化状态或外部系统”，而不是搜一段聊天记忆**。

例如，“可以恢复收费实验吗？”即使某段旧记忆写着“可以”，控制器仍然应该查最新许可范围与执行限制。历史文本是理解原因的证据，**不代替授权核验**。

2.4 缺失、冲突与不确定性信号

模型看到几个互相矛盾的历史片段时，检索源文和有效时间通常有价值；当没有证据支持一个具体历史断言时，也可以触发检索。但要区分**模型的主观不确定**与**客观证据缺失**：模型自称“我很确定”，不代表证据真的存在；模型自称“不确定”，也未必能从记忆库里找到答案。

三、四种常见的检索触发策略



图4 · 研究路线与教学比较；并非同一种论文方法的四个参数

3.1 策略A：每轮固定检索（Always-Retrieve）

做法：任何用户问题都查询记忆库，并返回固定数量的片段（如Top-5）。优点是控制逻辑简单，不太会漏掉明显的历史依赖；缺点是容易产生不相关文本、额外API与检索成本、上下文污染、延迟和过时信息风险。

它适合作为一种**需要明确成本口径的对照基线**，不是所有长期助手的最佳方案。尤其对于简单算术、同轮可直接回答的内容，额外检索通常没有直接收益。

3.2 策略B：按规则触发（Rule-Based）

做法：依据明确的任务类型、用户历史引用词、状态读取要求等，触发特定检索。例如问“历史决定”就查事件日志；问“当前许可”就查结构化有效状态。

优点是可解释、便宜、边界容易核查；缺点是覆盖不了所有隐含需求。用户说“根据我们一路的研究，给一个建议”，没有标准关键词，规则可能漏掉真正需要的跨会话经历。

3.3 策略C：模型建议工具检索（LLM-Directed）

做法：模型判断当前信息不够，提出使用记忆搜索工具，并构造查询。CoALA把记忆操作纳入Agent动作空间，ReAct研究把推理过程与外部动作交替进行；MemGPT探索让模型参与不同记忆层之间的信息管理。[1][2][3]

但这不是自动获得可靠性的保证：模型可以**忘了自己需要检索**，也可能搜索错项目，甚至因自信过高而直接编造历史。控制器应约束工具范围、次数、预算与权限，关键状态核验不应完全依赖模型是否“想起来”。

3.4 策略D：自适应/分阶段检索（Adaptive / Multi-Stage）

做法：先使用已有上下文或低成本精确查询，必要时扩大到关键词、语义检索、时间过滤或多跳查询，再按证据充分程度决定停止。对于具体的RAG研究，Self-RAG讨论按需检索与自我反思，Adaptive-RAG依据问题复杂度选择不同检索策略，FLARE研究生成过程中的主动检索。[4][5][6]

重要区分：上述工作并不等同于已经完整解决“长期智能体的记忆触发”这一问题。我们借用其**选择是否检索与何时追加检索**的研究思想，不能把论文的方法名称直接当作某个实际智能体记忆控制器的现成实现。

四、触发决策究竟由谁做?

一个工程系统可以把决策分为三层：**确定性的硬约束、任务分类与控制策略、模型提出的可选检索建议**。



图5 · 模型的可选检索建议受系统控制与权限规则约束

- **硬约束**：遇到付费许可、访问控制、删除权限等必须读权威状态，不能只凭对话猜测；这是控制层规则。
- **策略层**：根据任务依赖、可得证据、延迟预算，决定是否检索、走哪些入口。
- **模型层**：模型可主动发现缺失信息、提出查询词、解释为何需要过去经历，但不可越过上层约束。

这里尤其要留意：**“模型提出调用”与“工具实际成功返回”不是一回事**。系统需要记录请求、执行、实际检索结果和是否进入上下文。后续若答案错误，才能定位是没有触发、没有执行、没有找到还是找到了却用错。

五、一个可推导的判断模型：什么时候检索“值得”？

在非强制检索情形中，可以用“预计收益减去成本”的方法理解策略选择。我们给出一个**教学效用公式**，并不声称这是Self-RAG或任何论文的标准公式：

$$\Delta U = P(\text{不检索错误}) \times L(\text{不检索损失}) - P(\text{检索后错误}) \times L(\text{检索后损失}) - C(\text{检索})$$

其中`P(error)`表示相应策略下发生错误的估计概率，`L`表示发生错误造成的损失，`C_retrieve`把延迟、Token、外部API费用和不相关记忆的干扰折合成相同单位的效用代价。**只有单位一致才能相减**；实际系统不能把“毫秒+人民币+准确率”直接相加。



图6 · 所有数值均是教学假设，实际概率与成本必须通过数据估计

5.1 手算例子A：一个高度依赖历史的任务

假设系统要回答“上次为什么停止那项工作？”。为了演示，设不检索时错误概率为0.30，错误损失为10个效用单位；检索并核验后错误概率为0.08，错误损失仍为10；检索总成本为0.5个效用单位。

则不检索的期望错误损失=0.30×10=3.0；检索后的期望错误损失加成本=0.08×10+0.5=1.3；净改善=3.0-1.3=**1.7个效用单位**。在这个假设条件下，检索是值得的。

请注意，0.30与0.08只是为了手算，不是我们测得的概率。模型若把它们看作实测数据，就犯了**教学公式冒充经验规律**的错误。

5.2 手算例子B：一个无需历史的算术问题

同样设简单算术题不检索时错误概率0.01，错误损失10；检索后错误概率仍为0.01，检索额外成本为0.5。此时不检索成本=0.10；检索成本=0.10+0.5=0.60，净收益=**-0.50**。对这道问题，检索只是在支付额外成本。

5.3 为什么不能机械套用单个阈值?

任务损失不同，证据重要性不同，检索对正确率的改善也不同；成本还取决于索引类型、历史长度、工具费用与响应时限。所以“置信度低于0.6就检索”只能是某类系统的候选启发式，**不能未经校准就作为普适科研结论**。

另一个更基本的边界是：权限、隐私与安全的硬约束不能直接被上述期望值优化所取代。所谓“省0.5成本所以不查授权”不是合法的替代关系。

六、触发检索之后，还要回答“到底找什么？”

这时才进入前面学习过的检索技术。第一步不是马上算Embedding，而是先把用户问题**拆解成可查证的子问题**。

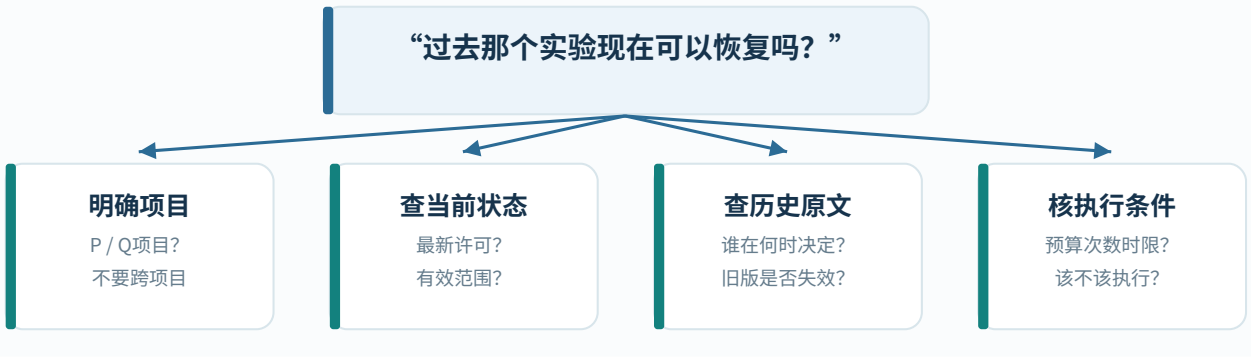


图7 · 查询改写应保留实体、时间、状态和授权边界

6.1 从用户语言提取检索目标

用户问：“根据之前的经历，现在那个实验可以恢复吗？”至少包含：当前是什么项目？“之前的经历”指哪次实验？是否有正式暂停决定？其有效时间与作用域如何？有没有后续授权？当前请求要的是“执行”还是“分析可行性”？

注意，系统不能凭相似度把“项目A的暂停”误当“项目B的决定”。**实体ID、项目作用域、时间范围和命令类型**都应成为查询构造条件。

6.2 查询改写与扩展

从一句含糊的话变成数个有目的的查询，例如：

- **状态查询**：项目ID=P-07，取最新有效授权与限制。
- **事件来源查询**：检索D08/D20决策原文、记录主体与时间。
- **失败经历查询**：检索故障ID、工具回执和后续归因结论。
- **背景经验查询**：与该项目相关的过往失败总结，保留来源及是否适用。

不要把问题改写成带预设结论的引导式查询，比如把“是否批准”改为“查找已经批准的证据”，这样很容易诱导检索偏向预期答案。

6.3 检索目标不同，入口也不同

如果需要查精确决策状态，应优先使用**结构化字段与当前权威状态**；如果寻找语言表达相近的经验，使用**向量相似检索**；若要求准确字符串、编号或状态码，使用**全文索引或ID查询**；如果要追溯不同结论间的多跳联系，再考虑**图路径查询**。

这里没有一个固定要求“每轮四种检索全开”的规定。越复杂的管线会引入越多同步、排序和成本问题。检索策略应由任务需要反推架构，而非由已经购买了什么数据库来决定。

七、从“找到相关”到“真正能用”：检索之后的三次把关

即使搜索引擎返回了高度相关的历史片段，仍可能出错。可以把检索之后的检查分为三关：**身份来源、时间与有效状态、面向当下任务的证据充分性**。



图8 · 来源、时间与证据充分性不可由单个向量分数替代

7.1 身份来源

AI在D03提议“扩大付费实验”，研究者在D08明确“不批准”。两条记录都与“收费实验”高度相关，但角色与行为类型不同。**AI建议不是研究者批准**；检索不能仅按语义权重作“最新最强”决定。

7.2 时间与有效状态

系统检索到D08不批准之后，还应该检查是否有D20更新、D26特定范围许可等。即使D26存在，也必须判断它是否仅限某个项目、预算上限、调用次数和时限。**新记录不必自动覆盖所有旧规则**。

7.3 证据充分性与未知

搜索没找到批准信息，只能说“目前在可访问的记录中未找到批准依据”，不能机械推断“世界上从未批准”。相反，也不能从没有查到限制就猜测“默认允许”。在重大外部行动场景，应由权威控制机制决定，不应把检索缺失转成授权。

八、检索何时停止？一次没找到就无限多查吗？

没有停止准则，主动检索很容易变成无界循环：查一次→模型不放心→继续查→换关键词再查→重复命中同一事件→费用与延迟失控。一个实用的教学机制是设计**有界的阶梯式检索**，而不是持续探索直到模型“感觉满意”。



图9 · 省成本不能以漏掉必须核验的约束为代价

1. **第一阶**：直接查询当前结构化状态或已有明确ID、时间和项目的来源。
2. **第二阶**：若关键证据缺失，使用同一来源的关键词与语义候选，并做时间、身份、作用域过滤。
3. **第三阶**：仅在需要复杂关系时扩展到多跳查询、源文回溯或更宽时间范围。

4. **终止**：证据已足够且一致，或已触达请求次数/Token/延迟上限，或进一步检索没有新增证据，或已经确认原始资料不可获得。
5. **输出未知或转交**：如果关键权威依据缺失，保留不确定状态；需要用户授权时向用户明确提出，不用自造结论填空。

8.1 一个受控的重复检索例子

教学设定每个问题最多3次检索，第1次命中正确项目但只找到旧版本，第2次使用时间过滤找到新版本，第3次仅在仍有冲突时回原始批准记录。若第2次已经找到了最新、来源明确且没有冲突的权威状态，可以在第2次停止，不必为了“用完次数”再查。

在研究中不能无差别统计“检索次数越少越好”。少到漏掉必须核验的状态，可能导致质量严重下降；多到查大量无关内容，则产生额外成本。应报告**每类任务的收益—开销—错误后果**。

九、贯穿案例：科研助手30天里的七类问题

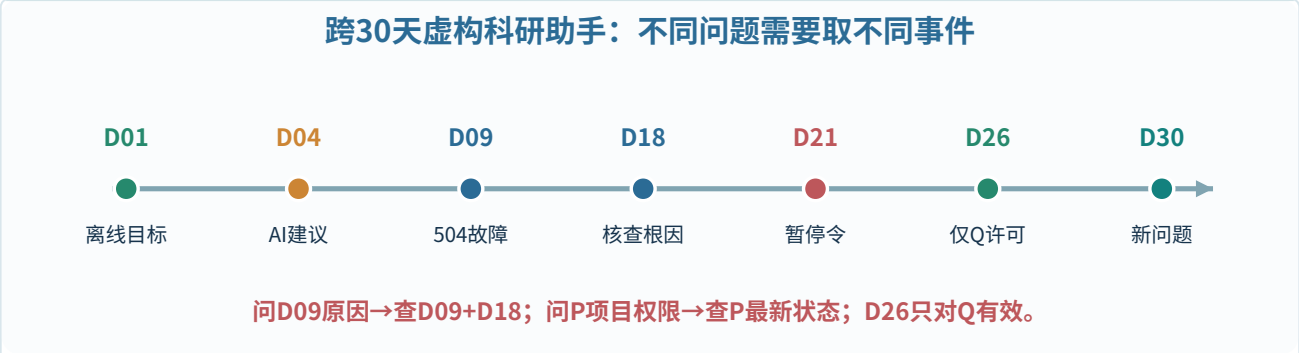


图10 · 不同问题的证据窗口、来源和适用范围并不相同

下面所有日期和消息均为**虚构教学情景**，用于推演，不是用户实际科研任务记录。

- **D01**：研究者确定“当前仅进行离线梳理，不启用新增收费API”。
- **D04**：AI提出“扩大到100次付费实验会更充分”，记为AI建议，未获准。
- **D09**：一次工具请求返回HTTP 504，有原始日志，尚未确定原因。
- **D13**：另一个Agent总结“网络可能有问题”，属于有不确定性的分析。
- **D18**：核对网关日志后，将D09该次错误定位为网关超时；范围限于该事件。
- **D21**：研究者重申“未经新授权，不得恢复新增收费实验”。
- **D26**：在另一个项目Q上，研究者批准限10次、总额20元的一次性测试；该许可**只适用于项目Q**。
- **D30**：用户提出一系列新问题。

9.1 D30问题A：“5乘以6等于多少？”

无需历史。模型可直接运算；若系统每次检索旧实验记忆，可能造成不必要的成本。**触发策略：跳过长期记忆检索。**

9.2 问题B：“上次那次504的原因是什么？”

需要区分D09故障原始事实、D13猜测与D18查证结论。若只取最早的候选，可能误把“可能是网络问题”说成证实的原因。**触发策略：检索故障事件和后续归因，回源核对。**

9.3 问题C：“项目P现在能恢复收费实验吗？”

需要最新有效状态，D26在Q项目上的许可不自动适用于P。**触发策略：强制核验P项目当前权限与时间条件；历史检索用于解释，不代替控制器许可。**

9.4 问题D：“前一次类似故障有什么经验可以复用？”

需要跨事件经验，不一定有单个准确关键词。**触发策略：语义/关键词混合召回经历，再对照当前环境与版本筛选经验是否适用。**

9.5 问题E：“总结D01到D21的决策如何演化。”

需要带时间的多事件证据，以及区分建议、假设和正式决定。**触发策略：事件时间线+结构化状态来源，必要时进行多跳关系检索。**

9.6 问题F：“我们现在讨论的这一页内容是什么意思？”

若信息完整处于本轮上下文中，可能不需要跨会话检索；但若“这一页”指没有提供的资料，则首先应读取文档而不是捏造内容。**触发策略：先核对当前可见资料，缺少时再查指定文档。**

9.7 问题G：“帮我直接运行D26批准的动作。”

即使检索找到了D26相关记录，仍需核对**实际目标项目、行动范围、预算余量、时限和用户此轮意图。触发策略：权限状态强制核验并经控制器执行检查**，不因历史批准文字相似而自动实施。

十、检索控制的故障会发生在哪一层？

从系统工程角度看，至少有六个不同失效层次。



图11 · 保留触发、查询、候选、核验与真实行动记录，才能做可靠归因

层次	典型错误	举例	为什么不能混淆
触发层	本该检索却没有检索	询问旧决定，模型直接猜	搜索索引再好也无机会工作
查询层	问题改写错误	把项目P改成Q	系统可能准确地检索到错误项目
索引层	候选遗漏、索引滞后	旧版本比新版本先返回	触发正确却找不到证据
状态核验层	旧建议被当成许可	D04建议覆盖D21决定	相似性不能代表有效状态

层次	典型错误	举例	为什么不能混淆
上下文利用层	找到且读入仍答错	模型忽略“未经授权”	Retriever正确≠Reader正确
控制执行层	文本提议被越权执行	未核预算就提交请求	输出语言不能替代实际许可

诊断时应保留**是否触发、触发理由、查询文本、候选ID、过滤规则、当前有效版本、上下文组装与实际工具执行**。只看最后答案对不对，无法判断错误究竟来自哪一层。

10.1 为什么“无检索”也需要记录?

如果系统为了省Token决定不检索，应记录其判断依据与可用信息条件。否则后续出现错误，无法区分“策略主动跳过”与“工具连接失败/调用意图丢失”。当然这不意味着必须保存模型内部思维链；可以只记录**结构化动作与结果**。

10.2 检索结果为什么不该直接进入行动?

因为检索返回的是**资料和候选主张**，不是可执行许可。尤其对有界付费任务、外部副作用、敏感数据操作，应以控制器和实际用户批准的权限状态作为执行门槛。

十一、如何评价“检索触发策略”好不好?

不能只看检索的Recall@K，还应衡量触发策略把“该检索”和“不该检索”区分得怎样，以及最终任务是否真正受益。

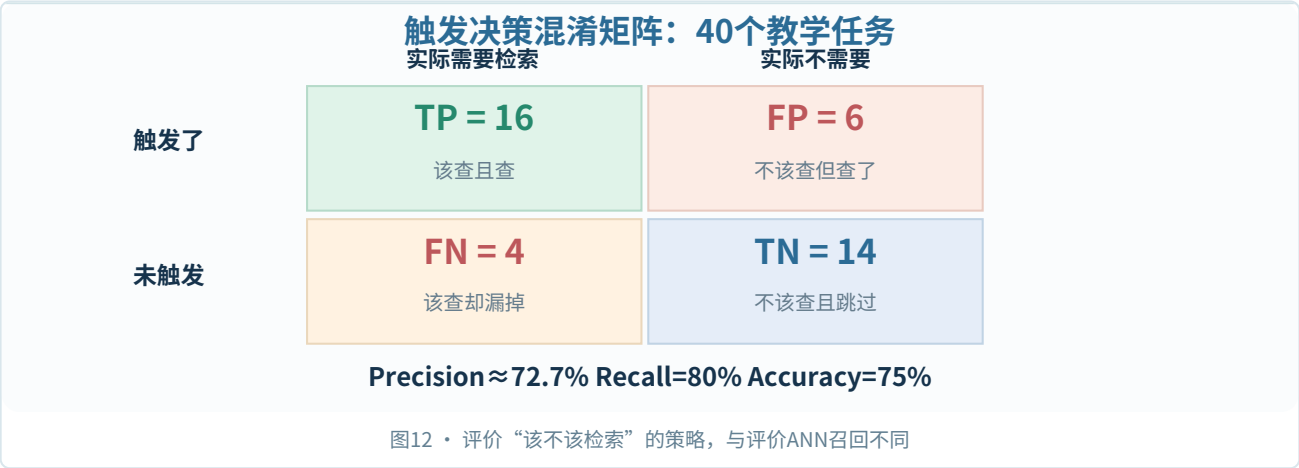


图12 · 评价“该不该检索”的策略，与评价ANN召回不同

11.1 触发混淆矩阵（教学数值）

设有40个任务，经独立标注，其中20个需要检索、20个不需要。某策略对真正需要的20个触发16个、漏掉4个；对不需要的20个误触发6个、正确跳过14个。则：

- TP=16，FN=4，FP=6，TN=14。
- **触发精确率 Precision=16/(16+6)=16/22≈72.7%。**
- **触发召回率 Recall=16/(16+4)=16/20=80.0%。**
- **不必要检索率**（在不需要检索的任务中）=6/20=30%。
- **触发准确率**=(16+14)/40=75%。

这些数字是课堂练习，不是Self-RAG、Adaptive-RAG或任何具体产品的实测结果。

11.2 为什么检索触发准确不代表答案正确?

假设需要检索的题目全部被触发，但关键词写错，候选仍可能遗漏；即使候选正确，模型也可能误读时间、条件或来源。反过来，某个问题本来可以不检索，系统多查了一次仍答对，但产生额外成本。因此**必须分别评价**触发质量、证据召回、证据正确使用、任务成功、延迟、Token与费用。

11.3 如何设计不偏袒复杂方案的理论比较?

即使现在不做实验，也应理解未来研究比较所需的公平性。一个合理的基线梯度可以包括：**不调用长期记忆、每轮固定检索、明确规则触发、由LLM建议触发、自适应分阶段触发**。让它们面对相同任务、底座模型、可访问记忆、工具约束和总资源预算，比较增益是否来源于触发策略本身，而不是“复杂方案额外看到了正确答案”。

难度、历史长度、信息过期比例、权限场景和是否存在可靠证据都可能影响结果。若不同组调用了不同模型或获得不同额外信息，就不能简单把结果归结为“触发算法更好”。



图13 · 单一Recall@K或答案准确率不足以解释触发策略的价值

十二、把代表性论文放回准确的位置

研究	与本讲的直接关系	不应作出的错误外推
Generative Agents (2023)	用相关性、时间与重要性驱动经验检索，支持行为规划	检索评分不能直接证明事实或执行许可
CoALA (TMLR 2024)	将记忆与外部环境操作纳入Agent的动作空间和决策框架	是架构框架，并非统一的实际检索触发算法
MemGPT (2023)	通过虚拟上下文与记忆操作管理有限上下文	调入信息不保证语义正确
ReAct (ICLR 2023)	推理和行动交替、外部查询可以随步骤发生	不是专门针对长期记忆触发评测的系统
FLARE (EMNLP 2023)	生成过程主动决定何时取新证据	主要针对外部文档检索，不等于Agent记忆授权控制
Self-RAG (ICLR 2024)	按需检索与反思，避免机械固定检索	论文自反思标记不是普适可靠记忆监控器
Adaptive-RAG (2024)	随问题复杂度选择不同检索策略	问题复杂度不能直接替代记忆依赖或权限后果
LongMemEval (ICLR 2025)	将长期交互设计拆为索引、检索、读取，含时间和更新考核	回答历史问答正确不等于真实外部行动安全

科研观察：这些方法表明“检索时机”和“检索策略”确实是设计变量，但是否在某种Agent Memory工作负载中有效，需要结合误触发、漏触发、历史有效性和下游行动来验证。不能只凭系统故事宣称某种触发策略更优。

十三、常见误区：12个需要辨别的说法

1. **“有长期记忆就应该每轮读一遍。”** 错。许多任务不依赖历史，强制检索可能引入成本与噪声。
2. **“没有出现‘之前’就不需要历史。”** 错。继续进行中的项目往往隐含历史状态依赖。
3. **“模型自称很确定，就不用查了。”** 错。自评置信不等于有权威证据。
4. **“只要模型想到了工具，就代表完成检索。”** 错。还要有实际调用、成功返回及上下文使用记录。
5. **“低余弦相似度说明无需检索。”** 错。它只表示某种查询与当前候选的几何关系，不回答任务是否需要历史。
6. **“检索到旧决定就说明现在仍然有效。”** 错。需要有效时间与后续状态。
7. **“多个检索器一致就是多份独立证据。”** 错。可能都指向同一条来源。
8. **“复杂检索总优于精确查状态。”** 错。准确ID和有效许可往往优先结构化查询。
9. **“没找到批准记录等于允许执行。”** 错。缺失证据不能自动转成权限。
10. **“检索得越多，答案就一定越准。”** 错。会有噪声、冲突、延迟和上下文挤占。
11. **“触发精确率高就代表记忆系统好。”** 错。还要看漏触发、证据正确性、任务成功与成本。
12. **“某篇RAG论文按需检索有效，就能保证智能体长期记忆安全。”** 错。方法迁移和可靠性需要独立验证。

十四、理论思考题（先尝试独立回答）

题1：区分“决定是否检索”和“决定用哪个近邻索引”两个问题，并举一例。

题2：同一智能体被问“2+2=？”与“上次为什么暂停付费任务？”应分别采用什么触发策略？为什么？

题3：用户说“继续推进”，没有明确“上次”。为什么仍可能需要检索？

题4：模型表示“我很确信已经批准”，为什么不能跳过权威状态核验？

题5：给出固定检索、规则检索、模型建议检索各一个优势和局限。

题6：在手算例子A中，0.30、0.08、损失10、成本0.5时，检索的净效用是多少？

题7：若不检索错误概率0.02，检索后为0.01，错误损失10，检索成本0.4，应该检索吗？忽略硬约束。

题8：将问题“根据之前的经历，现在可以恢复那个实验吗？”拆成至少四个可核查的子问题。

题9：检索到D04的AI建议和D21的负责人限制，向量相似度前者更高。能否按相似度直接决定权限？

题10：计算TP=16、FP=6、FN=4、TN=14时的触发精确率、召回率与准确率。

题11：某策略能正确触发，却总是查错项目ID。属于哪个故障层？如何定位？

题12：设计一个不依赖实际实验的概念性评价框架，用来判断“复杂自适应检索是否值得用于长期科研智能体”。

十五、思考题答案与详细推导

答1：先判断是否存在历史依赖；只有需要找时才选择词项、向量或结构化索引。算术题可不查；核对过去批准先结构化查状态。两步分开能避免把“哪个搜索器好”错当“该不该搜”。

答2：`2+2`本身不依赖项目历史，跳过长期记忆更直接；暂停原因是跨会话历史事实，应触发事件/决定检索并回源确认。区别来自信息依赖而非模型的“记忆大小”。

答3：“继续推进”隐含当前进度、约束、已完成和未完成事项；若这些信息不在当前上下文，需要跨会话读取项目状态。仅检查关键词会漏掉隐式依赖。

答4：模型的自评可能没有校准，也不能决定是否已获用户许可。外部操作尤其应核对结构化授权范围、时间、预算和用户实际决定。**模型的语句不是权威状态**。

答5：固定检索实现简单但成本高；规则检索可解释但容易漏掉复杂隐含需求；模型建议有灵活性但会出现主观不触发或查询改写错误。实际可加入控制层硬规则与分阶段回退。

答6：不检索预期损失 $0.30\times10=3.0$；检索后预期损失加成本 $0.08\times10+0.5=1.3$；净收益 $3.0-1.3=1.7$ 个统一的效用单位。正值说明在这组假设下检索合算。

答7：不检索成本 $0.02\times10=0.2$；检索后 $0.01\times10+0.4=0.5$，净收益 $0.2-0.5=-0.3$；在示例假设且无硬约束时，应跳过检索。该结果不允许类推到所有任务。

答8：项目是哪一个？当前有效决定是什么？过去暂停何时发生、谁作出的？是否存在后来更改、批准范围、次数及费用限制？本轮请求是仅讨论还是实际操作？这些问题对应不同数据来源。

答9：不能。相似度只能指示候选内容与查询的语义相关程度；AI建议与负责人决定具有不同来源和权限效力。应核对最新、适用范围内的权威许可，再决定回答或行动。

答10：Precision=$16/(16+6)=16/22\approx0.7273$；Recall=$16/(16+4)=16/20=0.8$；Accuracy=$(16+14)/(16+6+4+14)=30/40=0.75$。三项指标衡量不同方面，不能互相替代。

答11：触发层成功，故障位于**查询构造/范围限定层**。应核对实际项目ID、用户指代消解、查询过滤条件、返回候选的项目ID和来源；不能因为向量数据库成功返回结果，就认定触发策略也正确。

答12：至少分别考察：①无历史依赖与强历史依赖任务的触发TP/FP/FN/TN；②候选来源与有效时间准确性；③下游问题回答/行动正确性与权限违规率；④检索次数、Token、端到端延迟、费用；⑤复杂多跳查询是否有真实收益；⑥对模型、历史长度、过期信息比例的稳健性。应同时比较不检索、始终检索、规则与自适应方案，并公平控制能看到的信息和预算。复杂方案若没有非平凡、可重复的收益，就未必值得引入。

十六、全讲总结：能够“想起过去”不等于应该“立刻翻旧账”

回到本讲的完整心智模型：智能体先理解当前任务；确定它是否依赖历史或当前状态；若需要，则决定去哪个权威来源或检索视图寻找；取得候选后验证来源、时间与范围；选择进入上下文的必要证据；最后再做推理和受控行动。每个环节都有独立的失败方式，因此检索策略要追求的是**对需要历史的任务及时、正确取证，对不需要历史的任务减少无意义打扰**。



图14 · 需要历史 ≠ 一律向量搜索；检索成功 ≠ 允许外部行动

从科研视角得到的原则：与其问“使用哪一种最流行的检索触发模型”，不如先明确：在什么任务、怎样的历史信息、什么代价结构下，哪种触发策略会漏掉关键记忆、引入噪声、误用过时状态或增加成本？把这样的问题定义清楚，才有条件开展可证伪的机制研究。

参考文献与延伸阅读（截至2026-10-18）

以下条目注明研究对象与年份；引用的论文机制与本讲教学公式、虚构案例有明确区分。链接可直接访问原始论文或官方档案。

[1] Sumers, T. R., Yao, S., Narasimhan, K., & Griffiths, T. L. **Cognitive Architectures for Language Agents (CoALA)**. TMLR, 2024. 记忆与内外动作的认知架构。 https://mlanthology.org/tmlr/2024/sumers2024tmlr-cognitive/

[2] Yao, S. et al. **ReAct: Synergizing Reasoning and Acting in Language Models**. ICLR, 2023. 推理与工具动作交替。 https://mlanthology.org/iclr/2023/yao2023iclr-react/

[3] Packer, C. et al. **MemGPT: Towards LLMs as Operating Systems**. arXiv:2310.08560, 2023. 虚拟上下文与主动记忆管理。 https://arxiv.org/abs/2310.08560

[4] Asai, A. et al. **Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection**. ICLR, 2024. 按需检索与反思标记。 https://proceedings.iclr.cc/paper_files/paper/2024/hash/25f7be9694d7b32d5cc670927b8091e1-Abstract-Conference.html

[5] Jeong, S. et al. **Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity**. arXiv:2403.14403, 2024. 查询复杂度驱动的检索路线选择。 https://arxiv.org/abs/2403.14403

[6] Jiang, Z. et al. **Active Retrieval Augmented Generation (FLARE)**. EMNLP, 2023. 生成过程中的主动检索。 https://aclanthology.org/2023.emnlp-main.495/

[7] Park, J. S. et al. **Generative Agents: Interactive Simulacra of Human Behavior**. UIST, 2023. 记忆动态召回、反思与规划。 https://arxiv.org/abs/2304.03442

[8] Wu, D. et al. **LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory**. ICLR, 2025. 索引—检索—读取三阶段与时序更新评测。 https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[9] Shinn, N. et al. **Reflexion: Language Agents with Verbal Reinforcement Learning**. NeurIPS, 2023. 通过语言反馈保留经验。 https://papers.nips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html

[10] Wu, D. et al. **LongMemEval-V2: Evaluating Long-Term Agent Memory Toward Experienced Colleagues**. 2026年公开项目代码与基准资料。偏智能体任务的长期记忆评估，课程只作补充阅读。 https://github.com/xiaowu0162/LongMemEval-V2

下一讲（第22讲）：记忆检索的查询构造、排序与上下文选择。 在此讲明确“什么时候找”之后，下一讲将深入研究“已经决定要找，怎样选择真正需要的记忆并避免将不该看的内容塞进上下文”。