第五部分 · 记忆的检索与利用机制

记忆检索的查询构造、排序与上下文选择

从含糊问题到可信、可追溯、可阅读的证据

Query Construction · Ranking · Context Selection

> 找得到，只是第一步。
> 知道哪条现在有效，才有可能答得对。
> 把证据放得恰到好处，才能真正利用记忆。

零基础理论课 · 14张机制原理图 · 12道理论题与答案

v1.0 | 2026-10-18 | 纯理论，无实验

第22讲｜记忆检索的查询构造、排序与上下文选择

《智能体记忆系统：从零基础到科研理解》 · 第22/32讲 · 第五部分：记忆的检索与利用机制

副标题：从一句含糊的问题，到一组有来源、有效期和容量边界的可用证据

本讲要回答的中心问题： 智能体已经在第21讲决定“需要查历史”，下一步应该怎么查？一句用户问题怎样变成可用于关键词、向量、结构化数据库和关系图的检索请求？如果检索出20条记忆，其中哪几条应该送进模型？高相似度的旧建议与低相似度的有效决定发生冲突时，如何避免错误？

阅读约定： 本讲仅进行理论学习，不安排实验、代码或软件操作。D02、D06、D12、D17、D23、D30均是虚构科研助手的教学事件，所有Token、评分、排序和延迟数据均为课堂构造。这里的架构图用来解释机制，并不是要求所有系统必须采用完全相同的软件组件。

学习目标与本讲在全课程中的位置

第07讲解释“语义如何变成向量”，第08讲解释“如何搜索”，第14讲解释“怎样管理时间和冲突”，第18—20讲解释“存储和索引结构”，第21讲解释“何时触发检索”。现在我们要把这些知识连起来，解决**检索之后的查询构造、候选排序与上下文选择**。学完应当能够：①拆解一个历史问题的对象、时间、事实类型和证据需求；②区分查询扩展、召回、融合、重排与核验；③手算RRF；④解释为何排序分数不是事实可信度或执行授权；⑤用Token预算从多个候选中选择互补证据；⑥区分检索指标与真正的任务正确性；⑦独立重建一次完整的Agent Memory Retrieval流程。



图1 · 从查询意图到证据利用：找到不是最终目标，正确使用才是

一、先看到问题：为什么“检索到历史”还不够？

设想一个长期协助科研工作的智能体。它保留了30天的对话、工具结果和项目状态。第30天研究者问：

> **“P项目现在能恢复付费API实验吗？请把依据说明白。”**

系统中其实有六条相关历史：

ID	时间	原始内容（教学简写）	来源及性质
M1	D02	“P项目当前只做离线分析。”	研究者明确范围
M2	D06	“可以考虑让P项目执行60次付费调用。”	AI提出的建议，**没有获批**

ID	时间	原始内容（教学简写）	来源及性质
M3	D12	“暂停P项目一切新增收费调用，除非我另行批准。”	研究者有效决定
M4	D17	某次工具返回HTTP 504。	工具事件，不是项目授权
M5	D23	“Q项目允许1次、最多20元的付费验证。”	研究者决定，但**只适用于Q**
M6	D25	“D12暂停P付费”的一份AI摘要。	派生摘要，非独立新证据

如果只做向量相似度检索，“P项目、付费、调用、实验”最相似的可能是M2，因为它直接讨论付费实验；“Q项目允许付费”也可能被错误找来。**检索到相关句子，不代表找到了当前正确的答案。** 正确的关键是把M3及其原始证据带入回答，不能因M2语义相似就把建议变成批准，也不能把M5跨项目扩展到P。[1][2]



图2 · 检索出的文本必须保留来源、时间、主体与“建议/决定”的区分

这个例子还揭示了三个不同的优化目标：**候选召回**希望不漏掉重要材料；**证据选择**希望进入上下文的材料准确、互补且可追溯；**任务使用**希望模型依据有效证据作出正确解释。三者相互影响，但指标不能相互代替。

二、第一步：把自然语言问题拆成“检索意图”

2.1 一句问题不一定就是一次向量搜索

用户说“那个项目现在能做了吗？”——人可以结合最近对话理解“那个项目”的所指；但记忆库通常同时存在多个项目、版本和日期。直接把原话送进Embedding模型，可能将模糊指代保留在向量里。更加稳妥的处理是先问：**要查哪个对象、哪件事、哪个时间点、哪一类证据？**

可以用一个帮助理解的查询框架（不是业界固定标准）：

字段	要回答的问题	本例取值
entity / scope	要查的对象是谁、属于哪个项目？	project=P
intent	想找事实、原因、时间还是当前状态？	当前是否允许新增收费
time_mode	问的是“那时”还是“现在”？	NOW / 当前有效状态
source_requirement	必须来自哪个级别的证据？	研究者明确决定及其原文

字段	要回答的问题	本例取值
negation	有没有“暂停、禁止、除非”这类限制?	保留“不允许，除非另行批准”
response_need	用户需要简答还是完整依据?	结论 + 依据 + 适用范围

从当前提问产生一份结构化检索意图，**不意味着模型已经证明了这些字段全部正确**。例如项目指代无法确定时，应在现有上下文和权威项目列表中查证；仍不能确定，就需要澄清，而不是擅自猜测。

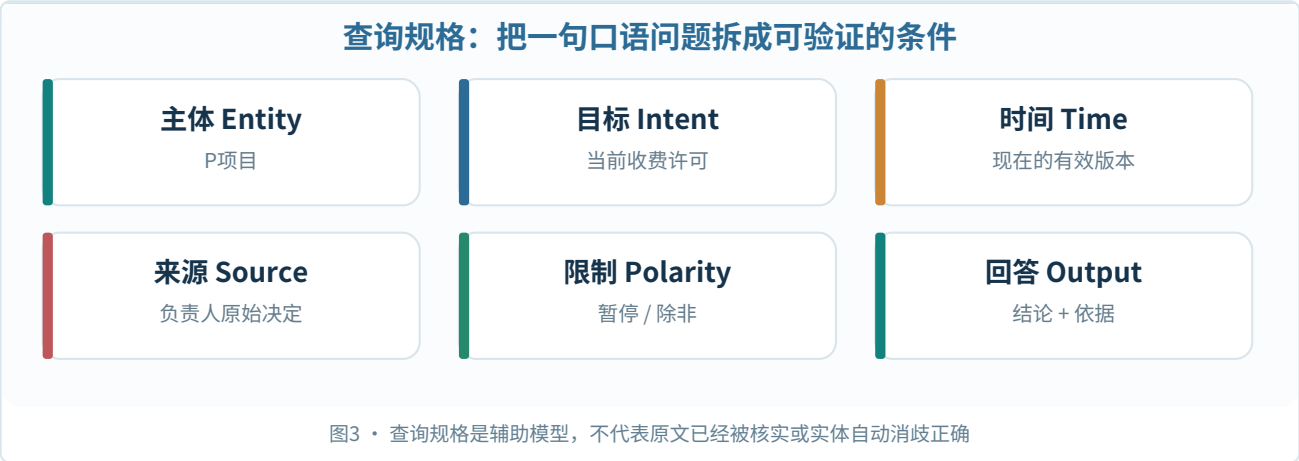


图3 · 查询规格是辅助模型，不代表原文已经被核实或实体自动消歧正确

2.2 拆分子查询：同一个问题可能需要多种证据

“P项目现在能恢复付费吗？”至少可以分为三个子问题：（A）P项目当前有效的费用限制是什么？（B）此前相关决定有哪些、是否有明确替代记录？（C）D23的Q项目例外能否影响P?

不同子问题应访问不同入口：A优先读取**结构化当前状态/有效版本**；B查原始决策记录与版本关联；C按项目作用域过滤。若问题变成“D17的504后来怎么解释”，检索目标应切换到**事件日志及后续归因证据**，而不是收费决策。

查询分解并非越多越好。太多子查询会增加召回噪声、重复材料和API开销。真正有用的是能补足答案所缺证据的分解，而不是机械地把一句话拆成十句。

三、第二步：查询改写与扩展——提高召回，不能改写事实

3.1 为什么原句可能搜不到正确记忆?

记忆里写“暂停新增收费调用”，用户却问“能恢复付费实验吗”。两句话包含不同字词，语义指向同一限制。词项检索可能因为词形差异漏掉材料；Embedding虽然能缓解同义问题，却可能把“允许”和“禁止”看得过于接近。两者各有盲区。[3][4]

可尝试的查询表达有：

- 关键词视图：`P项目 付费 API 暂停 禁止 新增`；
- 语义视图：`P项目最近一次关于新增收费调用的决定是什么?`；
- 结构化视图：`project_id=P AND topic=paid_api AND status=active`；
- 历史追溯视图：`P项目 关于付费权限 的所有决定 + SUPERSEDES关系`。

这些表达是一个真实问题的**不同检索视角**，不是四个独立的新事实。尤其不能把用户问句改写为“P项目已经获准恢复实验了吗”，因为“已经获准”偷偷添加了未经确认的前提。

3.2 两条守则：保留“限制词”，保留“实体与时间”

第一，保留否定与条件。 “暂停，直到另行批准”中，决定行动边界的恰恰是“暂停”和“直到”。为了增加语义匹配而删除这类词，等于在检索之前就篡改问题。

第二，保留作用域。 P项目、Q项目、同一个项目不同版本，以及“现在/当时/后来”不是可随意舍弃的装饰词。它们决定答案中哪条记忆有效。

LongMemEval研究特别强调时间推理与知识更新，并讨论时效相关的查询扩展；它支持我们应认真管理查询粒度与时间范围的方向，但不意味着论文提出了本讲完全相同的查询模板。[1]



图4 · 多种视图都属于同一个问题，不能擅加“已允许恢复”的前提

四、第三步：多路召回——先建立候选集合

4.1 精确检索、词项检索、语义检索各负责什么?

精确入口（ID/字段/数据库）： 对项目ID、当前有效状态、具体事件ID等有明确结构的需求，先用确定性匹配，能避免语义相近但作用域错误的材料。

词项检索（如BM25）： 它根据词项是否出现、出现频次及文档长度等信号估计检索相关性。对“HTTP 504”“预算20元”“编号Q-17”等原样术语尤其有用，但对自然语言同义改写可能漏召回。[3]

稠密语义检索（如双编码器DPR）： 将问题和文档分别编码为向量，寻找语义邻近的候选。它可以找到“停止收费”和“暂停付费”的近义表达，但向量近不等于事实一致，也不保留原文的完整授权结构。[4]

图或时间视图： 如果需要回答“哪条决策替代了旧决定”“这条摘要来源于谁”，使用关系/版本结构比只按文本相似度找单句更直接。



图5 · 不必每次启动所有索引；具体入口由证据需求和成本决定

4.2 高召回不是无限召回

通常可先用不同入口拿到各自的Top-K候选，形成并集，再通过相同`memory_id`和原始来源ID去重。**同一事件的三份摘要不是三条独立证据**。多索引返回相同记录，表示“多个搜索方法找到了它”，不表示事实被多次独立证实。

一个合理的初选策略可以是：结构化当前状态首先进入必备候选；关键词与语义检索补召历史细节；需要复杂关系再扩展图；最后回源核对。这里“优先”是查询任务的设计选择，而非适用于所有任务的绝对顺序。

五、第四步：融合和重排——先不要把排序分数当作可信度

5.1 排序到底在排什么？

BM25分数、余弦相似度与神经重排分数的尺度和含义不同。例如余弦相似度0.91不能解释为“此主张有91%的概率真实”；BM25=7.2也不能与向量0.82直接比较。它们主要是**检索信号**，不是人类授权、事件发生概率或证据证明力的统一数值。

在工程上可选择归一化后加权，或者先融合**名次**。RRF（Reciprocal Rank Fusion，倒数名次融合）正是常见的名次融合方法，源于Cormack等在SIGIR 2009的工作。[5]

5.2 RRF完整手算：两路排名如何合成一路？

教学假设词项检索和语义检索各返回如下排名：

候选	词项排名	语义排名
A	第1名	第4名
B	第2名	第2名
C	第4名	第1名

为便于手算，设平滑参数`k=10`（论文和实际实现可用其他值），公式是：

```
RRF(d) = 1/(k + rank_lex(d)) + 1/(k + rank_sem(d))
```

A = 1/11 + 1/14 ≈ 0.16234；B = 1/12 + 1/12 ≈ 0.16667；C = 1/14 + 1/11 ≈ 0.16234。于是B排在最前面。虽然A在某一路是第一，但B在两条路都稳定排第二，综合成绩略高。

关键提醒：RRF只解决“不同检索器名次如何综合”，不解决“哪条记录现在有效”。 如果B恰好是Q项目的付费许可，不能因它在融合榜上第一，就推断P项目已获许可。必须再做作用域与有效性检查。

RRF(k=10)：融合的是排名，不是真实性

候选	词项名次	语义名次	RRF分数
A	1	4	0.16234
B	2	2	**0.16667**
C	4	1	0.16234

B胜出，但若B是“Q项目许可”，仍不能作为P项目批准。

图6 · B=1/12+1/12≈0.16667；A/C=1/11+1/14≈0.16234

5.3 重排器和初步检索器有什么不同?

双编码器通常先分别编码查询与文档，可预计算大量文档向量，因此适于大规模候选召回；**交叉编码器重排**则把查询与候选文档放在一起判断相关性，通常更细致，但对大量候选逐一处理的成本较高。BERT passage re-ranking工作是代表性的早期方法。[6]

一个常见架构是“廉价高召回→昂贵小集合重排”。重排器**只能重新排列进入其候选集的材料**；如果关键的D12暂停决定在初步召回阶段完全漏掉，后续重排不会凭空补出该原始记录。ColBERT的Late Interaction是介于简单双编码器与完全交叉处理之间的另一设计空间，不要把所有神经排序模型都叫作同一种重排器。[7]

先召回、再重排：成本不同，能够解决的问题也不同



重排器无法对未进入候选集合的D12原始决定“凭空重排”。

图7 · 同一检索流水线中的三个阶段：召回、相似性理解、事实效力判断

六、第五步：从“相关候选”变为“可用于回答的证据”

6.1 必须经过的核验

在准备给模型阅读之前，至少按问题核查以下条件：

1. **主体与作用域**：证据属于P还是Q？适用于哪项实验？
2. **发生时间与有效时间**：它是什么时候提出、什么时候生效？是否被新版替代？
3. **来源和主张类型**：用户决定、AI建议、工具观测、外部文档或AI摘要？
4. **否定与限定条件**：暂停、除非、只对Q、最多20元这些限定词是否仍在？
5. **原文依据**：派生摘要能否回到原始消息或工具回执？
6. **证据是否足够**：检索材料是否能直接支持答案，还是需要进一步查找？

权限状态不能仅靠相关性软评分替代。 对需要真实外部付费操作的Agent，应由实际控制层检查权限；模型说“我认为已被允许”不等于授权已经存在。

6.2 当前状态与历史事实并不矛盾

M2可以被准确记成“D06时，AI曾提议让P做60次付费调用”；M3也可以被准确记成“D12起，研究者暂停P的新增收费调用”。两个历史陈述都可能是真的，问题只是它们**在行动决策中的效力不同**。为了说明为何没有开展60次调用，可以同时引用M2与M3；为了回答当前是否可以付费，M3在缺乏后续有效批准时具有决定作用。



图8 · 对实际外部行动，独立控制层仍需验证权限，不能只有LLM判断

七、第六步：有限上下文中到底放哪些记忆?

7.1 为什么不能“Top-K越多越好”

检索器返回Top-20，并不代表模型应该逐条读完。上下文窗口同时容纳系统指令、用户问题、工具定义、过程信息、检索证据和输出空间。超过预算的材料根本放不下；没有超过预算，也可能把真正决定性的证据埋在无关信息中。

Liu等在TACL 2024《Lost in the Middle》中，通过多文档问答和键值检索，报告了部分受测模型对上下文中间位置的重要信息利用不足的现象。因此，**能装入不等于能稳健使用**。该研究不证明所有模型永远都会出现同样模式，但足以说明检索后的信息选择与摆放值得单独研究。[2]

7.2 真实地计算一次上下文预算

设教学模型的总预算为8,192 Token，安排如下（这些是教学假设，并非任何真实模型的固定分配）：

占用类别	Token
系统规范和角色说明	1,100
当前用户问题和必要背景	330
工具规格/可用状态	1,050
中间任务状态与短期工作区	830
预留模型回答输出	1,600
防止截断的安全余量	500
可用于检索证据	**2,782**

手算：`8,192 − (1,100 + 330 + 1,050 + 830 + 1,600 + 500) = 2,782`。这一数字是上限，不是必须用满的目标。若1,200 Token足以构建正确的依据，强行填满2,782只可能带来额外噪声和成本。



图9 · 全部数值均为教学假设，实际需使用目标模型的Tokenizer与上下文约束

7.3 证据选择可以像“带约束的背包问题”

把每条候选记忆看成一件占用Token的物品，价值可能来自任务相关性、原始证据质量、时间有效性、信息新颖性及它与其他证据的互补程度。但与普通背包问题不同，**若某些材料属于必备证据，它们不能被低价值但高相似度的材料替换**。

本例提供一组教学候选：

候选	内容	Token	证据角色
A	D12 P当前暂停决定	330	必备：当前有效状态
B	D23 Q项目例外	460	可选：澄清作用域误传
C	D02 P离线范围原话	510	可选：解释历史范围
D	D06 AI 60次调用提议	620	本问通常非必需
E	D17 504工具日志	390	本问通常无关
F	D12的重复AI摘要	340	重复且可回源

如果希望在1,500 Token内部说明当前结论和为什么Q的许可不能推广到P，可选择A+B+C，合计330+460+510=1,300 Token，还余200 Token用于证据头信息或短引文。不要认为D在向量榜上很靠前就必须放进去，也不应为了填满剩余预算随便补E或F。真实系统还需计算元数据、格式标记和实际Tokenizer开销。

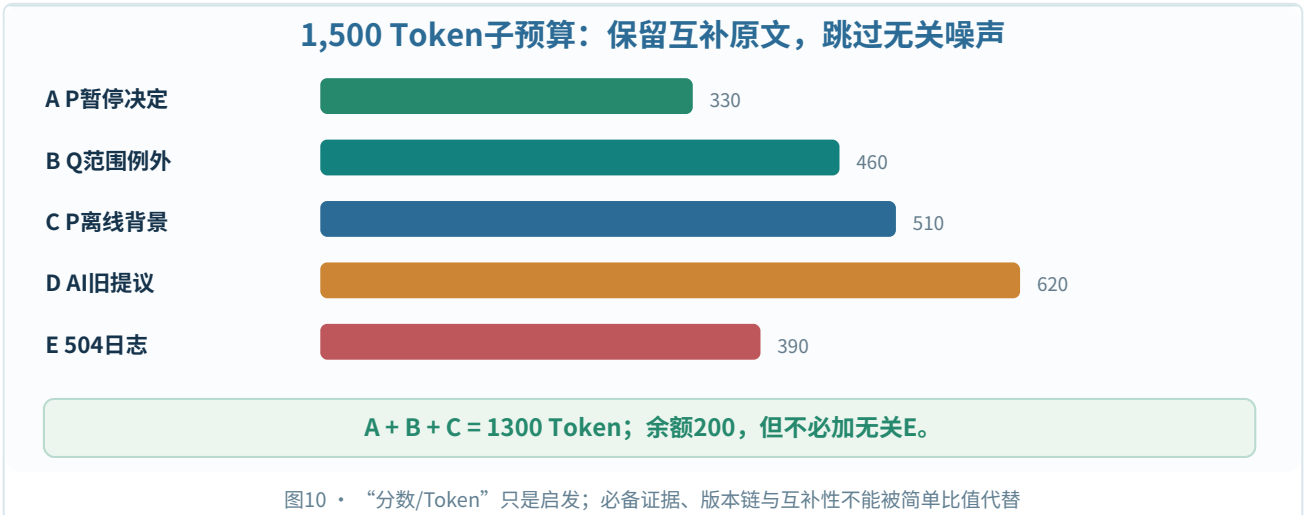


图10 · “分数/Token”只是启发；必备证据、版本链与互补性不能被简单比值代替

7.4 容量选择还需要考虑“证据之间的依赖”

同一份原始决定和它的AI摘要可能重复；另一方面，一条简短摘要如果没有原文指针，就无法独立支撑关键结论。故而价值不能简单设成每条记忆固定分数，然后按分数/Token排序。

以M3暂停决定和M6摘要为例，M6的价值依赖M3的可追溯性。若把M6和M3看成两条独立“高分证据”，就会错误增加支持度。复杂任务中还可能需要**成对证据**：例如一个旧决定、一个撤销该决定的新决议，两者缺一就可能误判状态演化。

八、第七步：把证据排布成模型易读、可核验的上下文

8.1 不只是拼接文本：应包括什么？

一个对长期任务更稳妥的教学示例是：先给出任务和当前状态结论，再列原始决策证据，最后放相关但非决定性的历史材料。每条证据带短编号与必要元数据，例如：

`[E1] 项目=P；来源=研究者原始消息；时间=D12；状态=当前有效；主张=暂停新增收费，直到另行批准。`

`[E2] 项目=Q；来源=研究者原始消息；时间=D23；状态=仅Q有效；主张=仅1次、最多20元。`

此后要求模型仅依据明确证据说明：“截至已有记录，P仍暂停；Q的授权不能扩展到P。没有看到P的后续批准，不能声称获准恢复。”这只是**证据辅助的回答组织方式**。对付费工具调用仍需独立的控制器权限检查。

8.2 位置、顺序和去重

把最关键且可靠的证据靠前列出，经常比把20段历史随机拼接更容易理解。但不是说“把所有重要证据放开头就能保证模型一定正确”；具体模型、任务和长度均会改变位置效应。[2]

同时，需要保留两个看似矛盾但不同时间有效的决议，而不是简单删除旧版：回答“现在状态”主要依赖最新版，回答“决策为何改变”还需要保留旧版和变化关系。



图11 · 证据号、项目作用域、来源和否定条件帮助复核，不等于保证模型不会误读

8.3 检索内容压缩是否值得？

RECOMP等研究探索对检索材料进行选择性压缩，减少上下文开销。[8] 对智能体记忆而言，这类技术有潜在价值，但必须防止“只剩结论，不剩否定词、来源和作用域”。**压缩比高不能替代事实忠实度、原文可追溯性和后续任务质量。**

九、第八步：证据不够时，应该如何回答？

智能体经常遇到三种缺口：①没有检索到对应记录；②找到了相关材料但来源弱、时间过时；③找到了相互冲突且无法消解的有效主张。

“没有检索到”并不能证明“世界上不存在”。例如没有检索到P的批准，严谨的表述是“在目前能够访问和核验的记录中，没有找到P获准恢复的有效决定”；若用户要求执行收费动作，应以**尚缺有效授权**处理，而不是擅自调用API。

有时应扩大检索范围；有时应停止并声明证据不足。是否继续检索需要同时看遗漏代价、资源上限与预期新增信息，而不是无界重复调用模型。[1]

十、把整条链放到跨30天科研助手里重演

现在可以完整推演D30的问题：“P项目现在能恢复收费实验吗？给出依据。”

1. **理解问题：** 当前许可、主体P，明确要证据。
2. **构造查询：** P + 收费 + 最新状态 + 研究者决定，保留否定与时间条件。
3. **精确检索：** 当前授权状态与最新版本，得到D12暂停M3。
4. **多路召回：** 找到D06 AI建议、D23 Q许可、D02 P离线目标和若干摘要。
5. **去重与融合：** 同源的D12摘要不计作独立事实；融合分数仅决定候选审查顺序。
6. **校验：** D12适用于P；D23仅适用于Q；D06是AI建议不是用户批准。
7. **上下文选择：** 至少放M3及其来源，必要时放Q的范围证据和P旧目标，省略无关504。
8. **回答：** 当前可用记录显示P仍暂停收费，Q的例外不适用于P；缺乏P后续授权，不能恢复实际收费执行。
9. **反馈：** 新对话可形成事件记录，但不能凭模型输出自动制造一个“已批准”的新记忆。

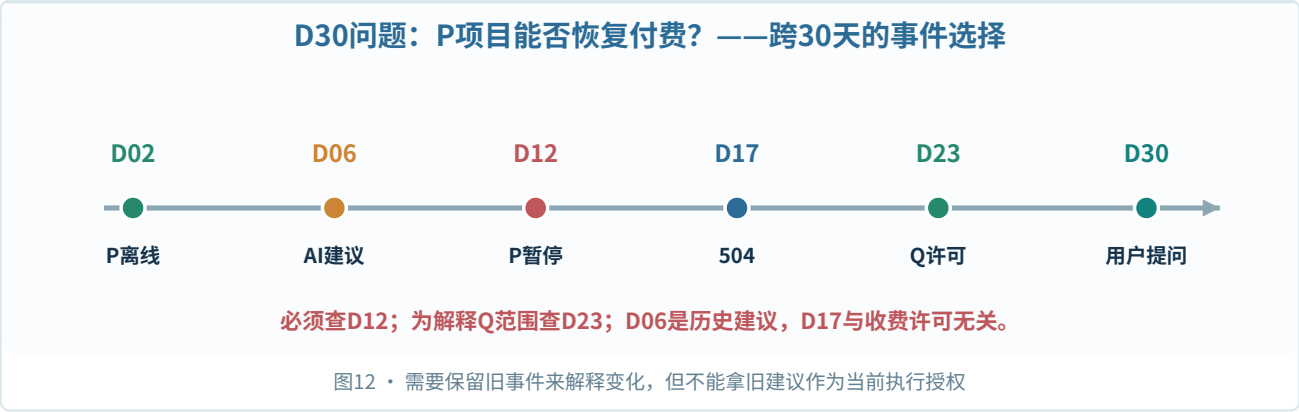


图12 · 需要保留旧事件来解释变化，但不能拿旧建议作为当前执行授权

这9步中最重要的区分是：**检索器负责找到可能相关的候选，证据核验负责判定其效力，LLM负责理解与表达，真实工具控制器负责执行授权。** 把所有职责都放在向量相似度一个分数里，必然产生难以诊断的错误。

十一、理论上怎样评价查询与上下文选择的好坏？

11.1 候选检索阶段

Recall@K（召回率）：需要的证据中，有多少在Top-K候选里？假设一个问题真正需要D12和D02两条证据，检索Top-4中只有D12，则Recall@4=1/2=50%。

Precision@K（精确率）：Top-K里有多少被标注为相关？如果Top-4中只有D12相关，则Precision@4=1/4=25%。标注时必须事先界定“相关”是主题相关、可作支持证据，还是当前有效决议，否则分母没有清楚意义。

MRR（平均倒数排名）：仅看每个问题第一个相关结果的位置。若3个问题的首个相关结果分别是第1名、第2名和在截断范围内未出现，MRR=(1 + 1/2 + 0)/3=0.5。MRR适合某些“尽早找到一个答案”的检索任务，但无法直接衡量需要多条证据组合的时间链推理。

11.2 上下文选择阶段

证据完整率：在真正进入模型的上下文中，所需关键证据是否齐全？一套检索器Recall@20很高，若后续只留下Top-3而恰好删掉D12，最终仍然可能答错。

证据忠实度：候选经重排/压缩后，否定、时间、主体和来源有无被改写？

版本有效性：最终进入上下文的主张是否对查询时间和作用域有效？

Token效率：正确任务所需的真实输入开销与延迟如何？不能单纯为了省Token删掉必备证据。

行动正确性：输出是否准确区分建议和批准，执行时是否通过控制器验证？



图13 · 分阶段报告效果，才能判断收益来自索引、排序、上下文还是模型阅读

11.3 论文中为什么需要分阶段的比较?

LongMemEval将长期记忆设计划分为索引、检索和阅读三个阶段，并据此分析改进方向。[1] 这说明仅报告“某个系统最终答对多少题”难以定位机制差别：改进可能来自更细分的事件索引，也可能来自更好的时间查询、更多上下文或更强的阅读模型。

如果未来做科研，应比较**相同原始记忆、相同问题、相同模型与Token预算**下，简单策略与复杂策略分别带来的召回、证据保留、时序正确性、延迟和端到端结果差别。这里我们只学习原理，不要求实际做实验。

十二、12个常见误区与正确理解

1. **误区：把用户的问题原样做一次Embedding就足够。** 当问题有指代、省略、时间和版本时，必须识别这些约束；否则可能跨项目找错材料。
2. **误区：查询扩展越多，召回一定越好。** 同义扩展可能带入其他项目或把否定条件删掉，应衡量增益与噪声。
3. **误区：向量相似度高代表记忆真实。** 相似度是表示空间信号，可能把“允许”与“禁止”判得很近。
4. **误区：BM25=8一定比向量0.9更可信。** 两种分数缺乏直接可比的统一概率语义。
5. **误区：RRF融合后第1名就是最可靠证据。** RRF聚合的是检索排名，不能替代来源、时间和授权检查。
6. **误区：昂贵重排器能补救任何召回失败。** 没进候选集的材料，普通重排无法补回。

7. **误区：同一条决定被三个索引找出是三份独立证据。** 应按照源事件ID去重，保留依赖关系。
8. **误区：最新的记录一定最有效。** 最新记录可能属于Q，查询却针对P；时间和作用域必须联合判断。
9. **误区：检索结果相关就可以直接送入LLM。** 还需核验来源、状态、版本及敏感信息边界。
10. **误区：上下文越满，回答越有根据。** 冗余和干扰材料可能拉低可用性；容量不等于理解质量。
11. **误区：引用了原文就一定回答正确。** 还需证明引用支持所作结论，不能断章取义或忽略限制。
12. **误区：检索不到批准就可以假定批准存在或默认执行。** 对需要授权的外部行动，缺少可核验证据意味着不能擅自行动。

十三、理论思考题（建议先独立作答）

题1（基本概念）： “什么时候检索”和“检索之后怎样构造查询”分别解决什么问题?

题2（查询拆解）： 用户问“上次那个项目的预算是不是改了”，你会提取哪些字段？如果项目身份不明确怎么办?

题3（否定与作用域）： 为什么“暂停P直到另行批准”不能改写为“P可恢复实验”？D23对Q的许可为什么不能作为P的有效决定?

题4（检索分工）： 在寻找具体事件ID、近义表达、版本替代关系时，你分别优先考虑哪类检索入口?

题5（RRF手算）： k=10，A的两路排名为1和4，B为2和2，C为4和1，分别求得分与名次。

题6（重排）： 一个包含10条候选的重排器没有收到D12决定，它还能单凭排序操作把D12排到第一吗？为什么?

题7（去重）： 三份AI摘要都依赖同一条研究者消息，它们是三条独立证据吗？应如何处理?

题8（预算手算）： 总窗口8192，固定/预留占用1100、330、1050、830、1600、500。证据预算是多少?

题9（证据选择）： A=330、B=460、C=510 Token。它们合计多少？当证据限额1500时，还剩多少？D17的504是否必须填进剩余空间?

题10（证据冲突）： D06的AI建议60次调用，D12研究者要求暂停；第30天问P是否能收费，如何组织证据和结论?

题11（指标计算）： 一题需要2条证据，Top-4仅找到1条；另有3题首个正确结果名次为1、2和超出检索范围。求Recall@4、Precision@4（假设Top-4仅1条相关）及MRR。

题12（独立重建）： 请从头画出“用户问题→查询→多路召回→融合→重排→回源/版本核验→上下文选择→LLM回答→控制器行动”的完整链路，并指出至少四个不同故障位置。

十四、思考题答案与推导

答1： 第21讲的触发决定“有没有必要动用外部历史”，第22讲从这个判断之后开始，决定“为当前问题构造什么检索目标、用哪个入口、如何选证据”。即使触发正确，查询也可能构造错误。

答2： 提取项目ID、预算类型、查询时点、原有数额、修改来源、当前有效决定和需要证明的比较。身份模糊先查当前会话和项目列表；仍无法确定就澄清，不凭相似语义猜测。

答3： 前者有明确禁止与条件，后者擅自反转为允许；Q与P是不同作用域。即使Q的许可更新更晚，也不能自动覆盖P的停止决定。

答4： 精确事件ID优先结构化索引或主键；近义表达可用语义/关键词混合检索；版本替代关系优先带时间和关系字段的历史记录或图查询。最后都要回源核验。

答5： A=1/11+1/14≈0.16234；B=1/12+1/12≈0.16667；C=1/14+1/11≈0.16234。因此B第一，A和C并列。结果只说明名次融合，不说明B最可信。

答6： 普通重排只对已给候选重新打分或调整顺序，不会凭空产生原来没有进入候选集的原始事件。应通过检索召回补救、扩大范围或查结构化当前状态。

答7： 不是。原始证据来源数量仍是一。可以保留不同摘要作为派生表示，但应将其共同连接到同一源ID，避免双重计数与循环自证。

答8： 固定/预留合计=1,100+330+1,050+830+1,600+500=5,410；证据预算=8,192−5,410=**2,782 Token**。数值仅为课堂构造，实际需要Tokenizer核准。

答9： A+B+C=330+460+510=**1,300 Token**；1500−1300=**200 Token**。D17与P收费许可问题通常无关，即便剩下空间，也不应为了凑数加入噪声。

答10： 保存D06作为“曾提出过的建议”，保存D12作为“有效暂停决定”。对于当前许可，应以D12及其后续有效更新为依据；若未发现P的后续批准，报告仍暂停，不能把建议变成批准。

答11： Recall@4=1/2=**50%**；Precision@4=1/4=**25%**；MRR=(1+0.5+0)/3=**0.5**。它们均不直接保证最终回答正确或外部行动合规。

答12： 推荐顺序：用户问题→识别对象/时间/意图→生成子查询→结构化、词项、语义、关系多路召回→同源去重→融合/重排→回源证据核验（含有效时间与作用域）→Token预算与依赖约束选择→为模型提供结构化证据→生成有条件回答→控制层核实际授权→记录新事件。至少可在查询指代、初步漏召回、版本核验失败、上下文删除关键事实、模型读错否定条件、控制器越权等处发生不同故障。

十五、本讲完整心智模型与下一讲衔接

当用户说“请根据过去的情况回答”时，你可以在大脑中推演五个连续问题：**（1）他到底在问哪个对象与哪个时间点？（2）需要哪些不同类型的证据？（3）哪几条候选可信且仍有效？（4）有限上下文应该携带哪些互补的原文依据？（5）模型的答案有没有正确使用它们？**

这样，你已经不再把“向量搜索”“RAG”和“记忆利用”当作同一个静态概念，而能分析从查询产生到答案落地的每一次状态变化。下一讲将进一步深入：**相关性之外，怎样处理时间、重要性、多跳关系以及更复杂的检索路径？**

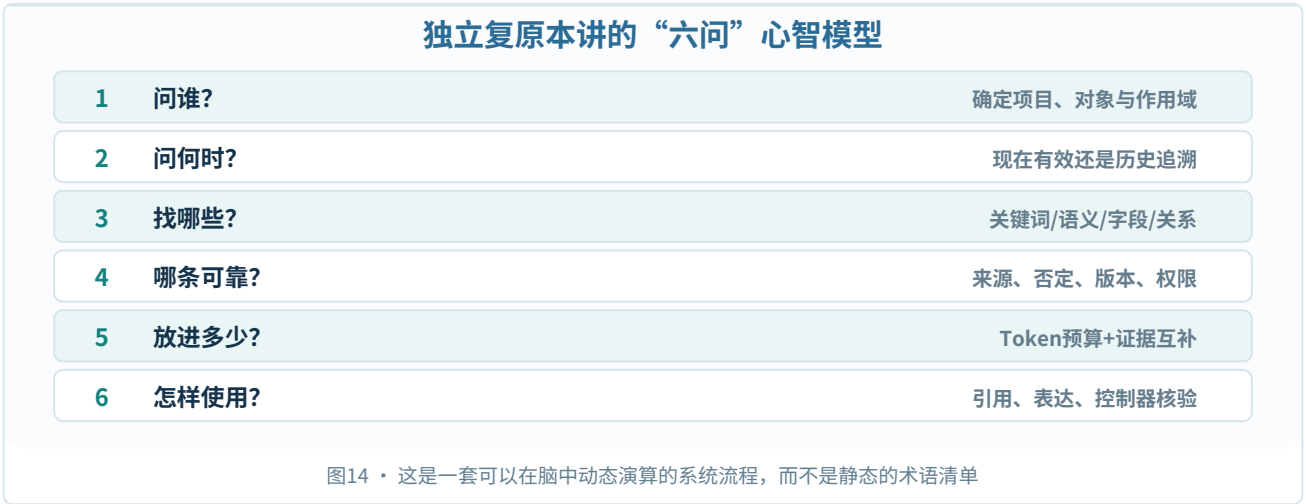


图14 · 这是一套可以在脑中动态演算的系统流程，而不是静态的术语清单

参考文献与原始研究入口

以下均为真实研究或正式技术资料；**本讲的算法示例、权重、数字与流程图为教学设计**，不应误认为这些论文发布了相同的数值或统一工程规范。

[1] Wu, D., et al. (2025). **LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory**. ICLR 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[2] Liu, N. F., et al. (2024). **Lost in the Middle: How Language Models Use Long Contexts**. TACL 12:157–173. https://aclanthology.org/2024.tacl-1.9/

[3] Robertson, S., & Zaragoza, H. (2009). **The Probabilistic Relevance Framework: BM25 and Beyond**. Foundations and Trends in IR. DOI: https://doi.org/10.1561/1500000019

[4] Karpukhin, V., et al. (2020). **Dense Passage Retrieval for Open-Domain Question Answering**. EMNLP 2020. https://aclanthology.org/2020.emnlp-main.550/

[5] Cormack, G. V., Clarke, C. L. A., & Buettcher, S. (2009). **Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods**. SIGIR 2009. https://doi.org/10.1145/1571941.1572114

[6] Nogueira, R., & Cho, K. (2019). **Passage Re-ranking with BERT**. arXiv:1901.04085. https://arxiv.org/abs/1901.04085

[7] Khattab, O., & Zaharia, M. (2020). **ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT**. SIGIR 2020. https://arxiv.org/abs/2004.12832

[8] Xu, F., Shi, W., & Choi, E. (2024). **RECOMP: Improving Retrieval-Augmented LMs with Context Compression and Selective Augmentation**. ICLR 2024. https://arxiv.org/abs/2310.04408