第五部分 · 记忆的检索与利用机制

多跳记忆检索 时间约束与 证据链排序

从分散的历史碎片，还原可追溯的完整判断

Multi-hop Retrieval · Temporal Reasoning · Evidence Chains

> 多跳检索：找到所有必须连接的事实。
>
> 时间检索：厘清何时有效与何时得知。
>
> 证据核验：避免把相似的旧建议当作当前决定。

零基础理论课 · 16张机制原理图 · 12道思考题与详细答案

v1.0 | 2026-10-18 | 纯理论，无实验

第23讲｜多跳记忆检索、时间约束与相关性之外的排序

《智能体记忆系统：从零基础到科研理解》 · 第23/32讲 · 第五部分：记忆的检索与利用机制

副标题：从分散的历史片段中，还原一条有时间、来源和适用范围的证据链

本讲的核心问题： 第22讲学会了构造查询、排序候选和组装上下文。但是：如果回答一个问题需要三条历史记录，而第一条只告诉我们下一条在哪里？如果某条政策刚被局部修改，另一条例外已经用完？如果工具故障发生在第9天、诊断证据第18天才出现？这时“检索最相似的句子”为什么不足以得出正确结论？

阅读约定： 本讲为零基础理论课程，**不安排实验、编程、环境配置或收费调用**。P、Q项目、D02—D30时间线、分数、Token与延迟均为教学构造，不代表任何真实研究项目或授权。论文中的真实研究思路与本讲提出的教学归纳模型分别标注。文中出现“证据支持”指可追溯到指定原始材料，仍需审查适用范围及推断逻辑。

本讲学习目标与知识地图

学完后，你应该能够：①判断单跳、跨会话多跳、时间追溯、有效状态查询之间的不同；②将复杂问题拆成可验证的证据缺口；③手工推演一次逐步检索和一条图路径；④判断一个关系是否是来源、替代、时间包含还是因果；⑤理解双时间与时间区间的基本计算；⑥设计“硬约束优先、软分数其次”的证据排序逻辑；⑦解释什么时候应当停止扩展并答“不知道”；⑧区分检索召回、整条证据链完整性及最终行动正确性。



图1 · 每一步回答不同的问题：关系、时点、证据效力与最终上下文

一、从一个需要五段证据的科研助手问题开始

1.1 同一个问题，隐藏着两个不同的证据链

假设科研智能体持续辅助研究者30天。第30天研究者提问：

> **“P项目还能再收费调用两次吗？另外，第9天的HTTP 504，后来确认是什么原因？”**

历史如下（全部为教学虚构）：

记录	时间	原始事件或结论	性质、范围与关键限制
E1	D02	P项目先按零费用离线分析推进	研究者明确目标
E2	D06	AI建议P项目进行60次付费验证	**AI建议，未获批准**

记录	时间	原始事件或结论	性质、范围与关键限制
E3	D09	某次工具请求返回HTTP 504	工具日志，尚不等于根因判断
E4	D10	AI推测“可能是模型参数导致”	**推断，未经核实**
E5	D12	P项目暂停一切新增收费调用	研究者决定，仍有效
E6	D18	排查D09对应网络追踪，指向上游代理超时，未获得模型决策输出	特定故障的诊断证据
E7	D20	针对D09形成“优先排查代理与回传”的复盘	来源于E3+E6的总结，不是新独立证据
E8	D23	Q项目可以单独做一次≤20元的验证	**仅适用于Q**
E9	D26	P项目仅允许一次、费用≤5元的例外验证	研究者限次许可，不解除一般暂停
E10	D29	P项目该次≤5元验证已执行并有日志回执	E9许可已消耗；需要核对回执
E11	D30	研究者询问P能否再做两次及D09故障原因	新问题，不自动授予行动权限

要回答第一个子问题，关键不是找到“付费”一词最相似的E2，而是组合**E5（总体暂停）→E9（一次例外）→E10（例外已用完）**。要回答第二个子问题，至少要组合**E3（真实故障）→E6（后来查到的追踪）**，必要时引用E7说明团队的后续复盘，而不能依赖E4的猜测。[1][2]

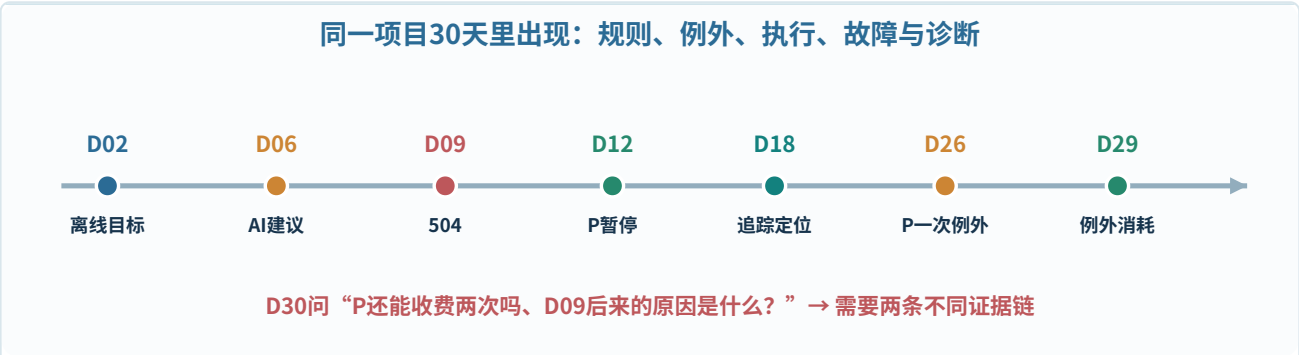


图2 · 时间接近不等于同一来源，也不等于同一授权范围

1.2 为什么这是“多跳检索”？

一次检索如果只返回E9，系统知道“曾允许一次”，但不知道是否已经用过；若只返回E10，它知道“一次执行完”，却不知道这次回执对应哪一个授权；若只返回E5，它知道“总体暂停”，却不知道后来存在局部例外。**答案依赖记录之间的关系，而不是任何单条记录本身。**

“多跳”（multi-hop）不是固定要查三次数据库。它指答案需要跨越多个事实、实体、事件或关系才能得到。系统可以通过一个图索引一次返回整条链，也可以逐步提出后续检索；关键是**有多少不可缺的关系需要成立**，而非API请求个数。[3][4]

1.3 单跳、并列证据、多跳、时间追溯的区别

问题类型	例题	关键动作
单跳（single-hop）	D12提出了什么决定?	找到E5原文
并列证据（aggregation）	D09与D18分别记载什么?	找回两段，分别陈述
关联多跳（multi-hop）	D29执行是否属于D26授权?	对比项目、范围、次数、执行ID
时间有效性（temporal validity）	D30还能收费两次吗?	结合E5、E9、E10的状态链
回溯知识（retrospective knowledge）	D10时系统知道D09根因吗?	区分D09事件和D18才获知的诊断
因果解释（causal claim）	D09是否由代理超时造成?	需要对应日志与排除其他原因，而非图中有路径

注意：现实问题经常同时属于两类甚至三类。“多跳”与“时间查询”并非互斥标签。

二、多跳的底层原理：答案依赖一条可验证的关系路径

2.1 先从“节点与边”理解，而不是先背算法

第19讲已经认识图：节点代表项目、事件、权限决定或工具回执；边表示带语义的关系。对本例可构造：

- `E9 --applies_to--> P`：E9属于P项目；
- `E9 --exception_to--> E5`：E9是E5一般暂停下的有限例外；
- `E10 --consumes--> E9`：D29成功执行消耗D26的一次许可；
- `E6 --diagnoses--> E3`：D18诊断关联D09工具故障；
- `E7 --derived_from--> E3,E6`：复盘从原始故障与诊断派生。

这些边是教学中经过明确归类的关系。实际系统生成这样的边可能会错，因此检索到边之后还要检查其`source_event_id`、是否有原始证据支持以及时间与项目范围。

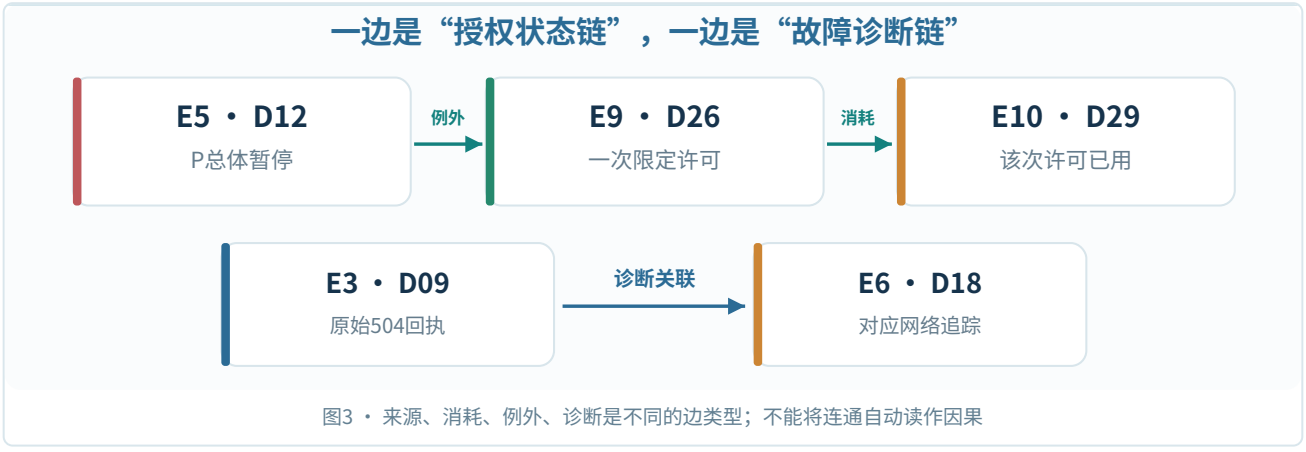


图3 · 来源、消耗、例外、诊断是不同的边类型；不能将连通自动读作因果

2.2 关系路径能回答什么、不能回答什么?

路径 `E10 → consumes → E9 → exception_to → E5` 可以帮助回答：“D26例外的次数是否用尽？”但它**不能仅凭连通关系就推出**“所有P项目未来活动永远禁止”。E5可能有以后新的替代记录；E10可能只是一次未成功的尝试；E9的许可可能有额外生效/失效条件。路径必须匹配用户真正提问的对象和时间。

另一个路径 `E3 ← diagnoses ← E6` 也只说明“E6声称诊断E3”。若E6没有对应请求ID、追踪或验证材料，路径本身不是因果证明。**“图上连着”与“证据已经支持”是两个命题。**

2.3 多跳检索的两种典型执行路线

路线A：图式多跳（graph-guided）。从P项目或D26例外出发，沿 `exception_to / consumes / supersedes` 等经过定义的边扩展候选，找到E5、E9、E10，再回读原文。图遍历可由广度优先搜索（BFS）、带约束路径查询或类似图排名方法辅助，但图边要有准确语义。[4][5]

路线B：迭代文本检索（iterative retrieval）。第一轮查询“P当前收费状态”找到E5，接着发现“是否有另行批准”的证据缺口，于是下一轮查E9，再发现“批准是否消耗”，最后查E10。IRCoT提出的是在多步问答中交替检索与推理的思路；我们这里把每个中间步骤约束为可见的子查询和证据检查，不把模型自由生成的解释当作事实。[3]

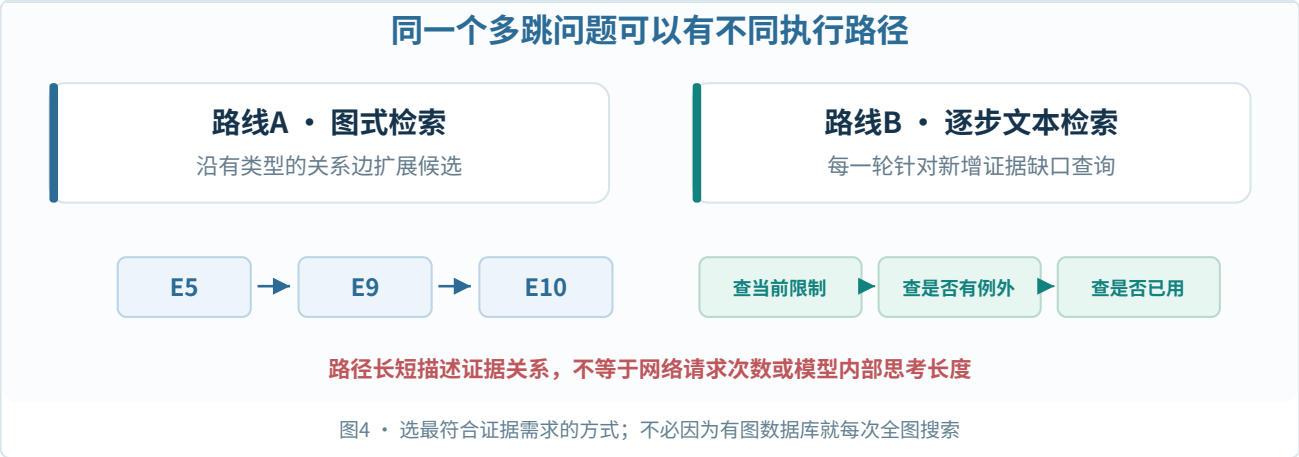


图4 · 选最符合证据需求的方式；不必因为有图数据库就每次全图搜索

2.4 为什么越多跳，遗漏和错误传播风险越大?

以纯教学假设为例：假设某条答案需要三个互不替代的证据环节，每一环都能以80%的概率成功找回，并且各环**相互独立**，那么三环全部到齐的概率是：

$$P(\text{全部到齐}) = 0.8^3 = 0.512$$

即51.2%。这解释了为什么单项召回不错，不代表多跳链条稳定。真实系统中各环错误往往相关，例如同一查询表述、同一索引、同一错误摘要，独立性通常不成立；因此不能把这个数字当作任何产品的预测准确率。

提高多跳性能有两个方向：一是提升每跳的关键证据召回；二是让系统把缺口作为明确的再检索目标，而不是在缺失第二跳时直接脑补后续结果。

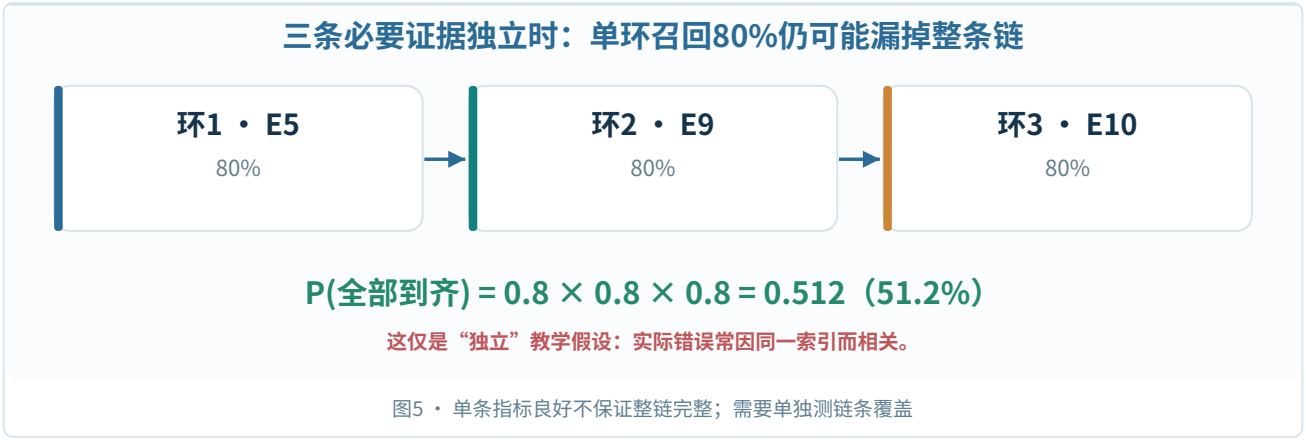


图5 · 单条指标良好不保证整链完整；需要单独测链条覆盖

三、逐步检索：先形成“证据缺口”，再产生下一跳

3.1 从复杂问题拆成“待证明的小命题”

面对D30问题，先拆成：

A. P项目是否存在当前一般性收费限制?
B. 是否存在P项目范围内、覆盖当前所问操作的有效例外?
C. 例外是否已经使用/失效?
D. D09那次请求实际发生了什么?
E. D18获得了哪些新的技术证据，是否能支持对D09的归因?

每个小命题对应需要的证据类型和原始记录。比起“再搜一点相关信息”，这种方法清楚说明**下一跳为什么必要**。

3.2 迭代不是无限延伸

第一次检索得到E5：“暂停，除非另行批准。”该句自带下一跳触发条件：**有没有另行批准?** 查到E9后又产生第三个问题：**一次许可是否已经消耗?** 找到E10后，该链闭合。

反过来，如果找不到E10，不能默认为“没用完”，也不能默认为“已经用完”。系统应标记“许可消费状态未核实”，并在必要时读取权威的执行日志或授权台账；查不到就明确证据不足。**没有检索到事实，不等于该事实不存在。**

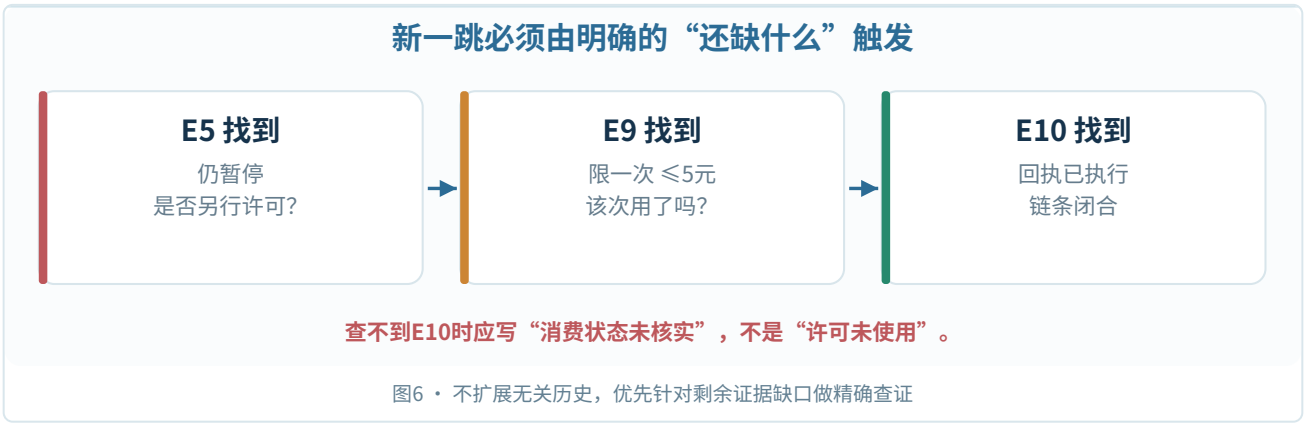


图6 · 不扩展无关历史，优先针对剩余证据缺口做精确查证

3.3 先做廉价的、能确定答案的查询

对于有结构化授权台账的智能体，回答“还能否收费调用”应该**先查当前有效的权威状态**，而不一定需要重复从十条历史自然语言中推演。多跳证据链仍有价值：它可解释状态为何如此、处理质疑、发现数据不一致。但如果一个简单状态查询已经足够，不应为了展示“智能”而额外启动昂贵图遍历。

这里的基本原则是：**选择满足证据需求的最简单路径**。复杂度应由任务所需信息结构决定，而不是由系统拥有多少种检索引擎决定。[1][6]

四、时间检索：不是给相关记忆加一个“越近越高”的分数

4.1 “最近”与“有效”是不同含义

用户现在问P的许可，D29执行日志很新；但它不是授权决定。D06旧的AI建议虽然过时，却可用来解释历史讨论。D12暂停仍可能有效，而D26出现了局部例外。按照“越近越重要”简单排序，将很容易选错证据。[1][2]

时间检索至少涉及三类判断：

1. **事件在何时发生？** D09工具返回504。
2. **事实/决定在何段时间有效？** D12暂停可能长期有效，D26一次性例外在使用前有效。
3. **系统在何时得知某个事实？** D18才拿到D09的代理追踪。

第14讲已介绍的双时间模型在这里开始真正发挥作用：既要回答“当时什么有效”，也要回答“当时系统知道什么”。Zep/Graphiti之类的时间图记忆研究说明，为动态事实维护时间信息是长期智能体的实质性需求，但它们并不能自动保证所有时间抽取都是正确的。[2][7]



图7 · 当前有效、当时真实、当时已知都不一样

4.2 用半开区间表示“在某时有效”

一个常见的教学表达是半开区间 `[valid_from, valid_to)`，包含起点，不包含终点。查询在时间 `t` 有效，要求：

$$valid_from \leqslant t < valid_to$$

如果 `valid_to` 尚未确定，则需有明确的“未知终点”表示；不可把未知当作“永久真实”。

以D26的一次许可为例：假设它在D26生效，到D29的实际执行回执确认消耗后不再可使用，则**课堂状态视图**可写成 `[D26,D29)`。注意这不意味着现实授权记录一定以D29作为精确终止时间；实际系统应依据执行事件的时间戳、原始授权条款、失败是否计次以及并发请求等合同规则确定。

D12的一般暂停与D26的一次例外是**不同作用域的约束**，不能把D26误解释为“永久撤销D12暂停”。

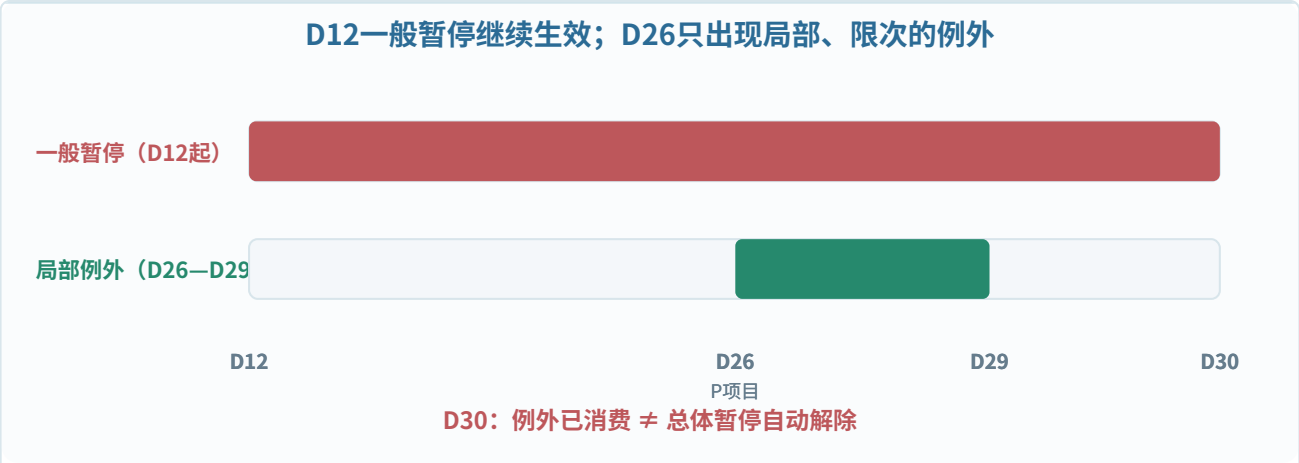


图8 · 例外有项目、限次、金额等独立作用域，不能用“时间更近”替代逻辑

4.3 用两条时间轴回答两个不同的问题

假设“D09的真实技术原因”直到D18才通过追踪日志得到可靠定位：

- **回看D09事件的实际情况**：可以使用D18新增证据，说明那次工具请求的代理超时解释。
- **询问D10当时系统知道什么**：不能拿D18才取得的证据假装D10已经掌握。D10只有504回执及E4的未经核实推测。

这是“事实发生时间（valid/event）”与“系统获知/记录时间（transaction/knowledge）”不同造成的。系统需要同时明确查询的时间语义：**现在回溯过去，还是还原过去当时的知识状态?**



图9 · valid/event time 与 knowledge/transaction time 的教学对照

4.4 时间逻辑还存在三种常见陷阱

时间顺序不等于因果。 D18查到网关问题，不意味着D09之后出现的任何失败均由网关造成。

“之后更新”不等于“之前记录完全错误”。 D12一般暂停与D26受限例外可以同时成立，只是作用域不同。

“晚于”不等于“最新有效”。 D29可能是一次执行结果，D26才是例外许可的原始来源；跨类型比较“新旧”不能代替状态判断。

五、相关性之外的排序：先过资格检查，再比较有用程度

5.1 相似度为什么不是证据可信度?

Embedding分数回答的通常是“查询与这段文本在模型表示空间内多接近”。它不能直接告诉我们：说话者有没有权限、决定现在是否有效、许可是否已消耗，或者一段总结是否具有独立证据价值。[1][6]

同理，RRF排名、BM25分数、图路径距离也都不等于“这个说法是真实且适用的概率”。用0.95的相似度理解为“95%允许付费”，属于概念性错误。

5.2 两阶段的排序原则：硬过滤→软排序

可以把课堂参考策略分成两阶段（这不是所有商业系统必须使用的统一算法）：

阶段一，硬资格条件： 项目ID和作用域是否匹配；查询时间是否有效；所需证据是否来自合适主体；关键否定/条件是否保留；是否能够追溯原始记录；对真实行动是否经过权威状态与权限检查。

阶段二，软优先级： 在资格相符的候选之间，再按查询相关性、链条缺口补全能力、证据原始性、信息互补性、延迟与Token成本排序。阶段二不能“加分覆盖”阶段一不合格的证据。



图10 · 相关性0.96也可能因来源无权限而不适合作为当前许可依据

5.3 手算一个“最像却没资格”的例子

用户问：“P项目能再收费调用两次吗？”候选如下，相关度均为课堂示意：

候选	内容简写	语义相关度	是否足以充当当前许可依据?
E2（D06）	AI建议60次付费	0.96	**否**：只有建议，没有批准
E5（D12）	P一般性暂停	0.74	**是，关于一般约束**
E9（D26）	P一次性、≤5元例外	0.81	**是，但需查消费状态**
E10（D29）	例外已执行的回执	0.61	**是，关于剩余次数**
E8（D23）	Q一次性≤20元许可	0.89	**否**：项目范围不匹配

若只按相似度，E2和E8会排得更靠前。正确做法是先排除其作为P当前许可的效力，再把E5、E9、E10作为互补的证据**一起**使用。E2仍可作为“以前讨论过什么”的历史材料，但不能进入当前许可结论的事实支撑链。

5.4 一条证据链必须“覆盖所问命题”

用于回答“能否再做两次”，E5解释一般暂停，E9解释有限例外，E10证明例外已经消耗。三者功能不同，而不是同一种内容的重复版本。

可以用教学集合记号表示：设问题需要证据要素`U={一般规则， 例外范围， 消耗记录}`，候选E5覆盖第一项、E9覆盖第二项、E10覆盖第三项；选择三条后覆盖率为`3/3=100%`。只选相似度最高的E2，覆盖的合法决策要素仍是`0/3`。这就是**证据集合的互补性**比单条相关性更重要的直观原因。



图11 · 答案需要一组互补证据，而不是一个语义相似度冠军

六、路径得分和候选数量：为什么“跳得多”不能无脑继续

6.1 图扩展会产生组合爆炸

如果每个节点平均连出4条候选边，最多探索3层、暂不去重，那么每层产生的候选路径末端分别是`4、16、64`，累计为：

$$4 + 4^2 + 4^3 = 84$$

这里的84只是一个理想化的树结构计算。真实图会有重复节点、环、边类型限制、过滤索引与缓存。它说明：如果不控制关系类型、时间范围和最大深度，即使每一步都“合理”，整体也可能产生大量无关候选。

6.2 与其无限增加跳数，不如优先填补“证据缺口”

例如已经拿到E5与E9，但缺E10，可以精确查询“E9授权的使用回执”，不需要沿所有与P相关的节点继续搜索。可以设置停止条件：

- 已找到覆盖全部关键命题的原始证据；
- 新候选只是重复摘要，未增加独立证据；
- 扩展路径进入与问题无关的项目或时间范围；
- 超过有界延迟/Token预算；
- 必要证据不可得，应标明未知或待核查。

这与IRCoT的迭代检索动机、HippoRAG的关联检索动机方向一致，但具体停止条件属于本讲的工程教学归纳。[3][4]

6.3 两种“连边可信度”的误用

不要把人工给三条边的0.9、0.8、0.7直接相乘，当成整条路径真实概率0.504。相乘只有在指标被正确校准、定义相同且满足相应独立性/条件概率前提时才有概率意义。

更不能认为只要两条证据分别“有来源”，它们拼在一起产生的推断就已经被原文支持。例如“工具失败发生于模型调用后”与“模型有输出”不是同一个命题；没有对应Trace，不能通过时间先后推导责任归属。



图12 · 真实图含环与重合，此处只是结构复杂度直觉，不代表实测成本

七、将多跳与时间检索装入有限上下文

7.1 模型不必看见整张图，而要看见“足以判断的证据包”

假设本轮可提供给模型的证据上限为1,600 Token（课堂构造），对于D30两个子问题，可以选择：

原始证据	说明	Token（虚构）
E5	P一般暂停决定原文	260
E9	P一次例外原文与限制	330
E10	例外已执行回执	210
E3	D09的504工具日志	270
E6	D18对应追踪的诊断片段	350
合计	五条互补证据	**1,420**

预算剩余`1600-1420=180 Token`。不必为了填满而加入E2的未批准建议或重复的E7摘要。如果证据还要求展示每条原始出处的标识，应该把标识开销也纳入预算。**精简证据包不等于省略条件。**

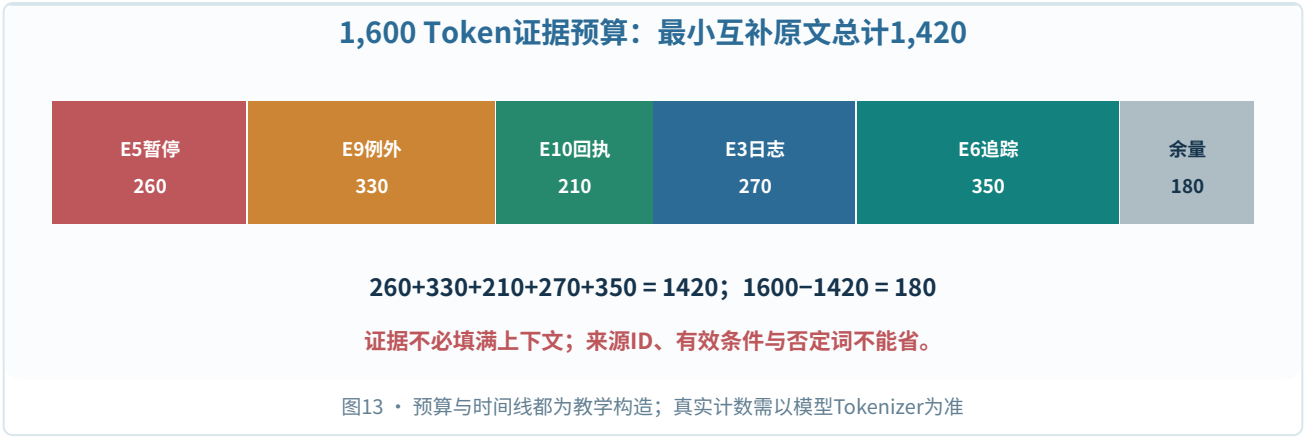


图13 · 预算与时间线都为教学构造；真实计数需以模型Tokenizer为准

7.2 两个子问题应分别给出答案与依据

针对“再收费调用两次”：

> 根据课堂记录，P的总体暂停仍在；D26只有一次不超过5元的例外，D29记录该例外已使用，因此无法仅据现有记录再进行两次收费调用。如果有新的负责人许可，需要核验其范围、额度和状态。

针对“D09 504后来怎样定性”：

> D09的原始工具回执记录了504；D18新增的对应追踪支持上游代理超时的诊断，因而该次事件更应按工具/基础设施问题记录，而不能仅凭D10的AI猜测记作模型参数错误。此判断不应外推为所有504故障的共同原因。

两段答案的证据链**互相独立**。即使它们都发生在同一科研项目，也不能把“D09工具故障”错误地当作“D30是否获准收费”的许可依据。

7.3 模型的解释与控制器的真实执行是不同环节

模型可以基于证据回答“现有记录不支持再收费调用”，但如果它同时提出调用付费API，外部控制器仍要读取**当前权威授权状态**并独立决定是否允许执行。一次正确的多跳自然语言推理不能取代执行层的权限约束。[1][2]

八、如何判断这类记忆检索有没有真正变好？

8.1 四级评价指标（理论理解，不安排实验）

第一级：单条证据召回。 E5、E9、E10分别有没有被找到？例如Recall@5是“前5个检索结果找回了多少相关条目”。

第二级：整链证据召回（chain completeness）。 完整答案所需的三段证据是否全部存在？单条Recall可能较高，但缺任一关键环都可能导致错误结论。

第三级：时间和来源有效性。 是否把D23的Q项目许可误转移到P？是否把D18才得知的诊断放进D10当时的知识状态？

第四级：最终回答/行动质量与成本。 是否正确回答、适当说明不确定性？若涉及外部行为，实际控制器是否按权威状态检查？需要多少延迟、Token、索引维护与人工核验成本？

LongMemEval明确考查跨会话推理、时间推理、知识更新与弃答能力，LoCoMo强调很长对话中的事件联系；这些可作为理解评价目标的代表来源。[1][8]



图14 · 长期记忆论文比较时，先确认各自测的是哪个环节

8.2 手算：单条召回率高，完整链却失败

假设本轮正确答案需要E5、E9、E10三条，某系统在Top-5中只找到E5和E9，另外找到三条无关片段。若只对这三条必要证据定义相关集，那么：

- `Recall@5 = 2/3 ≈ 66.7%`；
- `Precision@5 = 2/5 = 40%`；
- **整链是否完整？否**，因为缺E10，无法判定一次例外是否已经用完。

如果另一个系统找到全部3条并正确核验，整链就完整；但模型仍可能错误阅读，控制器仍可能执行失败，所以“整链完整”也不等于端到端成功。

8.3 一个有界延迟的教学例子

单次检索70ms、补查下一跳80ms、原文回读100ms、模型阅读生成400ms，则**两阶段检索**的教学总延迟是：

$$70 + 80 + 100 + 400 = 650\ \text{ms}$$

若增加第三轮无关检索80ms，延迟变成730ms，而证据未必增加。多跳策略的价值是补足必要证据，而不是让每次请求都消耗最多轮数。真实系统的网络等待和模型调用可以并发或串行，延迟公式只是说明结构，不是产品测量。



图15 · 延迟是示意计算，不是论文报告的基准测试或任何产品性能

九、代表性研究放在同一张地图上

研究或标准	本讲需要理解的真实重点	不应误读为
LongMemEval（ICLR 2025）[1]	长期记忆的跨会话推理、时间推理、知识更新、弃答等评估	已解决这些问题
Zep / Graphiti（2025预印本）[2]	动态信息、时间知识图与历史关系管理	图节点有边就必定真实
IRCoT（ACL 2023）[3]	多步推理过程中交替进行检索与下一步问题推导	AI的推理文本本身就是证据
HippoRAG（NeurIPS 2024）[4]	图关联与个性化PageRank支持多跳/关联性检索	必须采用同一种脑科学类比架构
HippoRAG 2（2025预印本）[5]	关联记忆与事实性、上下文整合的进一步设计	比任何简单检索都永远更好
GraphRAG（2024预印本）[6]	文档实体图与社区摘要服务整体性问答	与所有多跳Agent记忆任务完全相同
LoCoMo（ACL 2024）[8]	跨长对话事件、时间与因果联系的评估任务	长上下文一定等于准确记忆
W3C PROV-O（2013标准）[9]	原始数据、处理活动和责任主体的来源描述	具备溯源信息就表示观点正确
LongMemEval-V2（2026预印本）[10]	面向Web智能体历史经验、动态状态与工作流知识的记忆评估	只有问答准确率才值得关注

这几项研究的任务、数据与实验设置并不相同，**不能把它们在各自论文中的数字直接排成“统一系统排行榜”**。在科研阅读中要先问：它们究竟解决哪个环节的困难？[1][2][3][4][5][6][8][10]

十、十二个常见误区：把容易混淆的地方一次讲透

1. **“多跳=至少调用两次工具。”** 错。多跳描述的是所需事实与关系的复杂性，一次图查询也可能返回多跳链。
2. **“多跳越多越智能。”** 错。不必要的跳数会增加噪声、延迟和错误传播。
3. **“图里有路径就证明因果关系。”** 错。关系连通、来源派生与因果归属完全不同。
4. **“最近提到的总是当前有效。”** 错。D29是执行回执，不是新授权。
5. **“D26新许可覆盖D12所有禁令。”** 错。局部例外不必然撤销一般规则。
6. **“D18查明的原因也可作为D10已经知道的内容。”** 错。时间回溯和历史知识状态不同。
7. **“没搜到已用回执说明许可还没用。”** 错。检索缺失不等于事实不存在。
8. **“0.96语义相似意味着96%可信。”** 错。相似度与事实可信度不是同一变量。
9. **“E5/E9/E10只是三份重复文本，选一份就够。”** 错。它们分别覆盖不同的必要证据环。
10. **“来源标注正确，AI得出的结论就一定正确。”** 错。证据可能被错误解释或不支持推论。
11. **“所有时间查询只需按创建时间排序。”** 错。须区分有效时间、事件时间与获知时间。
12. **“检索系统回答正确就能直接执行收费调用。”** 错。执行需要独立检查当前授权及相应边界。

十一、理论思考题（建议先自己推演，再看答案）

题1（理解）：D30询问“P项目能再收费两次吗”，为什么只检索到D26的E9不能给出结论？请指出下一步必须查的记录。

题2（概念）：一次图查询返回E5→E9→E10三段路径，这属于几跳？数据库只查询一次是否意味着单跳记忆？

题3（手算）：若三环独立召回概率分别是0.9、0.8、0.7，完整链召回概率是多少？为什么不能把答案视为真实系统的准确率？

题4（时间）：一般暂停D12起长期有效，例外D26起生效且D29被消耗。请分别说明在D14、D27、D30，如何判断一般规则与例外的关系。

题5（回溯）：D09发生504，D18才获得代理追踪。问“D10时系统是否已经证实根因？”和“现在回看D09是什么原因？”两个问题的证据是否一样？

题6（排序）：E2的相似度0.96、E5为0.74、E9为0.81、E10为0.61。为什么不能按分数降序只取E2作为当前许可依据？

题7（图）：一颗无重复的候选树每层分支数4，扩展三层共看到多少个下一层节点？现实图为什么往往不同？

题8（指标）：正确回答需要3条不同证据，Top-5只找回其中2条。计算Recall@5、Precision@5，并判断整链是否完整。

题9（预算）：1600 Token证据预算，E5=260、E9=330、E10=210、E3=270、E6=350，五条总计多少？还剩多少？是否必须塞入一条旧AI建议？

题10（来源）：D20的E7复盘引用E3与E6。搜索同时找到了E3、E6、E7，能否算作三份独立证据？为什么？

题11（失效诊断）：系统正确找到了E5/E9/E10，但模型仍回答“已允许任意收费”。至少指出两种可能错误位置，以及如何区分。

题12（独立重建）：请用不超过八个步骤，从D30用户问题出发，自己设计一条多跳+时间的记忆检索流程，并指出停止条件和与执行权限的边界。

十二、理论思考题详细答案与推导

答案1： E9只能证明“存在一次、≤5元的有限例外”，不能证明该例外截至D30仍可使用，也不能推导“一次例外=还能做两次”。必须继续核验E10的真实执行回执与许可消费状态，并与E5一般暂停决定共同判断。缺E10时应保留未知，不可脑补许可剩余次数。

答案2： 如果以每条定义好的关系边为一跳，路径E5→E9→E10连接两条关系边，可称为两跳（具体需说明路径方向与边定义）。即使系统一次查询拿到整条路径，其**事实连接长度**仍是两跳。API调用次数和语义跳数属于不同指标。

答案3： 在题设独立假设下，`0.9×0.8×0.7=0.504=50.4%`。但真实链可能由同一索引、同一Embedding模型产生关联错误，独立假设未必成立；最终还涉及事实核验、模型阅读、行动控制，因此不能把50.4%直接称为任务正确率。

答案4： D14只有D12一般暂停，没有D26例外；根据现有许可记录，不能进行新收费操作。D27时一般暂停仍在，但D26给出覆盖P、限1次≤5元的局部例外，如果条件满足且尚未消耗，则最多一次符合范围的操作可能获准。D30时D29回执显示例外已经消耗，一般暂停未被解除，因此不能据旧例外再做两次。实际系统还需核验消费台账与实时授权状态。

答案5： 不一样。“D10当时是否已证实”只能用D10之前当时可得的信息，因此D18追踪不能证明D10已经知道根因。“现在回看D09”可以使用后验取得的E6，但仍只对对应D09那次请求作有边界的技术归因。两类问题区分了系统获知时间与被解释事件的发生时间。

答案6： E2的0.96仅是语义相似示意值，而且内容属于AI建议，未具备研究者批准的主体与状态条件。当前许可需要E5一般限制、E9例外范围、E10实际使用状态。硬资格条件必须优先于软相关性排序，高分无效证据不能覆盖低分有效证据。

答案7： 第一层4、第二层16、第三层64，合计`4+16+64=84`。这是假设每层恰好4个互不重复子节点的理想树；现实图有环、重复实体、不同关系类型、时间过滤和已访问集合，实际访问数可更少（也可能因分支变化不同）。

答案8： `Recall@5=2/3≈66.7%`，`Precision@5=2/5=40%`。整链不完整，因为至少一条必须证据未被找回。答案不能仅凭两个碎片推断第三条已存在或不存在。

答案9： `260+330+210+270+350=1420 Token`，剩余`1600-1420=180 Token`。没有必要为了用完预算放入未批准的旧建议；若必须展示引用ID、时间和角色，应先留出这部分格式开销，不足时压缩冗余而不是删除否定/条件。

答案10： 不可以。E7是基于E3和E6生成的派生复盘，其来源依赖已经包含E3/E6；它可以帮助阅读和归纳，但不能无条件算作第三条独立验证。应沿来源链去重并区分原始证据、推断和摘要。

答案11： 情况A：检索正确，模型阅读错误，例如把“只许可一次”理解为“永久放开”，属于上下文理解/时序推理层；检查输入证据和输出解释。情况B：模型输出了正确限制，但控制器仍发送额外付费调用，则是执行权限检查层；检查实际工具Trace与授权核验日志。还可能是E10“已执行”的含义被错误结构化，属于证据/状态维护层。通过各环节原始记录分层定位，而不是统一归因“记忆不好”。

答案12： 一条合理的教学流程：①确定P项目与两个子问题的范围；②先读取P当前权威收费状态；③获取E5一般暂停及版本；④检查有无E9覆盖P的例外；⑤查询E10消费回执并核状态；⑥对504分别查E3原始日志、E6后续追踪，区分发生/获知时间；⑦将最小互补证据包带原始出处组装上下文并分别回答，缺证据即说明未知；⑧若提议实际付费执行，控制器必须重新校验最新许可、额度与次数。停止条件为关键证据足够，或达到有界资源上限且必须明确剩余不确定性。

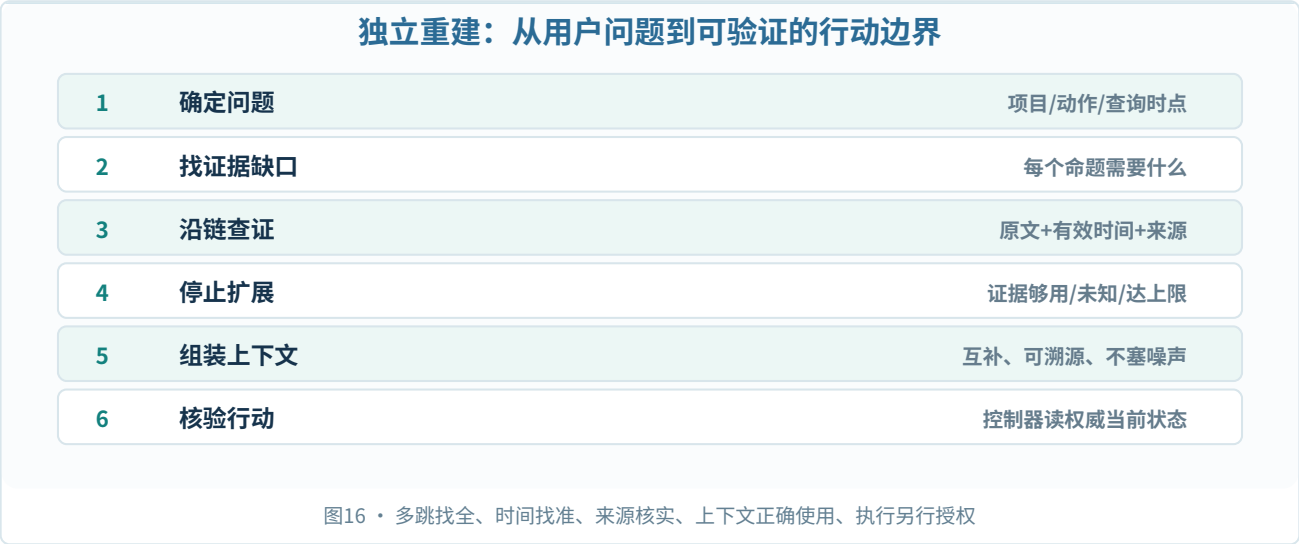


图16 · 多跳找全、时间找准、来源核实、上下文正确使用、执行另行授权

十三、本讲总结：知识应该在头脑里“动起来”

记忆检索并不止于“寻找最相似的过去文本”。真正复杂的长期智能体问题会要求我们：先拆清用户要问的命题，找到每个命题缺失的证据，从原始记录和关系索引扩展必要的下一跳，分别判断时间与来源是否适用，形成可以追溯的互补证据包，最后让模型依据证据回答，并将真实行动留给能检查权限和环境状态的控制器。

把它简化为一句话：**多跳负责“找全关系”，时间检索负责“找对时点”，证据核验负责“找准效力”，上下文使用负责“正确表达”，控制器负责“真实执行是否获准”。**

第24讲将继续学习“检索到的记忆怎样真正进入模型推理、规划与行动”，重点研究为什么证据都已找到，智能体仍可能做出错误决定。

参考文献与原始资料（截至2026-10-18）

以下为实际核对的研究论文、权威会议记录与技术标准；论文实验数据如未专门回核，不以作者数值作为本教程的独立结论。教学案例和示例数字均为原创构造。

[1] Wu, D., Wang, H., Yu, W., et al. **LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory.** ICLR 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[2] Rasmussen, P., Paliychuk, P., Beauvais, T., et al. **Zep: A Temporal Knowledge Graph Architecture for Agent Memory.** arXiv:2501.13956, 2025. https://arxiv.org/abs/2501.13956

[3] Trivedi, H., Balasubramanian, N., Khot, T., & Sabharwal, A. **Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions.** ACL 2023. https://aclanthology.org/2023.acl-long.557/

[4] Gutiérrez, B. J., Shu, Y., Gu, Y., et al. **HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models.** NeurIPS 2024. https://proceedings.neurips.cc/paper_files/paper/2024/file/6ddc001d07ca4f319af96a3024f6dbd1-Paper-Conference.pdf

[5] Gutiérrez, B. J., Shu, Y., Qi, W., et al. **From RAG to Memory: Non-Parametric Continual Learning for Large Language Models (HippoRAG 2).** arXiv:2502.14802, 2025. https://arxiv.org/abs/2502.14802

[6] Edge, D., Trinh, H., Cheng, N., et al. **From Local to Global: A Graph RAG Approach to Query-Focused Summarization.** arXiv:2404.16130, 2024. https://arxiv.org/abs/2404.16130

[7] Cai, L., Mao, X., Zhou, Y., et al. **A Survey on Temporal Knowledge Graph: Representation Learning and Applications.** arXiv:2403.04782, 2024. https://arxiv.org/abs/2403.04782

[8] Maharana, A., Lee, D.-H., Tulyakov, S., et al. **Evaluating Very Long-Term Conversational Memory of LLM Agents.** ACL 2024. https://aclanthology.org/2024.acl-long.747/

[9] W3C. **PROV-O: The PROV Ontology.** W3C Recommendation, 2013. https://www.w3.org/TR/prov-o/

[10] Wu, D., Ji, Z., Kawatkar, A., et al. **LongMemEval-V2: Evaluating Long-Term Agent Memory Toward Experienced Colleagues.** arXiv:2605.12493, 2026. https://arxiv.org/abs/2605.12493

[11] Yang, Z., Qi, P., Zhang, S., et al. **HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering.** EMNLP 2018. https://aclanthology.org/D18-1259/