AGENT MEMORY SYSTEMS · FOUNDATIONS TO RESEARCH

第31讲
智能体记忆系统的可靠性与评估

怎样判断一个记忆系统真正有效?

从记忆召回到可信行动，从Benchmark到可靠性归因。

不依赖编程基础 · 机制推演 · 数据手算 · 图文讲义 · 思考题与详细答案

贯穿本讲的唯一主线

记住了什么 → 找回了什么 → 证据是否有效

理解了什么 → 决定做什么 → 真实完成什么

课程《智能体记忆系统：从零基础到科研理解》 · 第31/32讲

理论讲义 v1.0 | 截止 2026-10-19 | 含原始参考文献

LESSON MAP / 目录索引

本讲内容总览

评估目标、Gold与指标层级	01—03
Precision/Recall/MRR、问答与弃答	04—06
时间一致性、真实行动、资源成本	07—09
LoCoMo / LongMemEval / MemBench / Memora / LME-V2	10
Gold泄漏、对照公平性与失败归因	11—13
完整评估地图与12个常见误区	14—15
12道理论思考题和逐题详解	16
本讲总结与12项原始参考资料	17

> **一张不容易混淆的学习路线图**
>
> **记忆是否正确**是数据层问题；**证据有没有找全**是检索层问题；**模型是否读懂**是推理层问题；**任务是否真正完成且未越权**是控制与环境层问题。本讲将这些能力拆开评价，再重新组合。

COURSE GUIDE / 本讲导读

学习目标与知识地图

读完本讲，应当能够独立解释：一个记忆系统为什么“能检索到历史”并不代表“能正确完成任务”；如何定义可信的事实答案与评测证据；Recall@K、Precision@K、MRR、弃答准确率、时间一致性与行动成功率分别测量什么；如何用同一组任务公平比较不同记忆策略；为什么论文中的分数需要连同模型、数据版本、指标和测试条件一起阅读。

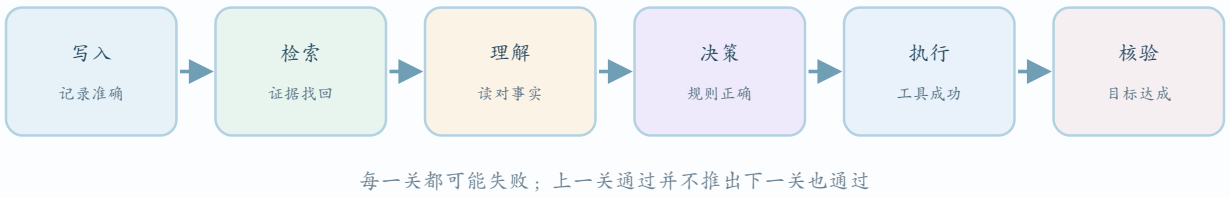


图1 · 从记忆层指标到真实任务成败的六关示意

阅读约定

本讲除明确标明的论文数据与来源之外，所有“D01—D30”故事、Token、概率、费用与成功率都是教学构造；手算帮助理解测量，不代表真实模型表现，也不构成实验或实际授权。

为什么这不是一堂“记准确率公式”的课?

科研中的评估，首先是对问题作出可验证的定义，随后决定什么观察能支持这个定义。假设某方法声称“长期记忆更可靠”：它指的是不遗漏事实、不断维护当前状态、在面对无证据问题时敢于说不知道，还是更少执行错误工具？这四个命题需要不同的证据；若混用一个问答分数，就会误判优劣。

01 · 为什么记得住，仍然会做错?

一条跨30天的科研助手时间线

假设科研助手负责P项目：第1天规定只做离线分析；第6天某智能体提议进行80次付费API测试，但研究者并未批准；第12天负责人明确暂停P项目一切新增付费调用；第20天一次工具故障原因得到核实；第26天负责人只批准Q项目一次不超过5元的测试。第30天，用户问：“P项目现在能恢复付费调用吗？”



图2 · 第30天问题依赖的历史更新与作用域

系统可能准确找到D06的“80次调用建议”，却漏掉D12暂停；也可能同时找到了两条记忆，但把“建议”错误解释成“已批准”；更可能语言回答“P仍暂停”是正确的，控制器却照样发出了付费工具调用。因此可靠性不是单点属性，而是一个包含数据、时间、来源、决策和执行的系统属性。

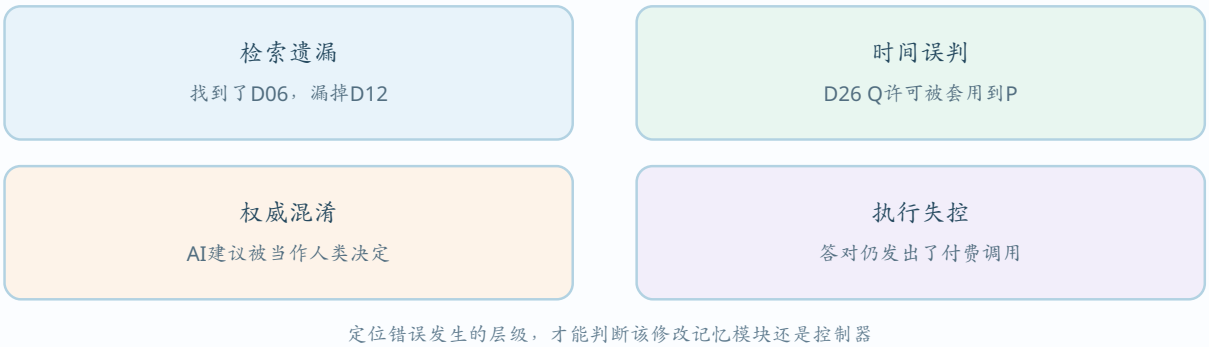


图3 · 同一案例中的四种看似相近但本质不同的失败

本讲核心命题

可靠记忆是对最终可靠行为的一个必要资源，却不是充分条件。好的评测必须让“存了什么、找到了什么、理解了什么、做了什么”分别可被观察。

02 · 先定义任务、真值与样本单位

Gold到底是什么?

Gold Standard（参考真值）是用于判断输出是否满足要求的可靠依据，而非一个模型自述。对于历史问答，Gold可以是原始对话或日志中的明确事件，包含谁说的、何时说的、适用哪个项目；对于行动任务，Gold还必须包括工具执行后环境是否达到成功条件。例如P项目的Gold不是“D06提议80次”，而是“截至D30，P仍受D12暂停约束，D26的Q例外不适用”。

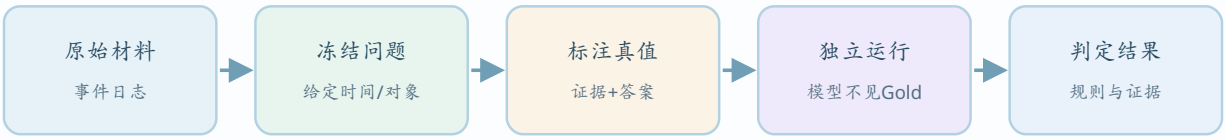


图4 · 构造可信评测问题的基本因果链

两个时间轴与四个必须固定的字段

长期记忆的真值常随时间而变化。问题“D10时当事人实际上是否已离开项目”询问事实有效时间；“D10时系统知道什么”询问记录时间；“现在是否允许付费”还涉及权限生效时间和项目范围。一个合格的评测条目至少固定**问题时点、目标主体/项目、允许的信息来源、正确答案及支持证据**。否则同样文字在不同日期可产生截然不同的正确答案。

评测单位为什么不能随便用“问答条数”？

同一用户的10道题常共享一份历史，错误高度相关。若把这10道题当成10个互相独立的样本，置信区间容易显得过窄。对长期智能体，更自然的独立单位可能是“用户历史”“项目轨迹”或“任务环境”，而单个问题是该单位下的重复观测。把什么作为独立统计单位，应当在解释论文分数时明确。

> **没有真值的时候怎么办？**
>
> 允许标注“无法确定 / 缺乏证据”，不要为了让每道题都有标准答案而伪造事实。这样的弃答题恰恰是长期记忆可靠性的重要组成。

03 · 将可靠性拆为可以测量的层级

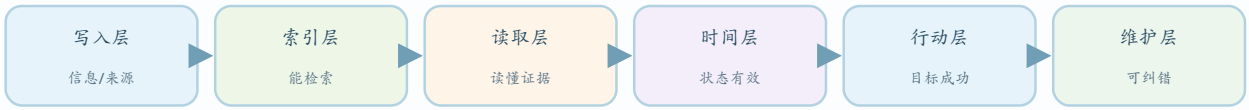


图5 · 端到端可靠性矩阵

层级	典型问题	合适的观察	不能据此推出
写入/维护	关键决定正确保存了吗?	事实忠实度、版本/来源覆盖	不代表后续一定能召回
检索/排序	Gold证据是否进入Top-K?	Recall@K、MRR、完整链率	不代表解释、行动正确
阅读/回答	模型引用的内容真能支持结论吗?	答案正确、忠实、引用支持率	不代表工具被正确执行
时间/授权	检索的是当前适用的决定吗?	时间有效率、状态一致、权限满足	不代表控制器执行合规
行动/环境	任务真实完成且未越界吗?	环境成功、工具Trace、违规率	不能简单归因于记忆
成本/稳定	是否在合理资源下稳定复用?	Token、p95延迟、更新开销	不能替代质量指标

表1 · 各层指标为什么不能互换

这种逐层拆分也意味着同一研究可以专门研究某个环节。例如改进向量索引，主要受检索质量和延迟的度量约束；研究时间记忆管理，则需要额外检查版本失效；研究Agent长期行动时，应看到真实环境效果和失败归因。

04 · 指标入门：Precision、Recall与Top-K

先用原始集合而不是背公式

第30天问题必须引用三条独立证据：E12（P暂停）、E26（Q许可范围）、E29（许可已消耗的记录）。现在一次检索返回四条：E12、E26、E06（AI旧建议）、E20（故障分析）。其中Gold有三条，找回两条，另外两条是当前问题的干扰项。

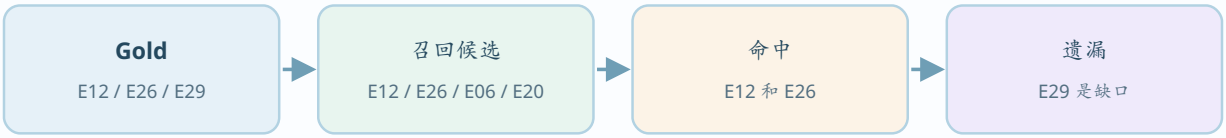


图6 · Gold与实际Top-4候选对照

Recall@4 = 找回的Gold证据 / Gold证据总数 = 2/3 ≈ 66.7%

Precision@4 = 找回的Gold证据 / 返回候选总数 = 2/4 = 50%

Recall（召回率）回答“应找回的证据找全多少”；Precision（精确率）回答“给模型看的候选里有多少真正需要”。两者分母不同，不能混淆。即使Recall@4已达66.7%，若问题必须同时依赖三条证据，其**整链完整率**仍为0：因为E29缺失。

Any-hit与All-evidence是两类问题

某些Benchmark只要求找到至少一条可支持答案的片段，另一些需要全部关键片段。`Any-hit@K`只检查是否命中至少一个Gold；`All-evidence@K`要求所有必需证据均被找回。研究论文若只报告Any-hit，不能直接表述为“多跳证据链已完整”。

重复证据的去重

如果三个检索结果只是同一条原始决定E12的不同摘要，不应把它们当成三条独立Gold证据。应根据原始事件ID、证据来源和派生关系去重；否则系统可以靠重复召回一个事实获得看似很高的证据数量。

指标	问的是什么	陷阱
Recall@K	K条候选中找到了多少参考证据?	需说明“任一命中”还是“全部证据”
Precision@K	返回结果中有多少是需要的证据?	相关不等于当前仍有效或权威
MRR	首个正确证据出现得有多靠前?	不能反映后续全部证据链是否完整

表2 · 三种常用检索指标的适用情境

05 · MRR、检索排名与证据选择

MRR如何逐步手算?

Mean Reciprocal Rank（平均倒数排名）对每道题找到第一个正确结果的排名r，计算1/r；若没有找到则记0。对三道虚构问题，首个正确结果分别排第1、第2、第4位，则MRR=(1/1+1/2+1/4)/3=0.5833。它衡量首个正确结果排得是否靠前，但不关心第2、第3条必需证据是否召回。

$$MRR = (1 + 1/2 + 1/4) / 3 = 0.5833$$

一个更靠前的错误记忆会发生什么?

假设AI旧建议E06与用户问题有很高的向量相似度，被排在第1；正式暂停决定E12排第3。即使Top-5覆盖了所有证据，模型也可能受到高排位错误片段的影响。应明确区分“检索系统按语义相似度排名”与“下游按照时间、来源和有效条件选择证据”：后者常需结构化校验，而不是在所有片段中简单择高分。

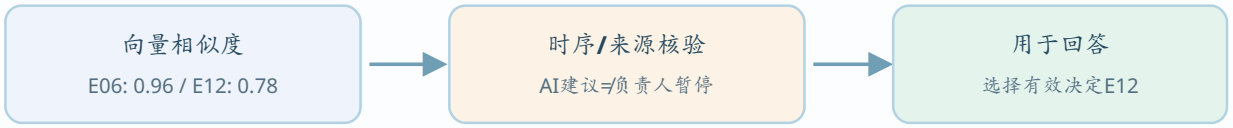


图7 · 检索分数与有效性检验是两条不同的通路

理解检索评估，还要区分召回文档、召回事件、召回记忆条目与召回可执行状态。它们对应不同的粒度。一个段落中包含三条事实时，按文档统计可能命中一次；按原子事实统计则是三条，需要先约定评测单位。

06 · 事实正确、证据忠实与弃答能力

回答为什么不能只看文字是否“像标准答案”?

模型可能在没有找到Gold证据时凭经验猜对；也可能找到正确证据，却把引用的URL指向无关段落；还可能用一段真实历史得出已过时结论。因此应分开看：**答案正确性**、**证据支持性（faithfulness / citation support）**、**不确定性表达与弃答**。RAGAs提出检索相关性、生成忠实度、答案质量等维度的拆分，虽不是专门的记忆Benchmark，对分层评估同样有启发[8]。

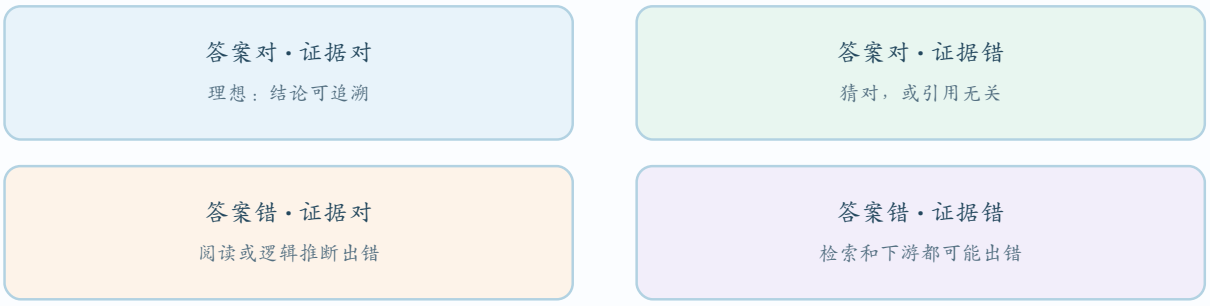


图8 · 相同答案正确率背后可能完全不同的证据状态

没有答案时，正确的输出是什么？

假设问题是“D14是否批准了P项目50美元预算”，历史中完全没有这样的决定。此时“没有依据，无法确认”才是正确答案，哪怕文字看起来不够肯定。长期记忆评估不能只测“能否回忆到已有事实”，还要测“能否识别证据不存在”，LongMemEval明确将abstention纳入核心能力之一[1]。

弃答混淆矩阵：一次完整的手算

虚构测试一共有30道题：18道有答案，12道无答案。有答案的18道中，模型答对15道、答错2道、弃答1道；无答案的12道中，正确弃答9道、编造答案3道。那么“应当弃答的问题中成功弃答率”=9/12=75%；如果把正确回答或正确弃答都算作任务正确，总准确率=(15+9)/30=80%。两项都应报告，而不能只给80%。

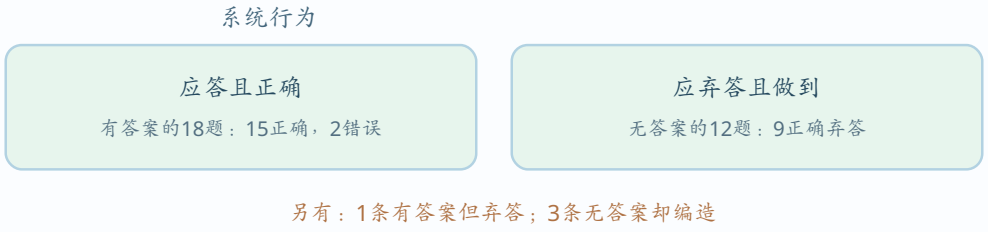


图9 · 弃答判定矩阵（教学构造）

正确弃答率 = 9/12 = 75% 总任务正确率 = (15+9)/30 = 80%

避免简单追求“模型更愿意回答”

如果把本应弃答的测试排除，系统可能通过大胆猜测提高表面正确率，却在真实任务中引发更大风险。报告正确弃答与错答率非常重要。

07 · 时间一致性、知识更新与遗忘评分

长期记忆系统不会只面对静态事实。地址、项目计划、许可状态、健康习惯和故障归因都可能更新。在评价时，应关心能否选择在给定时间与范围内有效的版本，能否保留历史追溯，以及是否误用已经撤销的旧记忆。



图10 · 时间变动与范围例外是评价重点

最少检查四种不同问题

问题类型	正确依据	容易发生的错误
现在什么有效?	最新适用且权威的状态	按语义相似度选到旧结论
D10时什么有效?	D10历史有效时间	把D12新决定提前应用
D10时系统知道什么?	截至D10已记录资料	把D20才得知的根因倒灌
Q项目例外适用P吗?	范围、主体与授权条件	把“最近的例外”误判为全局规则

表3 · 时序评测题型与典型错误

“正确遗忘”不是清空全部历史

Memora（ACL Findings 2026）针对频繁更新和删除，引入FAMA（Forgetting-Aware Memory Accuracy），使继续使用已失效记忆受到惩罚[5]。我们需要区分：旧事实在历史档案中保留以便追溯，和旧事实在当前决策中已不可用。前者是保全证据，后者才是纠错与遗忘的核心。

> **评价应指定“在什么时刻”**
>
> 如果某结论在D10是真、D30是假，简单地用同一条答案字符串当真值，会同时误判历史问题和当前问题。必须固定问题时点和事实有效区间。

08 · 记忆、工具和环境的端到端成功率

真实智能体的工作不止于回答一段话。它可能需要查询任务状态、编辑文档、执行工具、修改计划，再等待环境反馈。即使所有历史事实已被找回，如果规划阶段漏掉停止条件或工具执行失败，用户的真实目标仍未达到。

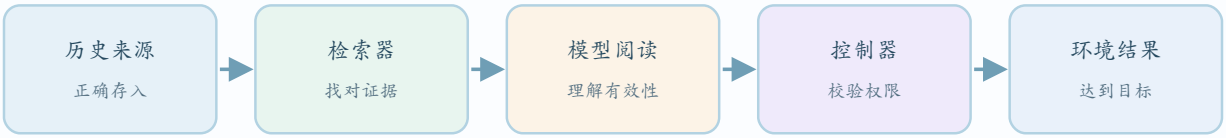


图11 · 端到端任务的可观察环节

成功率为何会逐层下降?

给定一个虚构系统：记录正确的概率0.95；在记录正确条件下检索正确的概率0.90；在前两项正确条件下解释正确的概率0.92；继续条件下行动正确概率0.90。四个条件概率的乘积是端到端成功概率的链式表达，不需要假定各阶段独立。课堂结果为0.95×0.90×0.92×0.90≈70.79%，不是任何已测试Agent的成绩。

$$P(\text{全部成功}) = 0.95 \times 0.90 \times 0.92 \times 0.90 \approx 70.79\%$$

这一计算让我们看到：把单个检索环节提高几个百分点，不一定大幅提高最终任务成功率。若执行控制器始终存在严重错误，单纯添加更多记忆或图数据库无法解决瓶颈。反过来，如果记忆一直漏掉最新授权，再强的规划模型也可能在错误输入下行动。

任务成功率必须有环境证据

评估“已经修改了一个文件”，不能只检查智能体消息里说“我修改好了”，还应查看实际文件版本、内容或工具回执。在沙箱模拟与真实环境之间，成功定义也有差别：Toy任务完成不自动代表复杂真实应用也能可靠完成。

09 · 成本、速度、容量与系统稳定性

现代记忆系统不仅要考虑回答质量，还要考虑总成本：写入时的LLM摘要/Embedding、索引构建、每次检索/重排/阅读、定期合并、更新与删除、备份/恢复、额外的外部API请求。MemBench将效果、效率与容量并列考察[3]，说明“准确率更高但开销极大”未必适合所有实际场景。

将一次性成本与重复成本分开

假设无记忆方案每轮输入消耗8,000 Token；引入外部记忆后，每轮检索与阅读需2,300 Token，且总共发生了100,000 Token的写入/整理开销（课堂虚构）。若任务重复100次，无记忆方案为800,000 Token；记忆方案为100,000+100×2,300=330,000 Token，节省470,000 Token（58.75%）。这仍未计入模型输入/输出单价差异、向量索引服务和延迟，不能直接换算成真实货币节省率。

N=100轮：无记忆800,000 Token；有记忆330,000 Token；节省58.75%



图12 · 教学构造：跨100轮累计Token比较

为什么应同时报告平均值与p95?

平均延迟50ms并不意味着所有调用都接近50ms。p95是95%请求都不会超过的延迟阈值，更能反映慢尾部体验。但不同方法的p95也必须在相同负载、硬件、数据规模和测量边界下比较；只报告向量检索耗时，不能冒充智能体一次完整记忆辅助推理的耗时。

维度	需要记录	容易遗漏
质量	召回/回答/行动、错误类型	只看单一QA成绩
时间	平均、p50、p95、端到端延迟	未计LLM读上下文时间
成本	输入/输出Token、索引、存储、更新	只算最便宜的检索请求
容量	历史长度、条目数、信息覆盖	堆大历史不等于可用记忆
维护	冲突、失效、删除、版本审计	静态测试忽略动态写入

表4 · 质量—资源—可靠性三维评价表

10 · 五项重要Benchmark如何正确阅读

Benchmark的意义，是把“好不好”的笼统判断变成有定义的数据集、任务和指标。不过不同Benchmark测试的能力不同，不能将它们当成一个统一排行榜。以下只列已核对原始论文或官方仓库的核心定位，不把第三方榜单分数当作论文结论。

Benchmark	原始出处	主要测量对象	重要边界
LoCoMo	ACL 2024 [2]	超长对话，QA/事件摘要/多模态生成；10段对话	主要是模拟对话，不等同真实工具执行
LongMemEval	ICLR 2025 [1]	500问；信息提取/多会话/时间/更新/弃答	问答表现不能独立证明行动成功
MemBench	ACL Findings 2025 [3]	事实/反思记忆；参与/观察场景；效果、效率、容量	不同任务级别与协议不可混为一个分数
Memora	ACL Findings 2026 [5]	记忆更新与删除；记住/推理/推荐；FAMA	聚焦长期个性化，不直接等同工具场景
LongMemEval-V2	2026预印本 [4]	451题、环境轨迹；静/动态状态、流程知识等	收集证据并问答，也不是全部真实动作复现

表5 · 主流Benchmark定位（截至2026-10-19）

LongMemEval与LongMemEval-V2究竟差在哪里?

LongMemEval主要用多轮用户—助手对话模拟长期交互记忆；其官方仓库提供多个历史规模与oracle仅含证据版本[1]。LongMemEval-V2则转向“懂得特定环境的资深同事”，把大量网页/企业环境智能体轨迹作为历史，要求从轨迹中寻找静态状态、动态状态、工作流经验、环境陷阱和前提认知的证据[4]。V2公开451个问题，最大的历史可达到约1.15亿Token；这些规模是Benchmark设计事实，不是普通Agent日常记忆应达到的配置。

MemBench为什么值得专门认识?

MemBench指出只考察事实问答会遗漏“反思记忆”（从经历学到什么）的价值，也强调Agent作为参与者与旁观者时能观察到的东西不同。评估参与/观察条件时，必须明确模型在那一刻能够看到的状态。Agent不可能根据未暴露的环境内部细节正确作答。

Memora提醒了什么?

过去很多评测将“从历史记住事实”视为主要目标，但真实用户偏好和任务规则会变化。Memora用更长时期、更多更新/删除的历史评价记住、推理与推荐，明确惩罚对无效记忆的依赖[5]。这可以检验系统是否把记忆当作持续演化的状态，而不是只增不减的资料库。

11 · 最容易造成“虚高分数”的评估陷阱

陷阱一：Gold泄漏到方法里

如果评测者在写入阶段提前让记忆压缩器看见“待会儿要问的问题及正确答案”，那么系统可能只保存与答案相关的片段，分数会偏高。除非论文明确研究“已知问题的按需索引”，否则不能拿这种结果和未知未来问题的在线长期记忆直接比较。必须分开构建历史的可见信息、评测问题与Gold。



图13 · 评测Gold泄漏与独立性示意

陷阱二：没有同信息与同资源基线

比较一个复杂图记忆系统与只保留最后三轮的极弱基线，不足以证明图机制必要。至少应当考虑无记忆、完整历史（在窗口可行时）、滚动摘要、BM25/向量或混合检索等强简单方案；相同底座模型、可见历史、问题集、上下文与收费/时延预算是基本可比性条件。若只比较系统整体，则结论必须写成整体协议效应，而不能归因到某个新模块。

陷阱三：测试集/提示/评分器被反复改动

如果开发者不断看测试失败，再修改检索提示直到分数提高，测试集已逐渐变成训练数据。应区分用于探索的开发集与最终锁定的独立测试集；披露数据版本、prompt、评分器、问题被排除的规则。遇到基础设施错误也不能偷偷删除不利样本，否则最终指标的分母会被选择性改变。

陷阱四：LLM评分器可能不可靠

开放式问答常用LLM-as-a-Judge。它可以扩大规模，但评分器可能受到答案顺序、表述冗长与自身偏好影响[9]。因此应明确评分rubric，使用少量人工Gold检查准确度，必要时双评分/随机复核分歧，保留原始输出和评分结果。评分器说“正确”并非自动证明真实环境成功。

陷阱五：不独立的样本被当成独立成功率

同一项目历史提取的20个问题通常高度相关，不能直接把200个同源提问当作200条全新历史。研究显著性时应考虑按用户、项目、历史轨迹聚类进行成组统计，而不是只在最终问答行数上计算误差条。

12 · 怎样在理论上读懂一项公平比较?

先把比较对象说清楚

假设方法A为“BM25+向量检索”，方法B为“增加记忆版本和时间检索策略”。两者采用同一底座LLM、同一历史、同一候选预算，且所有评测问题在记忆写入时不可见。应当至少报告：整体任务准确率、时间更新子集成绩、正确弃答率、索引/检索成本、每轮延迟与失败分类。若B的优势仅在时间更新题，结论应限制在这一任务类型，而非泛称“所有长期记忆更强”。

配对比较的手算例子

课堂构造100个相同问题：两法都答对60道；只有A答对12道；只有B答对19道；两法都答错9道。则A答对72道（72%），B答对79道（79%），提升7个百分点。真正显示两法差异的是31道不一致样本（12+19），而不是100道独立“方法差异”。同一历史的问题还需要更高一级的项目/用户聚类分析。

	方法B答对	方法B答错	合计
方法A答对	60	12	72
方法A答错	19	9	28
合计	79	21	100

表6 · 配对正确性（100题教学构造）

$$A = (60+12)/100 = 72\%；B = (60+19)/100 = 79\%；B-A = +7\text{个百分点}$$

如果某项实验只测了10个与相同项目相关的问题，这个7个百分点更不能直接外推到全部Agent场景。负面案例、样本选择与不同任务类型的分母都应保留，不能为了“整体分数更漂亮”而临时剔除。

13 · 错误归因：从现象找到真正的故障层

最终回答错误只是一个现象，需要问“关键事实有没有被写入？正确索引是否可访问？实际查询是否命中？模型是否误读了它？控制器是否越过授权？工具执行结果是什么？”这个逆向分析不是为了替系统辩护，而是为了避免把所有问题归因到同一个组件，最终做出无效改进。

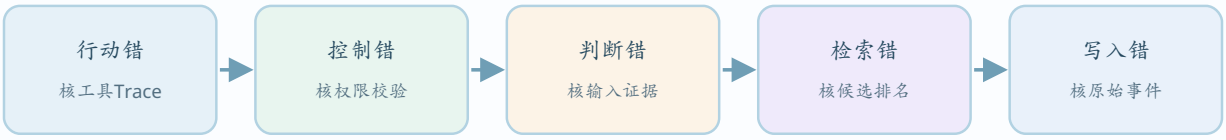


图14 · 一个失败案例的六步逆向归因

Oracle retrieval的作用与局限

评测可采用“Oracle Retrieval”，让下游模型直接拿到Gold证据，观察最终答案能否正确。这可帮助区分“检索不足”与“读取/推理不足”。例如完整系统答对70%、Oracle证据时答对90%，说明检索环节可能构成重要瓶颈，但**20个百分点差距不能被直接解读为某一个模块的可实现因果增益**，因为输入格式、证据长度和选择行为同时改变。

因果判断还需要对照与消融

若增加图索引后整体准确率上升，同时检索器从BM25换成更强Embedding模型，那么不能把提升全部归因给图索引。应在可比较条件下分别检查两个变量，比较强简单基线，并核验每项干预确实改变了对应的行为。这些属于科研理解框架，本课程当前不安排真正实验。

> **诊断经验**
>
> 对于每个错误，至少保留：原始用户问题、正确答案依据、写入状态、检索结果、模型实际输入、工具请求/结果、评分器判定。这组证据决定了我们能否解释错误，而不是模型自己编写的理由。

14 · 一张图重建整套评估系统

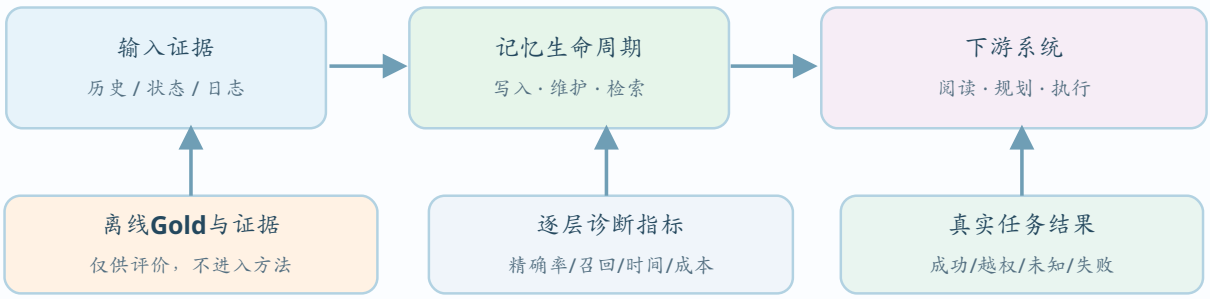


图15 · Agent Memory可靠性评价的整体地图

纵向阅读：上面是Agent真正执行的处理流程；下面是用于观察这个流程的证据和评价指标。记忆研究若希望形成可信的科学结论，需要同时回答“哪一个机制在何种条件下改善了什么指标”，以及“有什么不利证据和成本”。

理论验收清单

核查项	必须能够回答的问题
任务范围	评估历史问答、环境经验，还是最终工具行动?
数据与Gold	问题何时提出？证据来自谁？真值是否独立?
方法和可见信息	记忆写入时能不能看见未来问题或答案?
基线与控制变量	底座模型、历史、Token、工具和成本是否可比?
指标及分母	是Recall、答案准确、FAMA，还是环境成功?
负样本与缺失	是否计入弃答、时间更新、失败与基础设施异常?
效率与维持	是否计入写入、更新、检索和全生命周期成本?
统计与复现	样本独立单位、版本、评分器、随机重复是否说明?

表7 · 阅读一篇记忆评估论文时的最小核查表

完成本讲后，你应能拿到一篇新论文，先拆出它的任务和证据合同，再识别其Benchmark、强基线、测量指标与推断边界。这比记下一个“最新榜单排名”更具有可迁移的科研价值。

15 · 十二个常见误区：先诊断再纠正

01. Recall@5达到95%，所以记忆问答准确率也有95%。 不对。Recall衡量检索到Gold的程度；LLM仍可能误读、遗漏时序条件或执行错误。

02. 向量距离越近，历史事实越可信。 不对。相似度衡量表示接近，并不检验来源身份、事实真实性与生效范围。

03. 只要回答文本正确，就证明真正完成了任务。 不对。真实完成需工具回执、环境状态和成功判据，模型口头陈述不可替代。

04. 同一份日志被三个Agent引用，就是三份独立证据。 不对。应追踪原始来源和派生关系，避免伪独立证据。

05. 较新的记忆肯定覆盖较旧的一切记忆。 不对。项目、主体、适用范围、时间与授权级别必须匹配。

06. 应该删除所有旧事实，否则会造成记忆冲突。 不对。当前状态失效和历史证据归档是不同动作。

07. 一次只含Oracle证据的好成绩说明端到端方法已经可靠。 不对。这主要测试Gold可见条件下的阅读和推理，并不检验普通检索难度。

08. 所有QA分数都可以放到一个排行榜直接比较。 不对。数据、模型、上下文、任务、评分器、成本与版本不同时无直接可比性。

09. LLM评分器认为正确，就不存在评分误差。 不对。需核评分准则、偏差、人工一致性及无法确定情况。

10. 做更多调用就一定能够提高可靠性。 不对。无效检索可造成信息污染和更高延迟、费用，甚至提升越权风险。

11. 论文报告总体平均成绩即可，不必分析时间更新和弃答。 不对。高风险薄弱点常藏在少数能力子集和负例中。

12. 修复检索Bug后提升了总分，便证明全新的记忆算法有效。 不对。需区分工程修复、基线缺陷与真实机制增量。

16 · 十二道理论思考题与完整答案

建议先只看题目，尝试推理，再对照答案。这里的数字和案例都为教学构造，不需要编程或实验。

思考题 01 · 检索器在Top-5找回3条Gold中的2条，另外3条候选无关。Precision@5和Recall@5分别是多少?

答案与推导：Precision@5=2/5=40%；Recall@5=2/3≈66.7%。前者以返回5条为分母，后者以Gold共3条为分母。若3条Gold必须全部成立，这次整链召回仍失败。

思考题 02 · 一条测试需要E12、E26、E29三条证据；返回了E12和E26，还有重复的E12摘要。Any-hit@3和All-evidence@3分别如何判断?

答案与推导：Any-hit为命中，因为找到了至少一条Gold；All-evidence失败，因为E29缺失。重复摘要并不能代替独立证据。若以原始证据ID去重，只有2/3种必要证据被找回。

思考题 03 · 三道题首个Gold排名分别是第1、第2和第4。计算MRR。

答案与推导：MRR=(1+1/2+1/4)/3=1.75/3≈0.5833。它只考察第一个正确结果在排序中的位置，不能衡量所有必要证据是否齐全。

思考题 04 · 历史D04有AI提议，D12负责人暂停P，D26批准Q一次。D30问“P现在可收费吗”，检索到D04和D26是否足够?

答案与推导：不足够。D04只是AI提议，D26只适用Q项目，均不能构成P有效授权。应读取P项目最新权威状态D12；缺乏新的P授权时应回答不能。

思考题 05 · 什么情况应设计Gold答案为“无法确认”，这算不算失败样本?

答案与推导：当所有允许的原始资料均无支持某主张的证据时，应允许“无依据/无法确认”。这是有效的弃答测试，而不是失败样本。模型编造明确答案才应被记为错误。

思考题 06 · 18道有答案中15答对、2答错、1弃答；12道无答案中9正确弃答、3乱答。求正确弃答率和总体正确率。

答案与推导：正确弃答率=9/12=75%；总体正确率=(15+9)/30=80%。报告时还应单列有答案任务准确率15/18≈83.3%及错误弃答率。

思考题 07 · 给定条件成功率0.95、0.90、0.92、0.90，端到端成功概率是多少？要求说明独立性。

答案与推导：连乘=0.95×0.90×0.92×0.90=0.70794≈70.79%。若每个数字表示“在所有前置阶段正确条件下”的条件成功率，则依据概率链式法则相乘，无需假定独立；若只是无条件边际成功率则不能直接如此相乘。

思考题 08 · 为什么即使Oracle Gold证据输入时答对率90%，普通检索条件下只有70%，也不能直接说“检索算法存在20%的错误率”？

答案与推导：差20个百分点是两种整体输入协议下的表现差距；除证据是否找回外，还可能改变上下文长度、干扰量、证据排列和模型读取行为。定位检索错误率需直接检验Gold召回、下游条件成功与中介因素。

思考题 09 · 100道配对问题：两法都对60、A独对12、B独对19、都错9。求两法准确率与差值，并指出独立性风险。

答案与推导：A=(60+12)/100=72%；B=(60+19)/100=79%，相差+7个百分点；差异只来自12+19=31个配对不一致样本。若100题来自少量相同历史，还需以项目/用户为统计独立单位进行更合适的分析。

思考题 10 · 100轮任务中，无记忆每轮8000 Token；有记忆一次写入整理100000 Token、每轮2300 Token。比较总量。

答案与推导：无记忆800000；有记忆100000+2300×100=330000；节省470000 Token，占800000的58.75%。实际费用还需计入模型单价、输出Token、索引服务、维护、延迟。

思考题 11 · 为什么在现实项目中，Memora的过时记忆惩罚与LongMemEval的问答能力不能等同为一个指标?

答案与推导：两者任务与目标不同：前者强调持续更新/删除后不再引用无效记忆，后者考察跨会话提取、多会话推理、时间理解、更新和弃答。即使部分能力重叠，数据构造、问答协议与计分口径仍不同，必须按目标选择评价。

思考题 12 · 如果新增图记忆后准确率提升，同时也换了更强Embedding模型，能否证明图结构造成了提升？应怎样判断?

答案与推导：不能直接证明。两个设计变量同时改变，因果归因不清。理论上应在同样底座、同样历史、同样检索预算下控制变量，对比无图/有图与旧/新Embedding组合，检查具体关系多跳任务、质量、成本和失败样本；本课程当前只学习判断原则。

17 · 小结：从指标变成可重建的科研判断

这一讲最值得保留的不是某个公式，而是一种问题分解能力：先看历史中的事实是否可信，再看能否找回、能否按时间与范围正确利用，最后看真实任务有没有成功。评价时把数据与Gold、模型与控制器、成本与失效、作者原始结果和我们自己的推断分开。

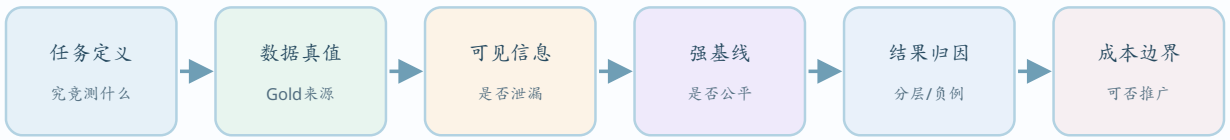


图16 · 下次读论文时的六步核对顺序

后续第32讲将把这套评估思想与开放科研问题结合起来，帮助你识别能够研究、可证伪、并有足够资源检验的智能体记忆机制。

参考文献与来源核查（截至2026年10月19日）

[1] Wu, D. et al. (ICLR 2025). LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[2] Maharana, A. et al. (ACL 2024). Evaluating Very Long-Term Conversational Memory of LLM Agents. https://aclanthology.org/2024.acl-long.747/

[3] Tan, H. et al. (Findings of ACL 2025). MemBench: Towards More Comprehensive Evaluation on the Memory of LLM-based Agents. https://aclanthology.org/2025.findings-acl.989/

[4] Wu, D. et al. (arXiv preprint, 2026). LongMemEval-V2: Evaluating Long-Term Agent Memory Toward Experienced Colleagues. https://arxiv.org/abs/2605.12493

[5] Uddin, M. N. et al. (Findings of ACL 2026). From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents. https://aclanthology.org/2026.findings-acl.1337/

[6] Wu et al. project team (Code/data; includes 2025 updated sessions). LongMemEval official dataset and README. https://github.com/xiaowu0162/LongMemEval

[7] Wu et al. project team (Code/data; 2026). LongMemEval-V2 official repository. https://github.com/xiaowu0162/LongMemEval-V2

[8] Es, S. et al. (EACL 2024 Demonstrations). RAGAs: Automated Evaluation of Retrieval Augmented Generation. https://aclanthology.org/2024.eacl-demo.16/

[9] Zheng, L. et al. (NeurIPS 2023, Datasets and Benchmarks). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. https://papers.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html

[10] Saad-Falcon, J. et al. (NAACL 2024). ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. https://aclanthology.org/2024.naacl-long.20/

[11] Snap Research (Repository). LoCoMo official code and data. https://github.com/snap-research/locomo

[12] Uddin et al. (Repository; ACL 2026). Memora benchmark official code/data. https://github.com/geniesinc/Memora