

第 12 讲：谁来主持讨论？

Leadership / Coordinator Selection / Information Bottleneck

固定同一团队，只改变“谁拥有最终权力”与“多少信息能进入决策节点”


本讲一句话目标：把第 11 讲选出的团队看成已经冻结的“专家组”。本讲不再改变成员，只研究协调层：Leader 身份与信息通道如何改变 collective outcome。

1. 从第 11 讲走到第 12 讲：团队选对了，还不等于系统就可靠

第 11 讲解决的是 WHO：谁应该进入这支临时团队。但一个多 Agent 系统真正运行时，还必须回答第三个问题：谁来汇总？谁先发言？谁拥有最终决定权？如果三名成员各自给出了判断，系统可以多数票，也可以让“最强成员”当 Leader，也可以让任务专家当 Leader，还可以增加一个外部 Coordinator。不同结构会改变信息流和权力结构，因此可能得到不同结果。

科研洞察：同一组三个成员的初始输出完全不变，只改变协调结构，结果仍可能变化。这说明系统性能不是成员能力的简单加和。

第12讲：同一团队，不同协调结构会得到不同系统结果



研究对象不再是“成员聪不聪明”，而是：谁拥有权力、信息如何流入决策节点。


图 1 Coordinator 同时是“权力节点”和“信息压缩节点”。

2. Coordinator 的底层本质：一个信息压缩器 + 决策器

Coordinator 往往看不到成员完整的内部状态。工程系统通常会把成员输出压缩成 verdict、短摘要、confidence、工具结果或结构化证据，再交给最终节点。这一步本身就是 information bottleneck（信息瓶颈）：原来分散在不同成员中的细节，可能在汇总之前就丢了。

- Verdict-only: Coordinator 只看到 VALID / INVALID。成本低，但几乎没有“为什么”。
- Compressed Summary: 每个成员只提供短摘要与置信度。比投票丰富，但细节仍可能被截断。
- Evidence Ledger: 显式保留支持 VALID、支持 INVALID、最强 dissent（异议）及其证据来源。

例子：假设 A、B 都投 INVALID，C 投 VALID。若 Coordinator 只看票数，C 的少数派信息几乎没有作用；但如果 C 恰好发现了一个决定性的工具返回值，Evidence Ledger 才有机会把这条证据保留下来。



Coordinator 的价值不是“再想一遍”，而是保留、比较并正确利用分布在不同成员中的证据。

图 2 压缩越强，越可能把“证据”压成“票数”。


3. Leadership Effect：为什么“平均最强”不一定适合当 Leader？

Leader 的特殊性不只在于它更强，而在于它拥有更高的 causal leverage：一次错误覆盖，可能把另外两名成员的正确信息全部抹掉。因此，Leader selection 不能只按全局排行榜。

Leader 规则	选择依据	可能优势	主要风险
Global-Strong	全局 calibration 平均最强	简单、稳定	任务错配；Leader 错时可能产生 harmful override

Leader 规则	选择依据	可能优势	主要风险
Task-Expert	当前 task family 最强	专业匹配	专家也可能过度自信；身份权重过高
Bridge Leader	与当前队友错误更互补	更可能吸收异质证据	自身平均能力未必最高
Cheapest	成本最低	省钱	不是可靠性导向，只应作为成本对照

同一组三个成员，只改变 Leader 身份



只有信息格式完全相同，才能把结果差异主要归因于 Leadership / Coordinator Identity。

图 3 做 Leadership 实验时，成员与信息格式必须保持完全相同。

4. 本讲为什么必须分成两个因子实验？

如果你同时把 Leader 从 A 换成 B，又把信息从 verdict-only 换成 full evidence，那么即使结果变好了，也不知道究竟是“B 更适合当 Leader”，还是“更多证据起了作用”。因此本讲拆成 A/B 两阶段。

阶段	固定什么	只改变什么	回答的问题
A: Leader Identity	同一团队；Named Full Evidence；相同最终权力	Global-Strong / Task-Expert / Bridge	谁来当 Leader 更合适？

阶段	固定什么	只改变什么	回答的问题
B: Information Channel	固定 Task-Expert Leader	Verdict-only / Compressed / Evidence Ledger	Coordinator 需要看到多少信息?
附加: Identity Control	固定完整 Ledger	Named Leader vs Anonymous External Coordinator	身份标签本身是否影响最终决策?

常见误区 / 风险: 这就是“控制变量”的最低闭环：一次只改一个结构变量。否则你得到的只是产品 A/B 测试，不是机制实验。

5. 五个必须看的指标：不能只看最终 Accuracy

- Final Error Rate: Coordinator 最终判断错误的比例。
- Override Rate: 最终结果与原始 majority 不同的比例。Override 本身不是好坏，关键看方向。
- Helpful Override: majority 原本错，Coordinator 改对。
- Harmful Override: majority 原本对，Coordinator 覆盖成错。
- Expert Suppression: Task-Expert 成员判断正确，但最终系统仍然错误。
- Leader Dependence: Leader 与另外两人意见相反时，系统有多大概率仍跟随 Leader。


科研洞察: 一个“很会覆盖多数票”的 Coordinator 可能看起来很主动，但如果 harmful override > helpful override，它实际上是在制造系统级错误。

6. Teaching Mock：同一团队，Coordinator 可以把系统带向完全不同结果

Teaching 条件	Error	Dangerous miss*	Helpful / Harmful override	额外成本(相对)
Anonymous Ledger	1.7%	2.2%	4 / 2	0.85
Evidence Ledger	2.5%	0.0%	2 / 1	0.85
Majority	3.3%	2.2%	0 / 0	0.00
TaskExpert	3.3%	2.2%	2 / 2	0.85

Teaching 条件	Error	Dangerous miss*	Helpful / Harmful override	额外成本(相对)
Compressed	3.3%	2.2%	0 / 0	0.55
Verdict-only	3.3%	4.4%	2 / 2	0.25
Bridge	4.2%	4.4%	1 / 2	0.85
GlobalStrong	5.8%	8.9%	0 / 3	0.85

* Dangerous miss rate 的分母是 human_label=INVALID 的样本，不是全部 120 条样本。



注意：这是受控合成教学数据，不是任何真实模型成绩。

图 4 受控 Teaching Mock，仅用于验证分析方法，不代表真实模型水平。

科研洞察：Teaching Mock 中 Global-Strong Leader 比多数票更差；Task-Expert 并没有自动优于多数票；保留完整 Evidence Ledger 后危险漏放下降。关键不是记住这些数字，而是理解：协调结构本身是一个可实验、可否决的系统变量。

7. 一个非常重要的反例：为什么“Leader 是家”仍然可能制家？

“专家被压制”听起来像只有弱 Leader 才会发生，其实不是。Task-Expert Leader 如果只看到别人的 verdict，而看不到证据来源，它也可能因为自己的先验、身份权重或过度自信而忽略正确异议。反过来，外部 Coordinator 如果只做机械多数票，同样可能把少数派专家淹没。

核心概念：信息结构决定了“专家知识能不能到达最终决策点”。团队里存在正确专家 $\neq$ 系统最终会使用正确专家。

8. 与 2026 年研究前沿的连接：把它们当作线索，不当作我们的结论

研究	公开结论与本讲关系
LASE, ICML 2026	使用 leader-supporter 非对称结构，说明 Leader 不是必然有害；关键是何时启用、信息如何定向流动。
Multi-Agent Teams Hold Experts Back, ICML 2026	自组织 LLM 团队经常无法达到最强专家的表现，即使明确告诉团队谁是专家。直接提示我们研究 expert suppression。
When Identity Skews Debate, ACL 2026	发现 identity-driven sycophancy / self-bias，并用 anonymization 降低身份偏置。支持把 “Named vs Anonymous” 作为控制条件。
Beyond Majority Voting, ICML 2026	指出简单多数票忽略模型异质性与相关性，并利用更高阶信息改进 aggregation。说明 Coordinator 不应只把 3 个判断当独立同质票。

参考链接：

<https://proceedings.mlr.press/v306/yoa26a.html>
<https://proceedings.mlr.press/v306/pappu26a.html>
<https://aclanthology.org/2026.acl-long.650/>
<https://proceedings.mlr.press/v306/ai26d.html>

9. 真实实验：为什么先冻结成员，再只调用 Coordinator？

如果为了测试 7 种 Coordinator 条件，每次都重新让 3 个成员生成答案，那么成员本身的随机性会进入实验。最省钱、也最干净的做法是：先冻结第 11 讲已经产生的 team outputs，再只重放 Coordinator 层。这样既省 API，又把因果干预限定在协调层。

```
python src/01_prepare_from_all.py --all-root ../All --out data/coordinator_inputs.csv
python src/03_run_coordinator_experiment.py --inputs data/coordinator_inputs.csv --config
configs/a12_coordinator.example.json --out outputs/real/coordinator_judgments.csv --limit 8
python src/04_analyze_coordination.py --inputs data/coordinator_inputs.csv --judgments
outputs/real/coordinator_judgments.csv --out-dir outputs/real/analysis
```

注意：先 --limit 8 做 smoke test。确认模型映射、输出 JSON、成本记录都正确，再扩大到正式 pilot。

10. 常见误区

- 误区 1：把“Leader 模型更强”当成“Leader 结构更好”。模型能力与结构效果必须分开。
- 误区 2：用 human_label / gold answer 写进 Coordinator prompt。这样会发生 benchmark leakage。
- 误区 3：只比较最后准确率，不统计 harmful override。Coordinator 可能是在用少量修正换来更多新错误。
- 误区 4：Evidence Ledger 写得越长越好。长并不等于信息保真，还要看真正关键证据是否保留。
- 误区 5：在 test split 上反复调 Leader 规则。Leader selection 只能用 calibration 数据定好，再一次性评估 test。

本讲最低闭环能力：最低闭环：冻结团队 → calibration 上定义 Leader 规则 → 同一批 test case 做配对 Coordinator 对照 → 统计 helpful/harmful override → 精读 harmful override Trace → 才提出下一条机制假设。

11. 下一讲预告：权力之外，还有“记忆”和长期经历

第 12 讲研究的是短时协调结构。接下来可以把时间轴拉长：同一个 Agent 经历不同历史以后，会不会形成长期功能性异质性？如果这些经历改变了它们的错误结构，系统是否能获得更持久的 error decorrelation？这将把课程从静态团队结构正式推进到 persistent agents 与 experience-induced heterogeneity。