

# 第 13 讲：不同长期经历会不会塑造不同的 Agent ？

## Persistent Agents / Experience-Induced Heterogeneity

冻结模型、Prompt、Tool 与 Role，只允许“过去经历”不同，第一次直接检验 Experience Divergence → Functional Heterogeneity → Error Decorrelation → Collective Gain

**本讲一句话目标：**本讲不是人为给三个 Agent 不同 persona，也不是换三个模型。三个 Agent 的基础配置完全一样；唯一允许长期积累并产生差异的变量，是它们经历过的历史 episode 与由此形成的 memory bank。

### 1. 为什么第 13 讲是一个转折：从“预设异质性”走向“形成异质性”

前几讲中的 Model Diversity、Role Diversity、Evidence Diversity，大多是在实验开始前由研究者直接指定差异。第 13 讲把时间轴拉长：如果三个初始完全相同的 Agent 长期经历不同任务，它们是否会逐渐形成不同的功能倾向、不同的错误模式，甚至不同的专长？这类差异如果真实存在，就更接近“经验塑造出的异质性”。

| 来源          | 如何产生差异                                  | 第13讲处理方式 |
|-------------|-----------------------------------------|----------|
| 模型异质性       | 换 backbone / family<br>预设异质性 ≠ 经验形成的异质性 | 不是本讲主变量  |
| Persona 异质性 | 不同人设 / 性格                               | 不是本讲主变量  |
| Role 异质性    | 不同系统职责                                  | 不是本讲主变量  |
| Tool 异质性    | 不同工具权限                                  | 不是本讲主变量  |
| 经历异质性       | 过去交互历史不同                                | 本讲唯一允许变化 |

图 1 本讲必须严格排除 model/persona/role/tool 异质性，否则不能把结果归因到 experience。

**科研洞察：**真正的问题不是“有记忆是否更强”，而是“不同经历是否让原本相同的 Agent 变得功能上不同”。这是两个完全不同的研究问题。

2. 最小 Persistent Agent：不用训练参数，也能长期“带着经历走”

本讲采用最小化定义：Persistent Agent = 固定的基础 LLM + 固定系统提示 + 固定工具/角色 + 一个跨 episode 保留的 Experience Bank。每完成一个 episode，系统把可复用经验写入 bank；遇到新任务时，再检索少量相关经验注入上下文。这里不做模型微调，目的是把“经验效应”隔离在外部 memory 层。

Experience Divergence → Persistent Functional Heterogeneity: 最小因果链




图2 三个 Agent 从同一初始状态出发，仅长期经历流不同。

一个 Experience Card 至少包含：历史情境、关键 evidence、当时采取/拟采取的动作、最终 outcome、以及一句可复用 lesson。注意：memory 不是“事实数据库”，而是带有历史噪声、选择偏差和错误风险的经验池。

3. Experience Divergence 的实验定义：差异必须来自历史，而不是身份标签


| 变量                      | 三个 Agent 是否相同 | 第 13 讲做法                                       |
|-------------------------|---------------|------------------------------------------------|
| Base model              | 相同            | 同一个模型标识、同 reasoning 参数                         |
| System prompt / role    | 相同            | 不写“你是 Policy 专家”之类身份标签                         |
| Tools / permissions     | 相同            | 相同工具集合、相同 policy                               |
| Memory capacity / top-k | 相同            | 每人经验数量、检索条数匹配                                  |
| Experience stream       | 不同            | P 主要经历 policy；E 主要经历 evidence；R 主要经历 parameter |

常见误区 / 风险：如果你直接把 Agent P 的 prompt 写成“你是 Policy Specialist”，那得到的是

4. 四个条件：怎样把“记忆增益”和“经历分化”拆开？

| 条件                      | 长期经验         | 三人是否相同   | 回答的问题                               |
|-------------------------|--------------|----------|-------------------------------------|
| C0 No Memory            | 无            | 完全相同     | 基础参考：没有长期经历时，群体是什么样？                |
| C1 Shared Memory        | 有；三人拿同一份混合经验 | 相同       | 记忆本身是否提升单体，但仍保持相似错误？                |
| C2 Divergent Experience | 有；三人长期经历流不同  | 不同历史     | 不同经历是否形成专业化、错误去相关与 collective gain？ |
| C3 Memory-Off           | 身份保留，但关闭检索   | 当前行为再次同质 | C2 的差异关闭 memory 后是否消失？——因果必要对照      |

第13讲的关键不是“加记忆”，而是用对照把 experience 的因果作用隔离出来



如果 C2 出现专业化/去相关，而 C3 又回到 C0 附近：才更像 experience-induced effect

图 3 Memory-Off 是因果隔离的关键，不是可有可无的“附加消融”。

5. “功能性异质性”到底怎么测？不能只看输出文本像不像

- 专业化矩阵（Specialization Matrix）：每个 Agent 在 policy/evidence/parameter 三类 held-out case 上分别多强。

- 行为分歧 (Verdict Disagreement)：相同输入下，不同 Agent 是否做出不同决策。它只能说明“不同”，不能说明“有用”。
- 错误相关 (Pairwise Error  $\phi$  / Double-Fault)：关键是它们是否在同一 case 上一起错。
- Collective Gain：多数票或其他固定聚合器的错误率，是否低于平均单成员错误率。
- Memory Dependence：同一 Agent 在 Memory-On 与 Memory-Off 时有多少判断发生变化；并区分 helpful flip 与 harmful flip。

**核心概念：**如果 C2 的三人答案更不一样，但多数票更差，那只是“噪声多样性”；只有个体能力仍可接受、错误互补且聚合后更可靠，才是有用的 functional heterogeneity。

## 6. Teaching Mock：为什么“平均单成员一样强”还可能产生完全不同的 collective outcome？

| Teaching 条件          | 平均成员错误 | 平均 pairwise $\phi$ | 多数票错误 | Collective gain |
|----------------------|--------|--------------------|-------|-----------------|
| No Memory            | 22.5%  | 0.078              | 14.2% | 8.3 pp          |
| Shared Memory        | 15.3%  | 0.263              | 10.0% | 5.3 pp          |
| Divergent Experience | 14.7%  | -0.034             | 3.3%  | 11.4 pp         |
| Memory-Off           | 22.5%  | 0.078              | 14.2% | 8.3 pp          |




图 4 Teaching Mock: Shared 与 Divergent 的平均成员能力接近，但错误结构不同，群体结果也不同。

**注意：**这些数值全部是受控合成数据，不是任何真实商业模型成绩。它只验证分析流水线，并帮助你建立“成员能力”和“错误结构”必须分开看的直觉。

## 7. 一个必须警惕的副作用：经验可能让 Agent 变得“有偏见”，不一定变得更聪明

长期经验会带来两面性。一方面，相似历史可以提供可复用策略；另一方面，Agent 也可能过度复现历史路径，把过去的错误继续传播到未来任务。尤其当 memory retrieval 找到的是“看起来很像、其实关键约束不同”的 episode 时，会发生 negative transfer。

**常见误区 / 风险：**Experience-induced specialization 不应被自动解释成能力提升。它也可能是经验诱导出的系统性偏差。科研上必须同时报告 specialty gain、off-specialty degradation 和 harmful memory flips。

## 8. 2026 研究前沿给了我们哪些“零件”，但还没有替我们证明整条链？

| 研究                                     | 已支持的事实                                                                                        | 与本讲关系                                           |
|----------------------------------------|-----------------------------------------------------------------------------------------------|-------------------------------------------------|
| Xiong et al., ACL 2026                 | 发现 experience-following；相似输入与检索经验会诱导相似执行，并可能产生 error propagation / misaligned replay。         | 说明经验确实可以持续改变行为，但也会放大历史噪声。                       |
| Zhao et al., ICML 2026                 | 用因果干预研究 experience faithfulness；发现 raw experience 依赖较强，而 condensed experience 常被忽略或误用。        | 提醒我们不能只“把经验塞进去”，必须验证 Agent 真正依赖这些经验。            |
| Hu et al., 2026 preprint               | 将 continual-learning 瓶颈重新定位到 memory representation / retrieval；报告 negative transfer 尤其伤害困难样本。 | 说明长期经验不是免费能力，会形成新的稳定性-可塑性问题。                    |
| LifeMem, Sep 2026 preprint             | 在多环境 lifelong setting 中聚类轨迹、提取 reusable skills，并研究 task stream 对学习的影响。                        | 说明“经历顺序/结构”本身值得成为实验变量。                          |
| Intrinsic Memory Agents, 2025 preprint | 用 agent-specific structured contextual memory 保持不同专业视角。                                       | 与“memory 产生异质性”接近，但本讲更强调同初始 Agent 由不同经历流自然形成差异。 |

参考：

<https://aclanthology.org/2026.acl-long.27/>

<https://proceedings.mlr.press/v306/zhao26aw.html>

<https://arxiv.org/abs/2604.27003>

<https://arxiv.org/abs/2609.12655>

<https://arxiv.org/abs/2508.08997>

**科研洞察：**截至 2026-10-01，这些工作已经分别研究了记忆、经验复用、持续学习和异质 memory，但“不同长期经历 → 功能性异质性 → 错误去相关 → collective gain”整条因果链仍应被当作研究假设，而不是已知定律。

## 9. 真实 Pilot：先用 Reviewer 子系统做最小闭环，不急着搭完整长期 Agent 社会

为了把变量控制干净，本讲先沿用前面 WRITE-reviewer sandbox。真实 pilot 可以直接从第 7 讲 fixed proposals 中抽一半作为“过去经历”，另一半作为 held-out evaluation。然后三个 Agent 使用同一模型与 prompt，只改变各自 experience bank。

```
python src/01_prepare_from_a07.py --a07-root /path/to/A07 --out-dir data/real
python src/02_build_experience_streams.py --experience-pool data/real/experience_pool.jsonl --out-dir data/real/banks
python src/05_run_persistent_agents.py --eval-cases data/real/eval_cases.jsonl --banks-dir data/real/banks --config configs/a13_persistent_agent.local.json --condition no_memory --out outputs/real/no_memory.csv --limit 6
python src/05_run_persistent_agents.py ... --condition shared ...
python src/05_run_persistent_agents.py ... --condition divergent ...
```

**注意：**先跑每种条件 6 个 held-out case 做 smoke test。确认 human\_label 没有进入 prompt、三个 Agent 的 model/prompt/tool/role 完全相同，再扩大样本。

## 10. 常见误区与否决标准

- 误区 1：把三种不同 Persona 当作“经历形成的异质性”。直接否决。
- 误区 2：三个 Agent 的经验数量不同，最后却把差异归因到 experience content。必须匹配 memory budget。
- 误区 3：只看总体 accuracy，不做 family-level specialization matrix。这样看不出“功能分化”。
- 误区 4：C2 比 C1 好，就直接说“经验导致”。还必须做 Memory-Off / paired ablation。
- 误区 5：经历中包含错误却不追踪 negative transfer。长期系统最危险的往往不是一次错，而是错误被写进 memory 后反复复用。

- 否决标准：如果 C2 与 C1 的 specialization/error-correlation 没有稳定差异，或 Memory-Off 后差异仍存在，就不能声称 experience-induced heterogeneity。

**本讲最低闭环能力：**最低闭环能力：冻结同一 Agent → 构造不同历史流 → 持久化 memory → held-out 测专业化 → 测错误相关 → Memory-Off 做因果回退 → 最后才讨论 collective gain。

## 11. 下一讲预告：Experience Divergence 需要“多久”才会形成？

第 13 讲只回答“不同经历能不能形成差异”。第 14 讲可以沿时间轴继续追踪 0→5→10→20→40 个 episode：功能性异质性是逐渐增长、很快饱和，还是会发生 specialization collapse / forgetting？这会把静态终点比较推进成真正的长期动力学。