

第 14 讲：异质性是怎样长出来的？

Longitudinal Formation of Functional Heterogeneity

0 → 5 → 10 → 20 → 40 episodes：同时观察 specialization、error correlation、collective gain、forgetting 与 negative transfer

本讲一句话目标：第 13 讲只比较“最终是否出现经验异质性”；第 14 讲把时间轴展开，研究它在第几个 checkpoint 开始出现、何时产生集体收益、以及经验继续累积后是否反而出现干扰。

第14讲核心：研究“异质性如何形成”，而不只比较最终状态




图1 本讲从“终点比较”升级为“形成过程”：时间本身成为实验变量。

1. 为什么只比较“训练前 vs 训练后”是不够的？

如果只看 checkpoint 0 和 checkpoint 40，你会错过三个最有科学价值的问题：异质性何时开始出现？错误去相关是否先于集体收益？继续积累经验后，性能是否出现平台、反转或遗忘？

- 形成时间（onset）：5 个 episode 就出现专业化，还是要到 20 个以后才稳定？
- 顺序关系（temporal ordering）：先 specialization，还是先 error decorrelation？两者谁更可能是中介机制？
- 非单调性（non-monotonicity）：更多经验是否始终更好，还是存在 sweet spot？
- 长期副作用：retrieval interference、negative transfer、error propagation、forgetting 是否在大 memory bank 中增加？

科研洞察：“最终不同”只是结果；“怎样逐步变得不同”才开始接近机制科学。纵向 checkpoint 能把一张静态照片变成一段系统演化轨迹。

2. 最小纵向实验：只让 Experience Dose 随时间变化

三个 Persistent Agent 仍然从完全相同的模型、Prompt、Tool、Role 和检索配置出发。我们只增加 cumulative experience bank，并在固定 checkpoint 暂停系统、对同一套 held-out evaluation 重新测量。

变量	固定 / 改变	第 14 讲做法
Base model / version	固定	三个 Agent 完全相同
System prompt / role / tools	固定	禁止写“专家身份”提示

Retrieval top-k / temperature	固定	所有 checkpoint 相同
Held-out evaluation	固定	每个 checkpoint 都测同一批 case
Experience count	主变量	0 / 5 / 10 / 20 / 40
Experience content	对照变量	Shared vs Divergent

Shared Memory 条件让三人获得等量、相同分布的经验；Divergent Experience 条件让 P/E/R 三人分别长期接触 policy/evidence/parameter-heavy 流。这样可以把“经验数量增加”与“经历分化”分开。

关键原则：checkpoint 必须是 cumulative：20 = 前 10 个经验 + 新增 10 个，而不是重新抽 20 个完全不同的样本。否则你测到的是 sample replacement，不是 longitudinal learning。

3. 五条动力学曲线：不要只盯 Accuracy

3.1 Specialization Index：功能差异什么时候真正出现？

对 Agent a 定义一个简单的课程诊断量：

$$SI_a(t) = Accuracy_{own-family}(t) - Mean\ Accuracy_{other-families}(t)$$

SI 接近 0：该 Agent 还没有稳定的 family-level 专业化；SI 持续为正：它在长期经历对应领域形成了相对优势。注意：SI 只是 operational measure，不等于“内部产生了某个神经机制”。




图2 Teaching Mock: Divergent Experience 的 specialization 随 episode 累积逐渐形成；虚线只是课程诊断阈值。

3.2 Error Correlation 与 Collective Gain：异质性有没有系统价值？

专业化本身不够。真正重要的是：三个人是否开始在不同 case 上犯错。继续沿用前几讲的 pairwise error ϕ ，并固定 majority aggregation。

$$Collective\ Gain(t) = Mean\ Member\ Error(t) - Majority\ Error(t)$$

如果 SI 上升、 ϕ 下降、而固定 majority error 同时下降，这才是“功能性异质性可能转化为 collective gain”的证据链。




图3 Teaching Mock：checkpoint 20 附近去相关与多数票收益最明显；继续积累到 40 后，收益可能回落。

4. Teaching Mock：为什么 checkpoint 20 比 checkpoint 40 更值得研究？

下面全部是人为构造的合成数据，只用于验证分析流程。它故意设计成“异质性逐步形成，但更多经验并不单调更好”。

条件	Checkpoint	平均成员错误	平均 ϕ	Specialization	Majority 错误
Divergent	0	25.0%	0.067	-0.025	16.7%
Divergent	5	20.7%	0.089	0.028	13.9%
Divergent	10	14.1%	-0.011	0.053	3.9%
Divergent	20	11.5%	-0.094	0.131	1.1%
Divergent	40	18.7%	-0.009	0.197	8.9%
Memory-Off @40	40	25.0%	0.067	-0.025	16.7%

怎么读这个表：20 个 episode 时三人已经形成明显专业化、错误位置更互补、majority error 最低；到了 40，SI 继续上升，但总体成员错误和 majority error 反而变差。说明“更专业”与“系统更可靠”不是同义词。

本讲把“首次出现”定义为一个教学 operational criterion：SI ≥ 0.08 、相对 Shared condition 的 ϕ 至少下降 0.05、且 majority error 更低。Teaching Mock 第一次同时满足三条是在 checkpoint 20。这个阈值只用于练习，不是论文可直接照搬的科学定律。

5. 为什么更多经验会变差？四种候选机制

- Memory saturation / retrieval competition：bank 变大后，与当前任务真正相关的 experience 更难进入 top-k。
- Negative transfer：某一类长期经验形成了过强先验，迁移到别的 family 时反而做错。
- Forgetting：早期有用经验被新记录挤出检索，或者被后来的错误/噪声覆盖。
- Error propagation：早期错误 episode 被长期保留并在相似任务中不断 replay。




图 4 Teaching Mock: checkpoint 40 中部分 Agent 出现 retention drop 或 off-family negative transfer。

不要犯的因果错误：“checkpoint 40 更差”不能直接写成“memory saturation 导致性能下降”。它只是一个现象。要继续通过 retrieval log、删除/替换干预、固定 top-k、Memory-Off 等实验区分机制。

6. Memory-Off 与 Experience Faithfulness：变化真的是 memory 造成的吗？

第 13 讲已经建立 Memory-On / Memory-Off 的 paired intervention。第 14 讲把它放在纵向终点：同一个 checkpoint-40 Agent，在保持模型、Prompt、case 不变时关闭 experience retrieval。如果行为系统性回退，就说明历史经验至少对当前决策有因果依赖。

现象	能说明什么	不能说明什么
On/Off 判断发生变化	memory 对行为有 dependence	memory 一定有益
Off 后回到 checkpoint-0 模式	支持经验造成长期行为改变	内部机制已完全解释
On 比 Off 更准	支持 helpful memory use	所有检索 experience 都正确
On 比 Off 更差	可能存在 harmful replay / interference	必然是 memory size 太大

这也是为什么当前关于 self-evolving agents 的研究强调 experience faithfulness：把 experience 放进上下文并不等于 Agent 真正依赖了它；必须做 intervention。

7. 与当前研究的连接：LifeMem 告诉我们什么，没告诉我们什么？

2026 年 9 月发布的 LifeMem 研究 lifelong experience reuse，并报告 task streaming 会影响学习、经验持续累积会面临 forgetting，而把结构相似 trajectory 做 consolidation 能改善长期复用。它支持“经验顺序与组织方式值得研究”，但它并没有直接回答本讲的三 Agent 链条：不同长期经历是否形成错误去相关并产生 collective gain。

ACL 2026 的 experience-following 研究表明，检索到相似历史记录时 Agent 当前行为会更像过去执行，同时存在 error propagation 与 misaligned replay；ICML 2026 的 experience-faithfulness 研究则说明，raw experience 与 condensed experience 对行为的因果影响并不相同。第 14 讲把这些 memory-level 现象进一步连接到 multi-agent error structure。

可能的科研价值：如果真实实验能稳定复现“experience dose → specialization onset → error decorrelation → collective gain”，并找到 20→40 反转的边界条件，这比单纯提出一个新 memory 模块更接近可积累的 AI Systems Science 机制研究。

8. 真实实验的最低闭环：先别一上来跑 40×3×大量 case

- Step 1: 先用第 13 讲已有的 10 条/family experience stream 跑 0/5/10 三个 checkpoint，验证日志和 metric pipeline。
- Step 2: 只为一个 Agent 收集到 20/40 episode，检查 retrieval 与 memory growth 是否可运行，再扩到三人。
- Step 3: 正式实验必须固定 held-out case、模型版本、prompt hash、retrieval config；每个 checkpoint 保存 memory snapshot。
- Step 4: 对最关键的 10→20 与 20→40 变化做 Trace Review，而不是只画折线。
- Step 5: 如果 20→40 明显反转，再设计 memory-size / retrieval-top-k / consolidation ablation，寻找机制。

对于个人研究者，这种 staged design 很重要：先证明曲线值得研究，再投入 API 费用。你不需要一开始就构造“无限寿命 Agent”。

9. 常见误区

- 把 checkpoint 间换掉的 evaluation sample 当成“成长曲线”——这是数据集差异，不是时间效应。
- 只看最终 accuracy，不看 SI、 ϕ 、majority、retention——会把系统机制压成一个分数。
- 40 比 20 差就直接宣称 catastrophic forgetting——需要 retention probe 与干预证据。
- 让三个 Agent 在不同 checkpoint 使用不同模型版本——时间变量被模型升级污染。
- 为了做满 40 个 episode 而重复同一经验——那是 replay count，不是 experience diversity。

10. 本讲最低闭环能力

你学完后应该能做到：拿一组 Persistent Agents，在 0/5/10/20/40 checkpoint 冻结状态并重复评测；画出 specialization、error correlation、collective gain 三条关键曲线；发现非单调变化时，用 retention / transfer / Memory-Off 区分“成长”与“长期副作用”。

11. 近期参考资料

- Xiong et al., 2026, How Memory Management Impacts LLM Agents: An Empirical Study of Experience-Following Behavior, ACL 2026.

- Zhao et al., 2026, Large Language Model Agents Are Not Always Faithful Self-Evolvers, ICML 2026.
- Qiu et al., 2026, LifeMem: Enabling Lifelong Experience Reuse for LLM Agents, arXiv:2609.12655.
- Luo et al., 2026, From Storage to Experience: A Survey on the Evolution of LLM Agent Memory Mechanisms, Findings of ACL 2026.
- Su et al., 2026, Mistake Notebook Learning: Batch-Clustered Failures for Training-Free Agent Adaptation, Findings of ACL 2026.