

第 19 讲：把机制链做成论文——Experience Divergence → Error Decorrelation → Collective Gain

Paper-Grade Mechanism Chain · Controlled Experiments · Pre-Registered Decision Gates

本讲唯一目标 把第 13-18 讲压缩成一个“第一篇论文能真正完成”的核心实验。不是继续堆模块，而是删掉不必要变量，只留下能证明或否证主机制链的实验。

1. 为什么第 19 讲必须“收缩”，而不是继续扩展

前六讲已经积累了很多系统变量：长期经验、共享、治理、污染、修复、自愈。论文最常见的失败不是实验太少，而是一次想证明太多。第一篇机制论文应只回答一个核心问题：不同经历是否能让相同 Agent 形成有用的功能性异质性，并通过错误去相关产生集体收益？

- 主链只有四个节点：Experience Divergence → Functional Heterogeneity → Error Decorrelation → Collective Gain。
- 第 15-18 讲的 sharing / governance / contamination / repair 在第一篇论文中主要作为边界条件、讨论或后续工作，不全部塞进主实验。
- 论文贡献应是“发现并验证机制”，不是“造一个复杂大系统”。

第19讲主论文机制链：先证明链条，再讨论边界




图1：第 19 讲主论文机制链。

2. Research Question 与可证伪假设

层级	问题/假设	如果不成立会看到什么
RQ1	不同长期经历能否在相同初始 Agent 上形成可测的功能性异质性？	不同 family 上性能差异接近 0，或差异不随 experience bank 交换而移动。
H1	Divergent Experience 的 Specialization Index > Shared Experience。	C2 和 C1 specialization 无差异。
H2	功能性异质性伴随较低的 pairwise error ϕ / double-fault。	单体能力变化，但错误位置仍高度同步。
H3	在成员平均能力相近时，更低的 error correlation 带来更高 collective gain。	ϕ 降了但 majority/oracle coverage 无收益。

H4	Memory-Off 后 C2 的 specialization / decorrelation 显著回退。	关闭 retrieval 后现象仍存在，说明不是 memory 驱动。
H5	Memory-Swap 后 specialization 跟随 experience bank 而非 Agent identity。	换 bank 后原 Agent 仍保持原专长。

3. 六个条件：为什么每一个都有用

Paper-Grade Condition Matrix		
C0	No Memory	基线：没有长期经验
C1	Shared Experience	控制 memory amount；三人看到同一 experience
C2	Divergent Experience	核心处理：等量但不同经历
C3	Memory-Off	同一 C2 agent，关闭 retrieval
C4	Memory-Swap	交换 experience bank；专业化应跟随 bank
C5	Full-Share Boundary	在 C2 后全量共享，测试 re-coupling

必须先看 manipulation check，再看 specialization，再看 Φ ，最后看 collective gain。

图2：论文级条件矩阵。C0-C4 构成核心因果检查，C5 是边界条件。

Condition	改变什么	主要回答什么	优先级
C0 No Memory	无长期 experience	原始同质 Agent 的基线	必须
C1 Shared Experience	三人等量且相同 memory	控制“有 memory”本身的收益	必须
C2 Divergent Experience	三人等量、内容不同	核心处理：experience divergence	必须
C3 Memory-Off	C2 身份不变但关闭 retrieval	确认行为差异依赖 memory	必须
C4 Memory-Swap	交换三人的 experience bank	检查 specialization 是否跟随 bank	强烈建议
C5 Full-Share Boundary	C2 后把经验全量共享	测试 heterogeneity collapse / error re-coupling	预算允许再做

4. 证据必须按顺序建立：不要只报最终分数

Evidence Ladder：论文的“链”必须一层一层站住




图3：论文证据阶梯。任何一层站不住，都不能直接跳到“Collective Intelligence”。

- 1. 第一层：Manipulation Check。确认 memory 真正被检索/使用；C2 vs C3 和 Memory-Swap 是关键。
- 2. 第二层：Functional Heterogeneity。看 Agent × Task Family 的 error matrix，而不是只看全局平均。
- 3. 第三层：Error Decorrelation。计算 pairwise ϕ 、double-fault、错误集合 Jaccard。
- 4. 第四层：Collective Gain。固定 aggregation 规则，看 majority error、oracle coverage、collective gain。
- 5. 第五层：Boundary / Falsification。Full sharing 是否让 specialization 下降、 ϕ 回升？是否存在完全不受 experience 影响的任？

5. 三个核心指标，用通俗语言理解

5.1 Specialization Index

对 Agent P 来说：SI = 它在 policy family 的准确率 - 它在其他 family 的平均准确率。SI > 0 表示形成了功能性偏向；但 SI 太大也可能意味着过度专业化与负迁移。

5.2 Error Correlation ϕ

两个 Agent 都有 80% 准确率，并不能说明它们组合后有价值。如果它们每次都在同一个 20% 上一起错，团队没有获得互补性。 ϕ 衡量“错误是否一起发生”。

5.3 Collective Gain

最简单定义：平均单成员错误率 - Majority 错误率。它不是为了证明“多 Agent 一定强”，而是测量当前错误结构能否被固定聚合规则利用。

6. 资源受限研究者怎样把实验缩到可完成

阶段	规模建议	目的	停止规则
Smoke	6-10 held-out tasks × 3 agents × C0-C3 × 1 trial	检查代码、memory retrieval、日志完整性	任何数据链异常先修，不看“显著性”
Pilot	10 tasks × 3 agents × C0-C4 × 2 trials	看主链方向是否存在	Manipulation / SI / ϕ / gain 至少方向一致，否则不放大
Confirmatory	约 30 tasks × 3 agents × C0-C4 × 2 trials	主论文核心结果	按注指和 bootstrap CI 报告

Boundary	C5 + 第二模型/第二域少量复核	检查可迁移边界	预算不足可以进 appendix / future work
----------	-------------------	---------	--------------------------------

预算逻辑 如果 Confirmatory 采用 30 tasks、2 trials、3 agents、5 个核心条件，大约是 900 条 agent trajectories；真正费用仍取决于模型、user simulator、平均对话长度与重试，因此必须先用 Pilot 实测每条轨迹成本，再决定是否扩大。

7. 统计：第一篇论文需要什么，不需要什么

- 主结果优先使用 paired bootstrap 95% CI，因为条件共享同一批 case。
- Majority outcome 的条件比较可以做 paired / exact test，但不要只盯 p-value；同时报告 effect size 和置信区间。
- Specialization 与 ϕ 应报告 task-family / agent-level 分布，不只给一个平均数。
- “ ϕ 降低导致 collective gain”不能仅凭一次相关分析写成 causal mediation。更稳妥的措辞是：受控 condition manipulation 改变了 heterogeneity/error structure，并与 aggregation gain 同步变化；Memory-Off/Swap 提供额外因果证据。
- 如果某个条件只提高单体准确率、但不改变 ϕ ，也要如实报告：这是能力提升，不是 error decorrelation。

8. Teaching Mock：我们希望分析管线能识别什么




图4：Teaching Mock 的证据模式。这里只验证分析管线，不代表任何真实模型。

Condition	Member Err	SI	ϕ	Majority Err	Gain
no_memory	0.143	-0.019	0.292	0.122	0.020
shared_experience	0.085	0.019	0.476	0.089	-0.004
divergent_experience	0.111	0.133	0.024	0.033	0.078
divergent_memory_off	0.143	-0.019	0.292	0.122	0.020
memory_swap	0.113	-0.097	0.043	0.039	0.074
full_share_boundary	0.080	0.028	0.445	0.072	0.007

Teaching Mock 不是结果 它只是用合成数据检查：如果真实实验未来出现同类结构，我们的代码是否能正确提取 specialization、error correlation、collective gain 和 memory-swap manipulation check。

9. 哪些结果会让我们否决这篇论文故事

- C2 与 C1 的 specialization 基本相同：不同经历没有形成稳定功能差异。
- C2 的 ϕ 并未低于 Shared Experience：即使专业化存在，也没有产生错误互补。
- C2 的 collective gain 不优于 C1：错误去相关没有转化成系统收益。
- Memory-Off 不回退：长期 experience 不是主要因果来源。
- Memory-Swap 后专长仍跟着 Agent identity，而不是 experience bank：说明存在隐藏身份/seed/config confound。
- 结果只在极少数 cherry-picked case 上出现，整体或跨 trial 不稳定。

10. 本讲最低闭环能力

最低闭环 你不需要现在能写复杂理论。只要能做到：固定变量 → 构造 experience 条件 → 跑相同 held-out tasks → 生成 Agent×Family matrix → 算 ϕ → 算 majority → 做 Memory-Off/Swap → 根据预注册 Gate 决定“继续/否决”，就已经具备第一篇机制论文的核心实验能力。