

第 31 讲：Agent 的随机性与重复实验

目标：让你能够把“跑一次看到一个数字”升级为“用重复实验与不确定性评估 Agent 系统”。

● **核心结论：** Agent 是随机、环境会波动、任务有难度差异，所以“只跑一次”几乎不能支撑可靠科研结论。

1. 为什么同一个 Agent 每次结果可能不一样？

原因通常不是一个：模型采样可能随机；工具或网络返回可能变化；检索结果、并发时序、任务状态也可能变化。即使你把 temperature 设得很低，外部系统仍可能带来非确定性。

● **常见误区：**“我固定了 random seed，所以整个真实 Agent 系统一定可完全复现。”错误。Seed 只能控制你真正能控制的伪随机源；远程模型服务、搜索结果、网络、并发时序和外部数据仍可能变化。




图 1：每批只有 10 次运行时，观测成功率会明显波动。

2. “跑 10 次成功 7 次”到底意味着什么？

最直接的事实只有：这 10 次样本里有 7 次成功，样本成功率是 0.70。它不等于“这个 Agent 的真实成功概率精确等于 70%”，更不等于“换一批任务仍然一定是 70%”。

● **科研洞察：** 报告一个比例时，至少同时报告 n。70% (7/10) 和 70% (700/1000) 看起来一样，但证据强度完全不同。




图 2：样本量增大后，不同实验批次之间的成功率波动通常变小。

3. Random Seed：它能做什么，不能做什么？

随机种子用于初始化伪随机数生成器。同一个程序、同一算法、同一 seed，通常可以产生相同的伪随机序列。这使受控实验更容易复查。




图 3：相同 seed 在本地模拟器中产生相同序列；不同 seed 产生不同序列。

能帮助控制	不能自动控制
Python random / NumPy RNG	云端模型服务的所有内部随机性
本地故障注入顺序	实时搜索结果变化
训练/采样中显式随机过程	网络抖动、并发调度差异
可重复抽样	数据源版本变化

4. Mean、Variance、Standard Deviation 是什么？

Mean（均值）回答“平均大约在哪里”；Variance（方差）和 Standard Deviation（标准差）回答“波动有多大”。只报均值会把稳定系统和高波动系统混在一起。




图 4：相同平均 Latency 下，尾部和波动同样值得看。

● **通俗比喻：**两个班平均分都是 80 分。A 班人人都在 78-82 之间；B 班一半 40 分、一半 120 分（假设允许）。平均值一样，但系统性质完全不同。

5. Confidence Interval：给“估计值”加上不确定性

当我们用有限样本估计成功率时，应尽量给出置信区间。对于二项成功/失败数据，Wilson 区间通常比简单的 $p \pm 1.96 \times \text{标准误}$ 更稳健，尤其样本较小或成功率靠近 0/1 时。




图 5：样本量增加后，95% Wilson 区间通常变窄。

● **重要纠正：** 频率学派 95% 置信区间不能严格解释成 “真实参数有 95% 概率落在这一个已经算出的区间里”。更准确地说：若长期重复同样的抽样过程，按该方法构造的区间约 95% 会覆盖真实参数。

6. Bootstrap：没有简单公式时怎么办？

Bootstrap 的思想是：把现有样本当作一个经验总体，反复 “有放回重采样”，观察目标统计量（例如平均成本、平均步数）的波动，从而近似估计不确定性。




图 6：5000 次 Bootstrap 重采样后的平均 Cost 分布。

● **边界：** Bootstrap 不是魔法。原始样本如果严重偏、任务分布不代表真实使用场景，Bootstrap 只会非常认真地重复这些偏差。

7. 比较两个 Agent：为什么最好做 Paired Comparison？

如果 A 和 B 面对不同任务，任务难度差异会混入结果。更稳妥的比较是让 A/B 面对同一批任务、尽量使用相同外部条件，然后分析每个任务上的配对差异。




图 7：同一批任务上的 B-A 配对差异累计均值。

科研洞察：“A=72%，B=75%”本身不够。你还要问：差异来自哪些任务？是否稳定？是否只被少数任务驱动？重复不同 seeds 后是否仍然存在？

8. 为什么一次小实验可能把 Agent 排名看反？

当两个系统真实差距较小时，小样本波动完全可能让较弱系统在某一实验里看起来更高。这是科研中“lucky run”最常见的来源之一。




图 8：教学模拟中 B 的真实参数略高，但多个 20 次小批次里仍会出现 A 暂时领先。

9. Agent 实验至少应该怎样重复？

层次	最低建议	为什么
----	------	-----

Task	使用一组有代表性的任务	避免单个任务偶然性
Run	同一配置多次运行	估计随机波动
Seed	记录随机种子/采样配置	便于复查与受控比较
Model/API	记录精确版本与日期	服务更新可能改变行为
Environment	固定工具、数据版本、Harness	避免把环境变化误当成方法效果
Statistics	报告均值/比例 + 不确定性	避免只报幸运数字

10. 重复实验 = 机械地重复同一件事

如果你把同一个固定任务重复 1000 次，只能很好地估计“这个固定任务上的波动”，不能自动证明方法在真实任务分布上泛化。因此实验需要同时考虑 two axes：任务多样性（across tasks）与随机重复（within task）。

● **最低闭环**：至少做到：多个任务 × 多次运行 → 保存每次 episode-level 结果 → 报告成功率/均值 → 给不确定区间 → 做 slice/paired 分析 → 保留 seed、版本和完整配置。

11. 初学者最常犯的 8 个错误

- 只跑 1 次就下结论
- 只报平均值，不报 n 和波动
- 只挑最好的 seed
- A/B 用不同任务集
- 把 CI 当成结果一定落在其中的概率
- 任务数很多但每类只来自同一种简单场景
- 模型/Harness/数据版本没记录
- 看到 2%-3% 差距就立刻宣布方法更好

12. 本讲实验路线

实验	目的
01 10 次并不够	观察小样本成功率波动
02 Sample Size	观察 n 增大后的稳定性
03 Random Seed	理解“可控随机性”
04 Mean/Variance/Std	描述连续指标波动
05 Confidence Interval	给成功率加不确定性
06 Bootstrap	无简单公式时估计统计量不确定性
07 Paired Comparison	控制任务难度差异
08 Ranking Instability	观察小样本排名反转

13. 为后续科研提前埋下的问题

● **可能的研究问题**：Agent 的随机性来自模型、工具、检索、调度还是环境？不同 failure type 的方差是否不同？重复次数如何按预算自适应分配？多 Agent 的错误相关性如何改变置信度？这些都可以发展成真正的 Agent Systems 研究问题。

14. 本讲结论

科研上，“我跑了一次，效果不错”几乎只是一个 observation，不是 evidence。重复实验的目标不是制造更多数字，而是估计系统行为的分布、波动和不确定性。

下一讲：Benchmark 到底是什么——Dataset、Task、Environment、Metric 与 Leaderboard。

15. 一分钟复盘：把统计语言说准确

- “成功率 70%”应尽量说成“在 $n=...$ 的这批任务/运行中，观测成功率为 70%”。
- “更稳定”最好对应更小的方差、标准差或更窄的不确定区间，而不是凭肉眼判断。
- “可复现”必须说明复现的是哪一层：本地随机数、任务采样、模型输出，还是整个端到端系统。
- “方法更好”需要结合效应大小、不确定性、任务切片、成本与重复实验，而不是只看一次排序。
- “重复很多次”不能替代任务代表性；within-task repetition 与 across-task diversity 必须同时考虑。

16. 进入第 32 讲前，你应该能独立回答

- ☐ 为什么 Benchmark 不能只有一组数据？
- ☐ 为什么 Task、Environment 与 Metric 必须分开定义？
- ☐ 为什么同一 Benchmark 上的 Leaderboard 分数仍需要看重复性与方差？