

第2讲练习题与答案

Token: 大语言模型眼里的文字

动手实验 建议

先独立作答，再翻到答案。尤其要能清楚区分 Token、Token ID、Embedding。

A. 基础理解题

1. Token 为什么不等于“单词”？
2. Tokenizer 与 Embedding 的工作边界分别在哪里？
3. 为什么子词 tokenizer 比“纯字符”和“纯单词”通常更折中？
4. BPE 的“merge”到底在合并什么？
5. 为什么 Token ID 不能直接拿来算“语义接近”？
6. 为什么两个模型对同一句文本可能得到不同 token 数？
7. 为什么工具调用返回一大段 JSON 会消耗 Agent 的上下文？
8. 为什么比较跨语言 Agent 成本时，仅比较字符数可能不公平？

B. 场景题

9. 你设计了一个 32K context 的 Agent, 把 20K token 的工具手册全文放进 system prompt。可能带来哪些系统后果?
10. 同样一段 5000 字文本, 模型 A 编成 7000 tokens, 模型 B 编成 11000 tokens。你能从中直接推出 B “更差” 吗? 为什么?
11. 一个人说: “我的提示词只有 2000 个汉字, 所以肯定不到 2000 tokens。” 这句话哪里有问题?
12. 为什么多 Agent 论文最好报告总 token 使用量, 而不只报告 Agent 数量和成功率?

C. 参考答案

1. Token 为什么不等于“单词”？

Token 边界由 tokenizer 决定，可以对应完整词、子词、字符、空格+词、标点或字节片段。

2. Tokenizer 与 Embedding 的工作边界分别在哪里？

Tokenizer 把字符串离散化为 token IDs; Embedding 把 token ID 查表映射成可学习连续向量。

3. 为什么子词 tokenizer 比“纯字符”和“纯单词”通常更折中？

纯字符序列容易过长，纯单词词表容易过大且难处理新词；子词能让高频片段压缩、罕见片段组合表示。

4. BPE 的“merge”到底在合并什么？

合并语料中频繁相邻出现的符号/片段，使它们成为更大的词表单元。

5. 为什么 Token ID 不能直接拿来算“语义接近”？

ID 是索引编号，数值大小没有连续语义几何；语义相似性要看 embedding 或上下文化表示。

6. 为什么两个模型对同一句文本可能得到不同 token 数？

因为它们可能有不同 tokenizer 算法、词表、训练语料、预切分和字节处理规则。

7. 为什么工具调用返回一大段 JSON 会消耗 Agent 的上下文？

JSON 最终也会被 tokenizer 编码成 tokens，与其他输入一起进入 context window。

8. 为什么比较跨语言 Agent 成本时，仅比较字符数可能不公平？

不同语言在同一 tokenizer 下可能有不同 tokenization efficiency; 同字符数可能对应明显不同 token 预算。

9. 你设计了一个 32K context 的 Agent，把 20K token 的工具手册全文放进 system prompt。可能带来哪些系统后果？

可用 context 被大量静态文本占据；每轮输入成本和延迟提高；真正任务证据被挤压；长文本还可能引入检索噪声。

10. 同样一段 5000 字文本，模型 A 编成 7000 tokens，模型 B 编成 11000 tokens。你能从中直接推出 B “更差”吗？为什么？

不能。token 数更多只说明该 tokenizer

对这段文本编码粒度不同；模型质量还取决于架构、训练、能力等。

11. 一个人说: “我的提示词只有 2000 个汉字, 所以肯定不到 2000 tokens。” 这句话哪里有问题?

汉字与 token 没有固定 1:1 映射; 精确值要用目标 tokenizer 实测。

12. 为什么多 Agent 论文最好报告总 token 使用量, 而不只报告 Agent 数量和成功率?

Agent 数量并不能反映实际计算/通信成本。总 tokens

能帮助评估性能收益是否以巨大上下文和通信开销换来, 也利于复现。