

第3讲 Embedding 核心概念速查卡

零基础 LLM · 复习用



必须会解释

- Token ID 是编号，不是语义数值。
- Embedding = 把离散 ID 映射成连续向量。
- Embedding Matrix: $V \times d$, 每行一个 Token。
- Lookup: $\text{vector} = E[\text{token_id}]$ 。
- Token Embedding 是输入起点，不是最终语义。

相似度与上下文

- 余弦相似度比较向量方向。
- 相似度高 $\neq$ 事实正确。
- 二维词向量图通常是高维空间的降维投影。
- 同一 Token 的起始向量可相同；Transformer 后 hidden state 会随上下文改变。

Agent / RAG 连接

- Text Embedding
常把句子/段落压成一个向量。
- Vector DB 按相似度检索。
- Agent Memory、Tool
Retrieval、RAG 都可用向量检索。
- 检索偏差可能进一步放大为 Agent 系统行为偏差。

Core chain: Token ID -> Embedding Lookup -> Vector -> Transformer -> Contextual Representation