

第3讲：Embedding - 练习题与答案

建议：先独立完成“题目部分”，再翻到答案。题目刻意强调“解释为什么”，避免只背术语。

A. 基础判断

1. Token ID=200 比 Token ID=100 大，所以前者语义一定更复杂。（对 / 错）
2. Embedding Layer 的核心操作可以近似理解为“根据 Token ID 查表取向量”。（对 / 错）
3. Embedding 向量每一维都应该能被人类清楚命名。（对 / 错）
4. 同一 Token 在两个不同句子里进入模型时，起始 Token Embedding 可以相同，但经过 Transformer 后的 hidden state 可以不同。（对 / 错）
5. 两段文本余弦相似度很高，就足以证明两段文本中的事实都正确。（对 / 错）

B. 计算与机制

6. 假设词表大小 $V=80,000$ ，Embedding 维度 $d=3,072$ 。Embedding Matrix 有多少参数？如果每个参数占 2 字节，理论参数存储约多少 MB？
7. 用自己的话解释：为什么不能直接把 Token ID 当成普通连续数字输入后续神经网络？
8. 写出一行最简伪代码，表示根据 `token_id` 从 `embedding matrix` 取出向量。
9. $A=[1,0]$ ， $B=[0.8,0.2]$ 。你不用精确计算，也能判断余弦相似度会更接近 1、0 还是 -1？解释原因。
10. 为什么“二维词向量图”只能当成辅助可视化，不能完全代表真实高维空间？

C. LLM / Agent 场景题

11. “我吃了一个苹果”和“苹果发布了芯片”中，解释 Token Embedding 与 contextual representation 的差异。
12. 一个 Agent 把过去 10,000 条经历都做成 Text Embedding，并只按 cosine similarity 取 Top-3 记忆。请指出至少三个潜在失败点。
13. Tool Retrieval 中，两个工具描述非常相似，但实际权限完全不同。若只靠 embedding 相似度选工具，可能出现什么问题？应该增加什么校验？
14. RAG 检索到一段与用户问题“很像”的文档，这段文档就一定是正确证据吗？解释表示相似与事实验证之间的区别。
15. 你在论文里看到“we use the last hidden state as the representation”。这里的 representation 更接近 Embedding Matrix 的原始一行，还是经过上下文处理后的表示？为什么？

D. 小型代码实验任务

运行材料包中的 `04_embedding_geometry_demo.py`:

16. 记录 cat-dog、cat-car 的 cosine similarity。
17. 把 car 的向量改成 `[0.80, 0.72, 0.12]`，重新运行。发生了什么？
18. 解释为什么代码里的“相似”是我们手工构造的几何关系，而不是真实 LLM 自动学习的语义。

参考答案

1. 错。Token ID 是离散编号；数值大小通常不具有语义大小关系。
2. 对。Embedding Layer 从机制上可以近似理解为以 ID 为索引，在可学习矩阵中查出对应的一行。
3. 错。真实高维表示通常是分布式表示，单独一维往往没有稳定的人类可解释标签。
4. 对。输入 embedding 可以相同，但后续 self-attention 会结合周围 token 形成不同 hidden states。
5. 错。相似度是表示空间关系，不是事实核验结果。
6. 参数量 = $80,000 \times 3,072 = 245,760,000$ 。若 2 字节/参数，约 491,520,000 字节，按十进制约 491.5 MB；实际运行还会有额外开销。
7. ID 只承担身份标识。若直接把 100、101 当连续数值，会错误地人为引入“编号相近=语义相近”的顺序/距离结构。Embedding 用可学习向量替代这种伪距离。
8. 例如：vector = E[token_id]。
9. 更接近 1。两个向量都大致朝右，方向夹角较小。
10. 真实 embedding 常有数百到数千维；二维图必须降维，降维会丢失并可能扭曲距离结构。
11. 如果 tokenizer 产生同一 token，“苹果”的起始 token embedding 可以相同；但与“吃了一个”或“发布了芯片”交互后，Transformer 内部 hidden state 会分别偏向水果含义和公司实体含义。
12. 例如：表述不同但本质相关的记忆可能漏检；表述相似但结论错误的记忆可能被召回；只取 Top-3 会漏掉互补证据；旧的错误记忆可能反复强化；embedding 模型本身存在领域偏差。
13. 可能选到权限更高或语义近但操作不同的工具。应增加结构化 schema 校验、权限校验、参数约束、执行前 policy check 等。
14. 不一定。向量检索解决“相关性候选”，不能完成来源可信度、时效性、逻辑一致性与事实正确性验证。

15. 更接近上下文文化表示。last hidden state 是 Transformer 计算后得到的内部状态，而不是输入 embedding matrix 的原始查表结果。

16. 脚本会显示 cat-dog 相似度明显高于 cat-car。数值以脚本输出为准。

17. car 被手工改得靠近 cat/dog 后，cat-car cosine similarity 会大幅升高。这说明相似度取决于向量几何。

18. 因为脚本中的向量是人为指定的，没有经历真实模型训练。真实 embedding 的坐标是训练目标、数据与优化共同学习出来的。

自检标准

如果你可以不看材料，用自己的话回答下面四句话，本讲就算真正通过：

Token ID 为什么只是“地址”，而不是语义？

Embedding Matrix 为什么既像“表”，又是“模型参数”？

为什么同一个 Token 的最终表示会随着上下文变化？

为什么 Agent Memory 的向量相似度检索需要额外的可靠性机制？