

$$h = f(Wx + b)$$

输入 x · 权重 W · 偏置 b · 激活函数 f · 新表示 h

结构与参数

- Weight / Bias: 最典型的可学习参数。
- Parameter: 训练会更新并保存在模型文件中的数值。
- Layer: 一次表示变换。
- Hidden State: 中间层内部表示。
- 100B 参数 $\neq$ 100B 条知识。

为什么要非线性

- 只堆线性层: $W_2(W_1x) = (W_2W_1)x$ 。
- 激活函数打破线性可合并性。
- ReLU/GELU/SiLU 都是常见非线性。
- 多层 + 非线性才能逐步构造复杂函数。

训练 vs 推理

- Training: 前向 $\rightarrow$ Loss $\rightarrow$ 反向传播 $\rightarrow$ 更新参数。
- Inference: 固定已学参数做前向计算。
- 普通聊天不等于每次都训练全部权重。
- Transformer 仍是神经网络: Attention/FFN 都有大量矩阵参数。

Core chain: $x \rightarrow Wx+b \rightarrow \text{activation} \rightarrow \text{hidden state} \rightarrow \dots \rightarrow \text{output}$