

第4讲：神经网络到底是什么？ - 练习题与答案

建议：先只做题目部分。重点不是算数，而是能不能把概念之间的关系说清楚。

A. 基础判断

1. “100B 参数”表示模型内部保存了 100B 条文本知识。（对/错）
2. 权重 W 与偏置 b 通常都属于可学习参数。（对/错）
3. 不加任何激活函数时，连续多个线性层依然可以产生任意复杂的非线性函数。（对/错）
4. Forward Pass 指从输入到输出进行一次计算。（对/错）
5. 普通推理通常必须先计算梯度，再更新全部模型参数。（对/错）
6. Transformer 不属于神经网络，因为它使用 Attention。（对/错）

B. 概念解释

7. 用通俗语言解释 $h=f(Wx+b)$ 中每个符号。
8. 为什么神经网络更适合用矩阵形式表示，而不是逐个神经元写公式？
9. 什么是 hidden state? 为什么叫“隐藏”？
10. 参数 (parameter)、超参数 (hyperparameter) 和推理配置有什么区别？各举一个例子。
11. 为什么激活函数对深度网络很重要？
12. 用自己的话解释训练与推理的本质区别。
13. 为什么“一个参数=一条知识”通常是错误理解？
14. Transformer 中哪些地方会产生大量参数？至少写出 Embedding、Attention、FFN 中的两个。

C. 小计算

15. 某线性层输入维度 4，输出维度 3。权重矩阵 W 有多少参数？如果每个输出都有一个 bias，总参数是多少？
16. 给定 $x=[2, -1]$ ， $w=[0.5, 3]$ ， $b=1$ ，先计算 $z=w_1*x_1+w_2*x_2+b$ ，再计算 $\text{ReLU}(z)$ 。
17. 一个矩阵 W 形状是 4096×4096 ，不考虑 bias，它有多少参数？约多少百万 (M) 参数？
18. 为什么 $W_2(W_1x)$ 可以写成 $(W_2W_1)x$ ？这说明纯线性网络堆层有什么限制？

参考答案

A. 基础判断

1. 错。参数是可学习数值，不是一条条独立文本记录。
2. 对。它们是最典型的模型参数。
3. 错。没有非线性时，多层线性变换可合并成一个线性变换。
4. 对。前向计算就是从输入沿计算图得到输出。
5. 错。普通推理通常固定参数，只做前向计算。
6. 错。Transformer 是一种神经网络架构，Attention 与 FFN 都由可学习矩阵运算构成。

B. 概念解释答案

7. x 是输入； W 是权重矩阵，控制输入怎样组合； b 是偏置； f 是激活函数，引入非线性； h 是输出的新表示。 W 、 b 通常由训练学习。
8. 真实网络有成千上万甚至更多输入和输出。把权重组织成矩阵后，可把大量乘加运算统一为矩阵乘法，更容易表示，也更适合 GPU 并行。
9. hidden state 是网络中间层产生的内部表示。它叫“隐藏”，主要因为它不是系统直接展示给用户的最终输入/输出，不代表它不可访问。
10. parameter 是训练更新的模型数值，如 W ；hyperparameter 是训练设计设置，如学习率/层数；推理配置是使用模型时的生成设置，如 temperature。
11. 激活函数引入非线性。不然 $W_2(W_1x)$ 仍是一个线性变换，叠很多层也难以表达复杂非线性关系。
12. 训练的目标是根据 Loss/梯度修改参数；推理是在参数通常固定的情况下，用它们对新输入进行前向计算。
13. 现代网络的知识与功能通常分布在大量参数及其交互中；一个参数可能参与很多功能，一个事实也可能依赖很多参数。
14. Embedding Matrix 本身是大量参数；Attention 有 W_q 、 W_k 、 W_v 、 W_o 等投影矩阵；FFN/MLP 有大矩阵 W_1 、 W_2 （具体架构可能更多）。

C. 小计算答案

15. W 是 3×4 ，所以 12 个权重；bias 有 3 个，总共 15 个参数。
16. $z = 0.5 \times 2 + 3 \times (-1) + 1 = 1 - 3 + 1 = -1$ 。ReLU(-1)=0。
17. $4096 \times 4096 = 16,777,216$ ，约 16.78M 参数。
18. 矩阵乘法满足结合律，因此两个连续线性变换仍可合并成一个线性变换。没有非线性，增加层数不会带来同等意义上的函数复杂度。

D. 研究者视角加练

19. 为什么比较两个 LLM 时，不能只看参数量就判断谁一定更强？
20. 如果某论文把 hidden size 从 4096 提到 8192，为什么参数量和计算量往往会大幅上升，而不是简单“只多一倍”？
21. Agent Systems 实验中，如果底层 LLM 固定不训练，研究者仍然可以研究哪些系统变量？

参考思路

19. 能力还受训练数据质量/数量、训练目标、架构、优化、后训练、上下文与推理机制等影响；参数量只是容量与成本的重要因素之一。
20. 很多权重矩阵两边都和 hidden size 相关。例如 $d \times d$ 的矩阵，当 d 翻倍时参数会约变为 4 倍；具体取决于架构。
21. 仍可研究 prompt、memory、tool use、planning、communication topology、role assignment、retrieval、verification、aggregation、failure modes 等。底层模型参数固定不妨碍系统层研究。