

# 第5讲速查卡：模型是怎么“学习”的？

一句话总览

Forward 得到预测 → Loss 量化错误 → Backprop 计算梯度 → Optimizer 更新参数 → 重复。

| 术语               | 最简解释                | 千万别混淆                  |
|------------------|---------------------|------------------------|
| Loss             | 错误的数值评分             | 不是梯度                   |
| Gradient         | 每个参数的局部坡度/敏感度       | 不是参数更新本身               |
| Backprop         | 从 Loss 向前面各层高效算梯度   | 不直接负责 optimizer step   |
| Gradient Descent | 沿梯度反方向降低 Loss 的基本规则 | 不是唯一优化器                |
| Learning Rate    | 一步走多远               | 太大可能发散，太小太慢            |
| Batch            | 一次用于算梯度的一批样本        | 不等于 epoch              |
| Step             | 一次参数更新              | 一个 epoch 常含很多 step     |
| Epoch            | 训练数据大致完整看一遍         | LLM 常更多报告 tokens/steps |

# LLM 训练闭环 (next-token prediction)

| 阶段                | 输入/动作                   | 输出                   |
|-------------------|-------------------------|----------------------|
| 1. Token batch    | 一批文本 Token              | 输入序列 + 真实 next token |
| 2. Forward        | Embedding + Transformer | logits               |
| 3. Softmax / Loss | 对词表计算概率 + Cross Entropy | 标量 Loss              |
| 4. Backward       | 链式法则 + autograd         | 所有可训练参数的 gradient    |
| 5. Optimizer      | AdamW 等规则               | 更新后的参数               |

最重要公式 1

参数更新:  $\theta_{\text{new}} = \theta_{\text{old}} - \eta \cdot L$

最重要公式 2

语言模型单位位置交叉熵直觉:  $L = -\log p(\text{correct token})$ 。正确 Token 概率越低, Loss 越大。