

第5讲练习题：Loss、梯度、反向传播与梯度下降

建议先独立作答，再看后半部分答案。

Q1 概念辨析

请分别用一句话解释 Loss、Gradient、Backpropagation、Optimizer。

Q2 判断题

“只要已经算出了 Loss，模型就知道所有参数应该怎么更新。”对还是错？为什么？

Q3 数值题

模型 $\hat{y} = w \cdot x$ ， $x=2$ ，真实 $y=8$ ，当前 $w=3$ 。使用平方损失 $L = \frac{1}{2}(\hat{y} - y)^2$ 。求： $\hat{y}$ 、Loss、 dL/dw 。

Q4 更新一步

接 Q3，若学习率 $lr=0.05$ ，按 $w_{new} = w - lr \cdot dL/dw$ 更新一次，新的 w 是多少？

Q5 学习率

为什么学习率过大可能导致 Loss 不降反升？用“下山”的比喻解释。

Q6 链式法则

为什么深层网络不能只看“最后一层”就知道第一层参数的梯度？链式法则解决了什么？

Q7 LLM

给定“法国的首都是”，正确 next token 是“巴黎”。模型给“巴黎”的概率从 0.05 提升到 0.50。Cross Entropy Loss 大体是变大还是变小？为什么？

Q8 Batch / Step / Epoch

训练集 12000 条样本，batch size=200。忽略最后不足 batch 的情况，一个 epoch 大约多少 step？训练 5 epochs 大约多少 step？

Q9 机制题

为什么反向传播比“把每个参数分别加一点、重新跑一次模型”高效得多？

Q10 研究阅读题

论文写：We train with AdamW, a peak learning rate of $3e-4$, 2k warmup steps, and gradient clipping at 1.0. 你现在至少能读懂哪些关键词？哪些细节还不要求掌握？

答案与详细解释

A1

Loss 是错误评分；Gradient 是 Loss 对各参数局部变化的敏感度；Backprop 用链式法则高效算梯度；Optimizer 使用梯度更新参数。

A2

错。Loss

只告诉你当前“总成绩”有多差；还要求导/反向传播，才能知道每个参数分别怎样影响这个 Loss。

A3

$=3 \times 2=6$ ； $L=(6-8)^2=4$ 。 $dL/dw=2(-y) \cdot x=2 \times (-2) \times 2=-8$ 。负梯度表示在当前点增大 w 会让 Loss 下降。

A4

$w_{\text{new}}=3-0.05 \times (-8)=3.4$ 。因为梯度为负，所以减去负数，相当于让 w 增大。

A5

梯度只提供当前局部坡度。学习率太大，相当于下山时一步跨得太远，可能直接越过谷底跳到另一侧；下一步又跳回来，造成震荡，甚至越跳越远。

A6

第一层参数先影响第一层输出，再影响第二层……最后才影响 Loss。链式法则把每一段局部影响串起来，从而得到第一层参数对最终 Loss 的总影响。

A7

变小。 $L=-\log p(\text{correct})$ 。正确 Token 概率从 0.05 提升到 0.50，说明模型更倾向真实答案，因此惩罚降低。

A8

$12000/200=60$ step/epoch；5 epochs $\approx$ 300 steps。

A9

逐参数扰动需要对海量参数分别重新前向计算，成本近似随参数数目成倍增长。Backprop 会复用计算图中的中间结果，一次反向遍历即可得到所有参数的梯度。

A10

可以读懂: AdamW 是优化器; peak learning rate 是最大学习率; warmup 表示开始阶段逐步提高学习率; gradient clipping 限制过大的梯度。暂时不要求掌握 AdamW 的矩估计公式、warmup 调度的精确函数或 clipping 的工程实现细节。

加餐：手算一个完整训练 step

模型： $\hat{y} = w \cdot x + b$ 。给定 $x=2$, $y=7$, 当前 $w=2$, $b=1$, 平方损失 $L=(\hat{y}-y)^2$, 学习率 $lr=0.1$ 。

第1步: Forward

$$\hat{y} = 2 \times 2 + 1 = 5。$$

第2步: Loss

$$L = (5 - 7)^2 = 4。$$

第3步: Gradient

$$L / \hat{y} = 2(\hat{y} - y) = -4。$$

$$\text{因为 } \hat{y} = wx + b, \text{ 所以 } L / w = -4 \times 2 = -8。$$

$$\text{因为 } \hat{y} = wx + b, \text{ 所以 } L / b = -4。$$

第4步: Update

$$w_{\text{new}} = 2 - 0.1 \times (-8) = 2.8。$$

$$b_{\text{new}} = 1 - 0.1 \times (-4) = 1.4。$$

第5步: 重新 Forward

新的预测 $\hat{y} = 2.8 \times 2 + 1.4 = 7.0$, $\text{Loss} = 0$ 。这个玩具例子刚好一步到位；真实网络通常不会这么幸运，也不会使用这么简单数据。

真正应该掌握的不是算术

你要形成“计算图上的因果链”：参数 $\rightarrow$ 中间结果 $\rightarrow$ 预测 $\rightarrow$ Loss；反向时则沿着这条链把梯度传回去。