

第6讲速查卡：训练集 / 验证集 / 测试集 / 过拟合 / 泛化

概念	一句话	典型用途/信号
训练集 Train	直接用于计算梯度、更新参数	模型真正“学习”的数据
验证集 Validation	不更新权重，但用于做模型选择	调学习率、轮数、prompt、Agent策略
测试集 Test	最终独立评估	不能反复偷看
过拟合 Overfitting	训练很好，新数据变差	train loss ↓ , val/test loss ↑
欠拟合 Underfitting	连训练规律也没学好	train/val 都差
泛化 Generalization	未见数据上仍保持表现	真正关心的能力
泄漏 Leakage	评测信息提前进入训练/选择	分数虚高、结论失真
OOD	部署分布与训练分布不同	长上下文、工具变化、环境变化

最重要的流程

训练集更新参数 → 验证集选择方案 → 冻结方案 →
测试集只做最终评估。若你根据测试结果继续修改系统，测试集就不再是“测试集”。

Agent 研究额外检查

不要只看平均成功率：还要看跨模型/跨任务/跨工具/长程任务是否稳定，以及错误累积、恢复能力和失败模式。