

第6讲练习题与答案

建议：先遮住答案完成前半部分，再核对。

选择题 1

训练过程中，哪一份数据通常直接参与反向传播？

A. 训练集 B. 验证集 C. 测试集 D. 三者都一样

选择题 2

下列哪种现象最典型地表明过拟合？

A. 训练和验证都差 B. 训练越来越好而验证变差 C. 训练不收敛 D. GPU 利用率低

判断题 3

只要测试集没有参与反向传播，就可以无限次查看测试结果并据此改模型。

对 / 错

简答题 4

为什么验证集也可能被“过拟合”？

简答题 5

举一个 Agent Systems 中的 OOD 场景。

设计题 6

你要比较“单 Agent”和“3 Agent 讨论”的效果。请给出一个最小但可信的数据划分与实验流程。

分析题 7

某模型：训练准确率 99%，验证准确率 71%，测试准确率 69%。你首先想到哪些可能原因？

分析题 8

某研究在同一个 benchmark 上调了 200 次 prompt，最终报告最好一次结果。这个结论有什么风险？

参考答案

- 1) A。训练集通常用于计算 Loss 和梯度，并更新模型参数。
- 2) B。训练继续变好而验证变差，是经典过拟合信号。
- 3) 错。测试结果如果不断指导人工修改，信息仍然反馈进入了系统。
- 4) 因为研究者会根据验证集结果反复选择超参数、prompt 或结构。尝试越多，越可能偶然适配这份验证集。
- 5) 例如：开发时工具 API 总是正常返回 JSON，真实部署时 API 字段改名、延迟增加或返回错误信息。
- 6) 开发集用于调 prompt/通信协议；验证集选择讨论轮数与聚合规则；冻结方案后在独立测试集比较单/多 Agent；最好再换任务或基础模型复验。
- 7) 首先考虑过拟合；也检查训练-验证分布差异、数据泄漏/重复、预处理不一致、样本量是否太小等。
- 8) 它相当于对 benchmark 进行大量模型选择，最终最好结果可能包含很强的选择偏差，泛化到其他任务/数据未必成立。

科研小任务

找一篇你感兴趣的 Agent 论文，只看实验部分，不需要看懂算法。回答下面 5 个问题：

- 作者的开发/训练数据是什么？
- 作者有没有单独的验证集？它用来做什么？
- 最终测试数据是什么？是否公开？
- 作者是否在多个模型/任务/环境上重复关键现象？
- 如果只换一个新的 benchmark，你认为结论最可能在哪一步失效？

目的

这不是为了批评论文，而是训练你从“分数”进一步看到“结论是否能泛化”。