

第8讲速查卡：Attention / Q / K / V

组件	一句话	公式/动作
Q	我想找什么	$Q = XW_Q$
K	我怎样被匹配	$K = XW_K$
V	被关注后提供什么	$V = XW_V$
Score	Q 与 K 的匹配	$QK^T / \text{sqrt}(d_k)$
Softmax	把分数变权重	每行权重 > 0 且和 $= 1$
Output	读取上下文	$A V$

完整公式

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T / \text{sqrt}(d_k))V$$

记忆口令：Q 找 K，权重读 V。

步骤	你脑中应该出现什么
1. 投影	同一 X 通过 $W_Q/W_K/W_V$ 形成三个不同视角
2. 比较	每个 Q 与所有 K 做点积
3. 缩放	除 $\text{sqrt}(d_k)$ 控制数值尺度
4. Mask	GPT 屏蔽未来；Padding 屏蔽补齐位置
5. Softmax	把分数变成读取权重
6. 读取	权重乘 V，得到上下文文化输出

Attention Matrix / Mask / 易错点

概念	正确理解
Attention Matrix	第 i 行 = Query_i 对所有 Key 的权重
Self-Attention	Q/K/V 来自同一序列
Cross-Attention	Q 和 K/V 来自不同来源
Causal Mask	禁止看未来 token
Padding Mask	忽略为 batch 对齐补出的无意义 token
n 成本	n 个 Query x n 个 Key 形成 n x n 关系矩阵

最容易混淆

- 1) Q/K/V 不是三个 token; 每个 token 都有自己的 Q/K/V。
- 2) Key 负责匹配, Value 才是被读取的内容。
- 3) Attention 权重不是完整思维过程。
- 4) Self 不是“只看自己”。

最低闭环: $X \rightarrow Q/K/V \rightarrow QK^T/\sqrt{d_k} \rightarrow \text{Mask} \rightarrow \text{Softmax} \rightarrow AV \rightarrow \text{Output}$