

第8讲 · 练习题与答案

Attention: 从相关性、Softmax 到 Query / Key / Value

使用方法

建议先独立完成题目，尤其是第9、10、18题。能够逐步解释完整 Attention 公式，比背公式更重要。

1. 用一句话解释 Attention 的三步核心流程。
2. Query、Key、Value 分别是什么角色？
3. 为什么 Key 和 Value 不一定要是同一个表示？
4. Q、K、V 是从哪里来的？训练时哪些参数会被更新？
5. 点积 $Q \cdot K$ 在 Attention 中表示什么？
6. 为什么要除以 $\sqrt{d_k}$ ？

7. Softmax 输出有什么两个重要性质？

8. 为什么最终加权的是 V ，而不是 K ？

9. 请逐项解释 $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$ 。

10. 如果 Q shape= $[n, d_k]$ ， K shape= $[n, d_k]$ ，为什么 QK^T 是 $[n, n]$ ？

11. Self-Attention 中 “Self” 到底指什么？

12. GPT 为什么必须使用 Causal Mask？

13. Causal Mask 和 Padding Mask 有什么不同？
14. 为什么 Attention 输出可以说是“上下文表示”？
15. Attention 权重高，是否等于这个 token 是最终答案的因果原因？为什么？
16. 标准全注意力为什么会带来 n^2 级别的长上下文压力？
17. 结合 Agent Systems：外部 Memory 检索和模型内部 Attention 分别解决什么问题？
18. 请画出完整流程： $X \rightarrow Q/K/V \rightarrow \text{scores} \rightarrow \text{mask} \rightarrow \text{softmax} \rightarrow \text{weighted } V \rightarrow \text{output}$ 。

参考答案

1. 先计算当前 Query 与各 Key 的相关性，再用 Softmax 变成权重，最后按权重加权对应 Value。
2. Q 表示“我想找什么”；K 表示“我怎样被匹配”；V 表示“如果你关注我，我真正提供什么内容”。
3. 匹配所需特征和真正要传递的信息可以不同，分开后模型表达能力更强。
4. 来自输入表示 X 乘以可学习矩阵 W_Q 、 W_K 、 W_V ；训练时这些矩阵会通过反向传播更新。
5. 表示当前 Query 与某个 Key 的匹配程度/相关性分数。
6. 高维点积绝对值容易变大，缩放可避免 Softmax 过度饱和并改善数值和训练稳定性。

7. 所有输出都为正；所有权重总和为 1。
8. K 用来决定是否相关； V 才承载要被读取并传递到输出的内容。
9. QK^T 计算所有 Query-Key 分数；除 $\sqrt{d_k}$ 缩放；Softmax 归一化；最后乘 V 做加权读取。
10. K^T 是 $[d_k, n]$ ，矩阵乘法 $[n, d_k] \times [d_k, n]$ 得到 $[n, n]$ 。
11. Q 、 K 、 V 的源头来自同一序列的表示，而不是说 token 只能看自己。
12. 因为 GPT 要学习根据过去预测未来；若看到未来真实 token 就会泄露答案。

13. Causal Mask 屏蔽未来位置; Padding Mask 屏蔽为了批处理对齐而补的无意义位置。
14. 因为输出不只包含当前位置自身信息, 还融合了按权重从上下文其他位置读取的信息。
15. 不等于。Attention 权重只是一个中间计算量, 最终行为还经过多个 Head、层、残差和 FFN; 机制解释通常需要干预证据。
16. n 个 Query 都可能和 n 个 Key 比较, 因此关系矩阵规模是 $n \times n$ 。
17. 检索负责决定“把哪些外部信息放进上下文”; Attention 负责模型内部“怎样利用已经进入上下文的信息”。
18. 自检图应包含: $X \rightarrow$ 线性投影得到 $Q/K/V \rightarrow QK^T/\sqrt{d_k} \rightarrow$ 加 Mask $\rightarrow$ Softmax $\rightarrow$ 权重乘 $V \rightarrow$ 输出。