

第9讲速查卡：Multi-Head Attention

概念	一句话	关键式子/Shape
Head	一套独立 Q/K/V 投影 + Attention 分支	$\text{head}_i = \text{Attention}(Q_i, K_i, V_i)$
d_{model}	总隐藏维度	例如 512
h	Head 数	例如 8
d_{head}	单 Head 维度	常见 $d_{\text{model}} = h * d_{\text{head}}$
Concat	把多头输出拼接	$[h, n, d_{\text{head}}] \rightarrow [n, d_{\text{model}}]$
W_O	输出投影	$\text{Concat}(\dots) W_O$

完整公式

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

流程	脑中图像
1. 投影	同一 X 经过多套 $W_Q/W_K/W_V$
2. 分头	reshape 为 $[batch, h, n, d_{\text{head}}]$
3. 每头 Attention	每个 Head 独立算 $QK^T \rightarrow \text{Mask} \rightarrow \text{Softmax} \rightarrow V$
4. Concat	把各 Head 特征拼回 d_{model}
5. W_O	重新混合 Head 信息，得到 Attention 子层输出

易错点 + MHA/MQA/GQA

易错点	正确理解
Head 不是独立模型	只是同一层内部的并行分支
每个 Head 不只看一部分 token	通常都能访问允许范围内所有位置
不同 Head 不是人工分工	功能由训练形成，可能冗余
Concat 不等于融合完成	W_O 负责进一步线性混合
Head 数不是越多越好	单头宽度、冗余、计算效率都有权衡
Multi-Head 不是多 Agent	二者只是“多视角后融合”的抽象类比

结构	K/V 共享方式	推理直觉
MHA	多 Q 头通常各自有 K/V	KV Cache 较多
MQA	多 Q 头共享 1 组 K/V	KV Cache 更省
GQA	Q 头分组共享少量 K/V	表达/效率折中

记忆口令

多套投影，多头独立；拼接回来，W_O 混合。