

第9讲 · 练习题与答案

Multi-Head Attention: 为什么一个注意力头不够?

使用方法

先独立完成 1-20 题。重点不是背术语，而是能画出 Shape 与完整流程，并解释 Concat 与 W_O 的区别。

1. 用一句话解释 Attention Head 是什么。
2. Multi-Head Attention 与把同一个 Attention 结果复制多份有什么根本区别?
3. 为什么不同 Head 会产生不同的 Attention Matrix?
4. d_{model} 、 h 、 d_{head} 分别表示什么?
5. 若 $d_{model}=768$ ， $h=12$ ，在经典等分设置下 d_{head} 是多少?
6. 输入 $X=[n, d_{model}]$ ，拆成多头后常见 Shape 是什么（忽略 batch）?
7. 每个 Head 内部执行的核心 Attention 公式是什么?

8. 为什么说“不同 Head 学不同语法角色”只能作为直觉？
9. Concat 做了什么？它是否已经完成 Head 间的信息融合？
10. W_O 的作用是什么？
11. 写出 MultiHead 的经典公式，并逐项解释。
12. 为什么经典多头设计不会简单把总表示维度乘 h ？
13. Head 数是否越多越好？为什么？
14. GPT 中 Causal Mask 如何作用于多头 Attention？

15. 为什么高效实现不会真的用 Python for 循环逐个 Head 计算?
16. Multi-Head Attention 和多 Agent 投票有什么本质区别?
17. MHA、MQA、GQA 在 K/V Head 数量上的区别是什么?
18. 为什么减少 K/V Head 数量有助于推理系统?
19. 如果一个模型 Attention Heatmap 显示某个 Head 总关注句号, 能否直接断言“这个 Head 的功能就是识别句号”? 为什么?
20. 请画出完整流程: $X \rightarrow Q/K/V \rightarrow \text{Split Heads} \rightarrow \text{每头 Attention} \rightarrow \text{Concat} \rightarrow W_O \rightarrow \text{Output}$ 。

参考答案

1. 一条拥有自己 Q/K/V 投影参数、在较小维度内独立执行 Attention 的并行计算分支。
2. 不同 Head 使用不同可学习投影矩阵，因此得到不同 Q/K/V、权重和输出，不是同一结果的复制。
3. 因为各 Head 的 W_Q/W_K 不同，同一输入被映射到不同子空间后，点积分数自然不同。
4. d_{model} 是总隐藏维度； h 是 Head 数； d_{head} 是每个 Head 的 Q/K/V 维度。
5. $768/12=64$ 。
6. 常写成 $[h,n,d_{head}]$ ；含 batch 时常见 $[batch,h,n,d_{head}]$ 。
7. $\text{softmax}(Q_i K_i^T / \sqrt{d_{head}}) V_i$ ；GPT 类模型还在 Softmax 前加因果 Mask。

8. 真实 Head 功能由训练涌现，可能重叠、冗余或难命名，不是人为硬编码一个 Head 对应一种语法关系。
9. Concat 把多个 Head 的特征在最后一维拼起来；它本身只是并排放置，不是充分混合。
10. W_O 对拼接后的多头表示做可学习线性变换，使不同 Head 的信息重新混合并回到模型表示空间。
11. $head_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$; $\text{MultiHead} = \text{Concat}(head_1, \dots, head_h)W_O$ 。
12. 经典设计在 d_{model} 固定时把它分给多个较小 d_{head} ，拼接后仍回到 d_{model} 。
13. 不是；头太多会使单头变窄，可能冗余，还受参数、训练和硬件效率影响。
14. 同一个因果约束会作用到每个 Head 的 score 矩阵，使未来位置在所有 Head 中权重为 0。

15. GPU 擅长批量矩阵运算；把 Head 作为张量维度可并行完成，远快于解释器层循环。
16. Multi-Head 是单个神经网络层内部的连续向量分支；多 Agent 是多个相对独立推理/行动实体，可能有独立记忆、工具和通信。
17. MHA 通常多 Q 头对应多 K/V 头；MQA 多 Q 头共享 1 组 K/V；GQA 多 Q 头分组共享较少数量 K/V。
18. 历史 token 的 K/V 需要缓存；K/V 头更少意味着 KV Cache 和内存带宽压力更低。
19. 不能。它只是观察到相关模式，不足以证明因果功能；需要干预、消融或其他机制分析。
20. 自检图应包含：X $\rightarrow$ 线性 Q/K/V 投影 $\rightarrow$ reshape/split 为 h 头 $\rightarrow$ 每头 scaled dot-product Attention $\rightarrow$ Concat $\rightarrow$ W_O $\rightarrow$ 输出。