

第11讲速查卡：一个 Transformer Block 怎样工作

组件	一句话职责	关键公式/Shape
Attention	token 之间交换信息	$[n, d_{model}] \rightarrow [n, d_{model}]$
Residual	保留主干并叠加增量	$y = x + F(x)$
LayerNorm / RMSNorm	稳定数值尺度	逐 token 特征维归一化
FFN / MLP	逐 token 非线性加工	$d_{model} \rightarrow d_{ff} \rightarrow d_{model}$
Pre-Norm	先 Norm 再子层	$x + F(\text{Norm}(x))$
Causal Mask	禁止看未来	decoder-only 必需

完整 Pre-Norm Block	含义
$A = X + \text{Attn}(\text{Norm}(X))$	先交流，再把更新写回 residual stream
$Y = A + \text{FFN}(\text{Norm}(A))$	再本地加工，再写回 residual stream
Input/Output: $[batch, n, d_{model}]$	主接口不变，便于堆叠很多层

论文阅读五问

① Norm 是 Pre 还是 Post? ② Attention 是 MHA/GQA/MQA? ③ 是否 causal? ④ FFN 用什么激活/门控? ⑤ d_{model} 与 d_{ff} 是多少?