

第11讲练习题与答案

建议先独立完成，再看答案。

A. 基础判断

1. Transformer Block 只有 Attention, 没有其他关键组件。
2. Residual Connection 可以让输入绕过子层直接参与输出。
3. 标准 FFN 会让所有 token 两两进行信息交换。
4. Pre-Norm 可以写成 $x + F(\text{Norm}(x))$ 。
5. FFN 内部升维后, 通常需要回到 d_{model} 才能与 residual stream 相加。
6. GPT 类 decoder-only 模型不需要 Causal Mask。

B. 简答

- 1) 一个 Transformer Block 的四个核心组成是什么?
- 2) Residual Connection 为什么写成 $y = x + F(x)$? 它解决了什么问题?
- 3) LayerNorm 的主要目的是什么? 它和 BatchNorm 的直觉区别是什么?
- 4) Pre-Norm 与 Post-Norm 的结构差异是什么?
- 5) FFN 为什么可以理解为“逐 token 本地加工”?
- 6) 为什么 FFN 常把 d_{model} 暂时升到更大的 d_{ff} ?
- 7) Attention 与 FFN 在一个 Block 中的功能分工是什么?
- 8) 为什么一个 Block 的输入输出通常都保持 $[n, d_{\text{model}}]$?

答案

A: 1 错; 2 对; 3 错; 4 对; 5 对; 6 错。

B:

- 1) Multi-Head Attention、Residual Connection、Norm (LayerNorm/RMSNorm) 和 FFN/MLP。
- 2) 让原信息沿 shortcut 直接保留, 子层只学习增量 $F(x)$, 同时改善深层网络的信息和梯度传递。
- 3) 稳定单个 token 特征维度的数值尺度; LayerNorm 不依赖同 batch 其他样本的统计量, 而 BatchNorm 依赖跨 batch 统计。
- 4) Pre-Norm: $y=x+F(\text{Norm}(x))$; Post-Norm: $y=\text{Norm}(x+F(x))$ 。
- 5) 标准 FFN 对每个位置使用相同权重独立计算, 不显式读取其他 token。
- 6) 在更宽特征空间中进行更丰富的非线性组合, 再投影回 residual stream 的 d_{model} 。
- 7) Attention 主要负责 token 间信息路由; FFN 主要负责每个 token 的非线性特征加工。
- 8) 这样才能做 Residual Add, 并让多个 Block 按同一接口稳定堆叠。

C. 科研思考

- 如果论文只写 “we use a Transformer backbone”, 你还需要检查哪些 Block 细节才能复现实验?
- 如果把 FFN 的 d_{ff} 大幅缩小, 而 Attention 不变, 你预测会影响哪些能力/成本? 如何做消融实验?
- 如果一个 Agent benchmark 上模型表现退化, 怎样区分问题来自底层 LLM 的 Transformer 能力, 还是 Agent 的 memory/tool/context 编排?