

第12讲练习题与答案

建议

先独立回答，再看答案。目标是能“画结构 + 解释信息流”，不是背名词。

1. GPT 三个字母分别代表什么？每个词说明了什么？

答案

Generative: 可以生成 token; Pre-trained: 先进行大规模预训练; Transformer: 采用 Transformer 架构作为骨干。

2. Encoder-only 与 Decoder-only 的最核心信息流差异是什么？

答案

Encoder-only 的 Self-Attention 通常允许每个位置读取左右文; Decoder-only 使用 Causal Mask, 每个位置只能读自己及左侧历史。

3. 为什么 GPT

训练时可以一次并行算很多位置，却仍然满足“不能看未来”？

答案

整段 token 可以同时送入网络，但 Causal Mask 会在 Attention score 上屏蔽未来位置，因此每个查询位置虽然并行计算，却不能利用未来 token。

4. Cross-Attention 中 Q、K、V 分别来自哪里？

答案

典型 Encoder-Decoder 中，Q 来自 Decoder 当前 hidden states; K/V 来自 Encoder 输出。

5. 为什么 Decoder-only 也叫 Decoder，哪怕它没有 Encoder？

答案

它源自原始 Transformer Decoder 的结构路线，保留 Causal Self-Attention 等组件，但去掉依赖 Encoder 的 Cross-Attention，形成 Decoder-only。

6. 请解释 Autoregressive。

答案

模型根据已有前缀预测下一个 token，把新 token 追加回上下文，再预测下一个；前一步输出参与下一步条件。

7. LM Head 做什么？

答案

把最后的 `d_model` hidden state 投影到词表大小 $|V|$ 的 logits，让模型可以对每个候选 token 打分。

8. BERT 为什么适合“理解/表示”类任务？

答案

其双向 Self-Attention 能直接融合左右上下文，经典 MLM 预训练也鼓励用完整上下文恢复信息，因此很适合构造上下文文化表示。

9. 为什么不能说 Encoder 一定比 Decoder “更懂语言”？

答案

可见性不同只是架构约束之一；最终能力还取决于规模、数据、训练目标、优化、任务等，不能把双向可见性直接等同于总体智能。

10. 为什么 Decoder-only 很适合 Prompt 统一接口？

答案

问答、翻译、分类、代码、工具调用等都可以编码成一段前缀，让模型继续生成后续 token，从而统一成 next-token prediction 接口。

11. “Cross-Attention = RAG” 这句话为什么不准确？

答案

Cross-Attention 是神经网络层内部的连续向量注意力；RAG 是系统级检索流程，通常先用检索器找文档，再把文档放进上下文。层级和机制不同。

12. 画出一个 GPT 类模型的最小数据流。

答案

Token IDs $\rightarrow$ Embedding + Position $\rightarrow$ Causal Transformer Blocks $\times N \rightarrow$ Final Norm $\rightarrow$ LM Head $\rightarrow$ logits/Softmax $\rightarrow$ next token $\rightarrow$ 追加回上下文。