

# 第14讲核心概念速查卡：LLM 训练数据

| 概念                    | 一句话解释                    | 科研时要问什么               |
|-----------------------|--------------------------|-----------------------|
| Data Source           | 模型长期看到的数据来源              | 来源、版本、时间范围是什么？        |
| Parsing               | 从网页/文件中抽取真正内容            | 正文、代码、结构是否被正确保留？      |
| Quality Filtering     | 剔除低质量或不需内容               | 过滤标准会不会引入新偏差？         |
| Dedup                 | 删除完全/近似重复数据              | 文档级还是片段级？如何处理近似重复？    |
| Data Mixture          | 控制不同来源的采样比例              | 代码/数学/网页等各占多少？        |
| Synthetic Data        | 由模型或程序生成训练样本             | 有没有验证器？错误是否会被放大？      |
| Contamination         | 测试信息进入训练数据               | benchmark 是否可能被预训练见过？ |
| Privacy               | 训练数据包含个人/敏感信息的风险         | 是否检测、过滤、做泄露测试？        |
| Continued Pretraining | 在 Base Model 上继续用未标注数据训练 | 新数据会不会导致分布偏移/遗忘？      |

## 全流程

原始数据 -> 解析 -> 过滤 -> 去重 -> 配比 -> Tokenizer/Packing -> Batch -> Training

## 最重要的研究习惯

看到模型能力或 benchmark 分数时，不只问“模型多大”，还要问“它训练时到底看过什么、以什么比例看过、测试数据是否可能泄漏”。