

第14讲练习题与答案

建议先独立作答，再看后面的参考答案。

1. 为什么原始网页通常不能直接用于 LLM 预训练？

至少写出 3 个原因。

2. Dedup 和 Quality Filtering 有什么区别？

分别举一个例子。

3. 如果同样训练 1 万亿 token，为什么 Data Mixture 不同会导致能力差异？

请从梯度来源角度解释。

4. “数据越多越好”为什么不严谨？

至少给出 3 个反例。

5. Synthetic Data 的主要优势和主要风险分别是什么？

不要只回答“便宜”和“会出错”。

6. Benchmark Contamination 为什么会让评测分数失真？

说明“记忆”和“泛化”的区别。

7. 为什么公开网页中的个人信息仍然可能带来隐私问题？

从训练记忆和输出泄露两个阶段回答。

8. Continued Pretraining、Instruction Tuning、RAG 有什么区别？

分别说明是否修改参数以及主要目的。

9. 一个模型会写某段从未见过的代码，是否说明“模型不依赖训练数据”？

解释为什么。

10. Agent Systems 场景：两个 Agent 使用同一底座，但长期读取不同资料库。你认为它们为什么可能逐渐形成不同错误模式？

请从 $\text{Experience} = \text{Data Exposure}$ 的角度解释。

参考答案

1. 原始网页含广告、导航、脚本、乱码、模板和大量重复；还可能含低质量、敏感或不适合训练的数据，因此需要正文解析、过滤和去重。
2. Quality Filtering 关注“这条数据值不值得保留”，例如删除 SEO 垃圾页；Dedup 关注“同一或近似内容是否重复出现”，例如同教程被转载 100 次。
3. 每类 token 被采样的概率不同，会长期改变梯度来自哪些任务和领域。代码 token 比例更高，就会有更多参数更新由代码模式驱动。
4. 更多数据可能是重复数据、低质量数据、单一领域数据，或者超出训练算力能有效利用的范围，因此边际收益可能很低甚至带来偏移。
5. 优势包括可控制难度、补充稀缺场景、生成结构化监督；风险包括教师模型错误复制、分布变窄、模板化和验证器盲区。
6. Benchmark 本应测试未见样本上的迁移。如果原题/答案进入训练集，高分可能来自记忆或近似匹配，而不是对新问题的泛化。
7. 公开可见不等于适合模型反复训练。独特或重复的个人信息可能被模型记忆，并在特定提示下被重新生成，因此采集和部署两端都需控制。
8. Continued Pretraining 修改参数，继续学习新的未标注分布；Instruction Tuning 修改参数，学习指令-回答行为；RAG 通常不改模型参数，在运行时检索外部资料。
9. 不是。泛化本身来自训练数据中学到的语法、API 模式、算法结构等统计规律的重新组合。未见过完全相同样本不等于不依赖训练数据。
10. 长期读取不同资料库相当于经历不同的数据分布。它们的 memory、上下文、策略适应和后续决策依据不同，因此错误相关性、专长和偏差可能逐步分化。