

第15讲核心概念速查卡：Scaling Law

概念	一句话解释	最容易犯的错
N: Parameters	可学习参数数量，近似反映模型容量	把参数量直接当“智能值”
D: Training Tokens	训练时实际处理的 token 数	把硬盘数据量当训练数据量
C: Compute	训练消耗的计算量/FLOPs	忽略 N 与 D 的联动
Scaling Law	loss 随规模变化呈可拟合经验规律	当成永远精确的物理定律
Undertrained	模型容量大，但训练 token 相对不足	误以为参数多就一定充分学习
Compute-optimal	固定训练预算下合理分配 N 与 D	只追求最大模型
Chinchilla	强调很多模型应训练更多 token	机械背“20 token/参数”
Emergence	任务指标可能在某规模附近突然跃升	把阈值现象都解释成神秘能力
MoE	总参数多，但每 token 只激活部分专家	直接拿总参数和 Dense 横比

两个关键公式

粗略训练算力： $C \approx 6ND$ ；教学用幂律直觉： $L(x) \approx L_{\infty} + A \cdot x^{-\alpha}$ 。二者都应理解为数量级/经验模型，而不是绝对定律。

Agent 实验提醒

比较单 Agent 与多 Agent 时，要控制总模型调用、总 token、工具调用和推理预算；否则你测到的可能只是“花了更多 compute”。