

第15讲练习题与答案

建议先独立作答，再看参考答案。

1. N、D、C 分别代表什么？

请不要只写英文缩写，要说明它们为什么相互制约。

2. 为什么“70B 一定比 7B 强”是不严谨的？

至少列出 4 个还需要知道的变量。

3. 什么叫 Undertrained？

用自己的话举一个模型过大、数据不足的例子。

4. 固定训练 compute 时，为什么 N 和 D 像跷跷板？

从 $C \approx 6ND$ 的直觉解释。

5. Chinchilla 的核心思想是什么？

不要只回答“20 tokens/parameter”。

6. 为什么 20 tokens/parameter 不能当作永恒定律？

至少列出 3 个会改变最优配比的因素。

7. 什么叫边际收益递减？

说明为什么这会影响工业界的训练决策。

8. 为什么“涌现能力”有时可能受评测指标影响？

用 exact match 阈值举例。

9. 为什么 MoE 的总参数量不能直接与 Dense 模型横向比较？

解释 active parameters。

10. Agent Systems 场景：4 个 Agent 总共调用模型 20 次，单 Agent 只调用 1 次。若多 Agent 得分更高，可以直接说明协作有效吗？

请从 compute budget 的角度设计更公平的对照。

参考答案

1. N 是参数量，决定模型可学习容量； D 是训练 token 数，决定模型接受多少训练信号； C 是训练计算量。对 Dense 模型可粗略理解 C 与 $N \times D$ 同阶，因此预算固定时 N 和 D 会互相挤占。
2. 还需要知道训练 token 数、数据质量和配比、训练 FLOPs、架构、优化方法、是否 MoE、上下文长度、后训练方式等。参数量只是一个维度。
3. Undertrained 指模型容量相对很大，但给它的训练 token/更新不够。例如把参数量扩大 10 倍，却在固定算力下把训练 token 大幅减少，模型可能没有充分利用新增容量。
4. 若 C 固定且近似 $C \approx 6ND$ ，那么 N 增大时 D 必须下降才能维持相同计算预算； D 增大时则 N 需要降低。因此要寻找平衡点。
5.
核心是重新寻找固定训练算力下参数量与数据量的最优分配，并指出许多当时的大模型相对于模型规模训练 token 太少。
6. 最优比例会受架构、数据质量、重复训练、上下文长度、MoE、优化器、推理部署成本以及目标任务影响，因此不能把一个历史经验比例机械推广。
7. 规模继续增加通常仍有收益，但单位新增能力需要越来越多算力。工业界必须比较额外成本与额外收益，而不是只追求最大数字。
8. 底层能力可能从 0.49 平滑到 0.51，但 exact match 只看最终答案是否完全正确。当跨过决策阈值后，分数可能从 0 突然变 1，看起来像能力“突然出现”。
9. MoE 可能拥有很大的总参数库，但每个 token 只激活少数专家，因此一次前向实际使用的 active parameters 远少于 total parameters。计算成本也不等同于同总参数的 Dense 模型。
10. 不能直接说明协作有效，因为多 Agent 使用了更多 test-time compute。应至少设置 compute-matched baseline，例如让单 Agent 也获得相同总调用数/总 token/工具预算，再比较性能、可靠性和成本。