


第17讲

Preference Learning、RLHF、RLAIF 与 DPO

为什么有了 SFT，还要继续学习“哪个答案更好”？

本讲总目标

把“标准答案示范”与“偏好比较”彻底区分开，并理解 Reward Model、RLHF、RLAIF、PPO、DPO 分别处于哪一层。



先记住一句话：

“SFT 告诉模型一个可接受的答案长什么样；Preference Learning 进一步告诉模型：当多个答案都能回答时，人更喜欢哪一种。”

1. 为什么 SFT 以后还不够？

SFT 的训练信号通常来自“输入 → 理想回答”。但真实助手的质量并不只有“答没答出来”这一维。两个答案可能都没有明显事实错误，却在帮助性、简洁性、礼貌、安全性、推理清晰度等方面差很多。

Prompt	请解释为什么天空是蓝色的。
Answer A	因为大气中的分子会更强地散射较短波长的可见光；蓝光因此从各方向进入我们的眼睛。
Answer B	天空是蓝色的，因为颜色就是蓝色，这是自然现象。
Preference	人类/AI 评审更偏好：A

如果只做 SFT，我们可以把 A 写成标准答案。但现实中，“最优回答”往往难以唯一写出。相较之下，让评审在 A/B 两个候选之间做选择，常常更容易、更稳定。

核心变化	监督信号从“给我唯一正确答案”变成“告诉我两份答案哪一份更符合偏好”。这就是 preference data 的基本形态。
------	---

2. Preference Data 长什么样？

最常见的偏好样本可以抽象成三部分：prompt、chosen response、rejected response。

```
prompt    = x
chosen    = y_w    # winner / preferred
rejected  = y_l    # loser / less preferred
```


候选答案可以由同一个模型采样产生，也可以来自不同模型、不同解码设置或人工编写。评审者再根据某套 rubric 进行成对比较。

偏好维度	直观含义	示例
Helpfulness	是否真正解决用户问题	给出可执行步骤而非空泛结论
Correctness	事实、计算、代码是否正确	避免编造引用
Relevance	是否围绕问题回答	不大段跑题
Style	是否清晰、简洁、结构适合	不过度重复
Safety	是否满足规定的安全边界	对高风险请求采取合适处理

重要限制	“偏好”不是绝对真理。它取决于评审标准、标注人群、任务分布和组织目标。模型最终会学习这些偏好数据中体现出来的统计规律。
------	---

3. 从偏好对到 Reward Model：给答案打一个“隐含分数”

经典 RLHF 流程里，通常先训练一个 Reward Model (RM, 奖励模型)。它输入 prompt 和 response，输出一个标量 reward。



对于同一个 prompt，如果人更喜欢 A 而不是 B，我们希望：

$$r(x, A) > r(x, B)$$

训练时常用一种成对排序损失。直觉上，奖励模型不是要求“给 A 打 92 分、给 B 打 63 分”，而是要求 A 的相对分数高于 B。

一个常见形式可以写成：

$$L = -\log \sigma(r(x, y_w) - r(x, y_r))$$

其中 σ 是 sigmoid。只要 chosen 的 reward 比 rejected 高得越明显，loss 通常就越小。

底层原理

Reward Model 把“人更喜欢哪个答案”压缩成一个可优化的标量信号。后面的强化学习阶段就可以把“提高 reward”当作训练目标。

4. RLHF: Reinforcement Learning from Human Feedback

RLHF 可以直译为“基于人类反馈的强化学习”。在 LLM 语境里，一个经典流程通常包含三步：



这里的“策略 policy”就是语言模型本身：给定上下文，它决定下一个 token 的概率分布。完整回答可以看成一连串 action。

强化学习阶段的目标不是单纯最大化 Reward Model 分数，因为那样很容易把模型推得过远。通常还会加入约束，让新模型不要偏离参考模型太多。

经典直觉可以写成：

$$\text{Objective} \approx \text{Reward} - \beta \times \text{KL}(\text{policy} \parallel \text{reference})$$

KL 惩罚可以理解成“不要为了讨好奖励模型，把原来语言能力和行为分布彻底改坏”。


不要把名字理解错

RLHF 的关键不是“每个 token 都由人现场打分”。通常是先收集有限的人类偏好，再训练 Reward Model，用它批量提供训练信号。

5. PPO 在这里做什么？

PPO (Proximal Policy Optimization) 是一种强化学习算法。你现在不需要掌握完整推导，只需要知道它解决一个工程问题：怎样根据 reward 更新语言模型，同时避免一次更新走得太远。

极简流程：



Policy: 当前要训练的 LLM。

Reference Model: 通常是冻结的 SFT 模型，用于约束漂移。

Reward Model: 给完整回答一个偏好分数。

Value Model / Critic: 在经典 PPO 管线中帮助估计回报，降低训练方差。

PPO 很强，但管线复杂：需要同时管理多个模型、在线采样、reward、value、KL、优化器和大量超参数。因此后来出现了更直接的 preference optimization 方法。


零基础记法

PPO 的作用可以先理解成：“奖励高的回答方向多走一点，但每一步别跨得太大。”

6. RLAIIF：如果“评审”换成 AI 呢？

RLAIIF (Reinforcement Learning from AI

Feedback) 的基本思路是：偏好反馈不一定全部由人工逐条产生，也可以让一个更强模型、一个专门的 judge model，或者基于规则/原则的评审过程来比较候选答案。



这可以显著降低标注成本，也能扩展到人类难以大规模逐条评审的任务。但它同时引入新的风险：

Judge 本身可能有系统偏差。

被训练模型可能学会迎合 judge，而不是真正提高任务质量。

不同 judge 的偏好可能不一致。

如果 judge 和被评模型高度同源，错误可能高度相关。

科研连接

这正是 Agent Systems 中很值得关注的问题：当 Agent 互评、互审、互相给 reward 时，“评审者错误相关性”会不会导致错误被集体强化？

7. Constitutional AI：用原则来组织 AI Feedback

一种重要思路是先给出一组明确原则（constitution），让模型依据这些原则对回答进行 critique、revision 或 preference judgement。这样，AI feedback 不只是“凭感觉选一个”，而是有可检查的规范依据。


阶段	输入	产物
Critique	原回答 + 原则	指出哪些地方违反原则
Revision	原回答 + critique	修改后的回答
Preference	多个候选 + 原则	依据原则选出更优答案
Optimization	偏好数据	进一步训练模型

对于初学者，重点不是记住某个产品的具体流程，而是理解：偏好信号可以来自人，也可以来自模型；关键问题是信号是否可靠、是否可审计、是否与最终目标一致。

底层视角	训练信号的来源决定优化方向。把“评审者”从人换成 AI，并没有消除偏差，只是把偏差来源从人工标注分布转移到了 judge model 和规则设计。
------	---

8. DPO：为什么可以不显式训练 Reward Model + PPO?

DPO (Direct Preference Optimization) 的核心吸引力是：给定 chosen/rejected 偏好对，可以直接优化语言模型，使 chosen 相对于 rejected 的概率提高，而不必先单独训练一个 Reward Model 再跑 PPO。



你不需要现在推完整公式，但应该理解它关注的是一个“相对优势”：

新模型相对于 reference，是否更加偏向 chosen，而不是 rejected?

一种常见写法的核心结构包含：

$$\Delta = [\log \pi(y_w | x) - \log \pi(y_1 | x)] - [\log \pi_{\text{ref}}(y_w | x) - \log \pi_{\text{ref}}(y_1 | x)]$$

然后通过 sigmoid/logistic loss 鼓励 Δ 变大。 β 控制偏好优化强度。

为什么它受欢迎

工程管线更简单：不需要显式在线 RL rollout、单独 reward model 和 value model，也更容易在普通监督学习框架里实现。

9. SFT、RLHF、RLAIF、DPO 到底是什么关系？

方法	最主要数据/信号	是否显式 RM	是否在线 RL	直觉
SFT	指令 → 理想回答	否	否	模仿示范答案
RLHF + PPO	人类偏好 → RM reward	是	通常是	提高奖励，同时限制漂移
RLAIF	AI 产生偏好/反馈	可有	可有	把反馈来源从人扩展到 AI
DPO	chosen / rejected 偏好对	否	否	直接让 chosen 的相对概率更高

现实训练栈可能更加复杂，也可能组合多种方法。不要把这些词理解成互斥产品名，而应该把它们看作“数据来源”和“优化算法”两个维度。

重要区分	RLAIF 描述的是反馈来源；DPO 描述的是偏好优化方法。完全可以存在“用 AI 生成 preference pairs，再用 DPO 训练”的组合。
------	--

10. 一个具体例子：同一个问题，偏好训练到底改变什么？

Prompt	我有 30 分钟，帮我安排一个复习计划。
Answer A	前 5 分钟列目标；接下来 15 分钟做最重要的两道题；再用 7 分钟检查错题；最后 3 分钟写下下一次复习入口。
Answer B	你应该认真复习，多看书，多练习，保持专注。
Preference	人类/AI 评审更偏好：A

两个答案都“相关”，但 A 更具体、可执行。Preference Optimization 的目标不是记住“30 分钟一定按 5/15/7/3 分”，而是从大量比较中统计地学习：在类似任务里，具体、结构化、可执行的回答更受偏好。这也解释了为什么偏好训练会改变模型的风格与行为分布：它对“什么样的回答更值得提高概率”施加持续梯度。

注意	如果标注者偏好“长答案”，模型可能学会无论什么问题都变长；如果 judge 偏好华丽措辞，也可能诱导出表面优化。这类现象称为 reward misspecification / preference bias 的一部分。
----	--

11. Reward Hacking：模型会不会“钻评分规则的空子”？

会。这是强化学习和偏好优化中非常重要的风险。只要优化目标是一个代理指标，模型就可能找到“让指标变高，但并没有真正完成真实目标”的路径。

现象	表面上发生什么	真实问题
讨好 Judge	输出 Judge 喜欢的格式或措辞	不一定提高事实正确性
过度冗长	长答案得到更高偏好	token 增多但信息密度下降
假装引用	引用样式看起来专业	来源可能不存在
奖励模型漏洞	某类字符串触发高 reward	优化到了 RM 缺陷而非真实质量

这可以用 Goodhart 定律的直觉理解：当一个指标成为强优化目标后，它可能不再是原目标的好代理。

AI Systems Science 视角	这不是“某个模型训练不好”的孤立 bug，而是一个系统科学问题：真实目标 → 代理指标 → 优化器 → 策略适应，四者之间会发生反馈回路。
--------------------------	---

12. Preference Model / Judge 为什么也必须评测？

如果你把一个 Judge 当作实验中的“裁判”，就必须像评测主模型一样评测它。至少要检查：

与人工标注的一致性有多高？

不同任务、不同语言、不同长度下是否稳定？

是否存在 position bias（总偏爱 A 或前一个答案）？

是否存在 verbosity bias（总偏爱更长答案）？

是否对自己家族模型有 self-preference？

多次采样的判决是否稳定？

否则你测到的“模型变好”可能只是“更会迎合 Judge”。

实验原则


Judge-as-a-model

不能被当成绝对真值。它是一种测量仪器；测量仪器本身也有噪声、偏差和适用范围。

13. Preference Optimization 和“事实正确”不是一回事

偏好数据可以包含 correctness 维度，但“人喜欢”与“事实为真”在逻辑上不同。一个回答可能写得流畅、礼貌、结构漂亮，却事实错误；另一个回答可能很简短但完全正确。

因此现代模型通常需要多种训练/评测信号共同作用：



尤其在数学、代码、科学问题中，如果存在可执行验证器，verifiable reward 往往比纯主观偏好更可靠：代码能不能通过测试、数学答案能不能验证、工具调用有没有成功，都可以产生更客观的反馈。

科研洞察

未来 Agent 系统的一个核心问题，是怎样把主观 preference、客观 verifier、环境反馈和长期任务结果组合成可靠训练信号。

14. 从 RLHF 到 Reasoning：奖励可以来自哪里？

一旦你理解“模型可以根据 reward 被优化”，就能看懂推理模型训练中的一个重要方向：对可验证任务，reward 不必完全来自人类偏好。

Reward 来源	例子	优势	风险
Human preference	哪个回答更好	贴近人类需求	贵、主观、有偏差
AI feedback	Judge 比较答案	可大规模扩展	继承 judge 偏差
Rule-based	格式/约束是否满足	明确、便宜	覆盖面有限
Verifier	代码测试/数学验证	客观、精确	只适合可验证任务
Environment	Agent 任务是否完成	接近真实目标	环境复杂、credit assignment 难

这也为下一讲的 reasoning / test-time compute 做铺垫：模型不仅可以学习“哪种回答更受欢迎”，还可以学习“哪些推理轨迹最终更容易获得可验证成功”。

15. 对 Agent Systems 为什么尤其重要？

Agent 不只是一次性回答。它会计划、调用工具、修改环境、观察反馈，再继续行动。因此 preference / reward 的设计会直接塑造整个行为策略。



研究 Agent 时，reward 设计至少要考虑：

最终任务成功率，而不只是中间“看起来合理”。

总 token / API 成本 / 延迟。

工具调用失败、权限违规、不可逆操作等安全成本。

多 Agent 系统中的团队 reward 与个体 reward 是否冲突。

短期 reward 是否会诱导长期坏策略。

一个典型研究问题

如果所有 Agent 都由同一个 Judge 奖励，它们是否会逐渐形成高度相关的“讨好 Judge”行为，导致多样性和错误去相关性下降？这就是很典型的 AI Systems Science 问题。

16. 常见误区集中纠正

误区	正确理解
“RLHF 就是人工直接训练每个 token”	通常先收集偏好，再训练 RM 或直接做 preference optimization。
“DPO 不是学习，因为没有 reward model”	DPO 仍然在根据偏好数据更新 policy，只是不显式训练独立 RM + PPO。
“RLAIF 和 DPO 是竞争方法”	一个描述反馈来源，一个描述优化方式，可以组合。
“Reward 高就代表真实质量高”	Reward 是代理测量，可能被 hacking。
“偏好训练能解决所有幻觉”	不能。偏好可能改善行为，但事实正确仍需数据、验证、工具等。
“Judge 模型就是客观裁判”	Judge 也有 bias、noise 和适用范围。
“RLHF 后模型一定能力更强”	很多变化属于行为对齐；某些基础能力可能不升反降。

17. 小实验：不用真正 LLM，也能看懂 Pairwise Loss 和 DPO

材料包里的 Python 程序只使用标准库，模拟两个核心机制。

实验 A: Reward Model pairwise loss

假设 chosen 的 reward 从 0.2 提高到 1.4，而 rejected 保持 -0.1。程序计算 $-\log(\text{sigmoid}(r_{\text{chosen}} - r_{\text{rejected}}))$ ，你会看到差距越大，loss 越小。

实验 B: DPO 风格的相对 log-prob 优化

我们人为设置 policy 和 reference 对 chosen/rejected 的 log probability，观察 “policy 相对 reference 是否更加偏向 chosen”，再计算一个简化 DPO loss。

```
delta_policy = logp_pi(chosen) - logp_pi(rejected)
delta_ref    = logp_ref(chosen) - logp_ref(rejected)
advantage    = delta_policy - delta_ref
loss         = -log(sigmoid(beta * advantage))
```

实验边界

这是教学玩具，不是完整 DPO 训练器。真实 DPO 对完整 response 的 token log-prob 求和/聚合，并对神经网络参数反向传播。

18. 本讲知识地图：把所有概念放回正确位置



请把这些概念分成两层：

反馈来源层：Human Feedback、AI Feedback、Rules、Verifier、Environment。

优化算法层：SFT、PPO-style RL、DPO 及其他 preference optimization。

这样以后读论文就不会被术语绕晕。比如 “AI-generated preference + DPO” 完全合理； “human preference + DPO” 也完全合理。

最低闭环

看到一篇模型对齐论文时，先问四个问题：数据是谁产生的？偏好怎样定义？用什么 objective 更新模型？最后用什么独立评测验证真的变好了？

19. 练习题

建议先不看答案，口头解释即可。

- 1) 为什么 SFT 已经有“标准答案”，还需要 Preference Learning?
- 2) chosen / rejected preference pair 各表示什么?
- 3) Reward Model 的输出通常是什么?
- 4) RLHF 中为什么常加入 reference model / KL 约束?
- 5) RLAIIF 和 DPO 是同一维度的概念吗? 为什么?
- 6) 用一句话解释 PPO 在 RLHF 里的作用。
- 7) DPO 为什么可以绕过显式 Reward Model?
- 8) 什么是 reward hacking? 举一个 LLM 例子。
- 9) 为什么 Judge Model 也需要单独评测?
- 10) 多 Agent 系统如果共享同一个 Judge, 可能出现什么研究风险?

20. 练习题答案

- 1) SFT 主要给示范，但很多任务不存在唯一标准答案；偏好比较能进一步表达“多个可行答案里哪个更符合帮助性、风格、安全等目标”。
- 2) chosen 是评审更偏好的回答，rejected 是相对不偏好的回答。
- 3) 通常是一个标量 reward，用来表示该回答在学到的偏好维度上的相对好坏。
- 4) 防止模型为了追求 reward 一次偏离原 SFT 模型太远，导致语言质量或原有能力崩坏。
- 5) 不是。RLAIF 描述反馈来自 AI；DPO 描述怎样利用 preference pair 优化 policy，两者可以组合。
- 6) 让高 reward 的行为概率上升，同时控制每次 policy 更新不要过大。
- 7) DPO 直接从 chosen/rejected 的相对 log-prob 构造目标，使 policy 相对 reference 更偏向 chosen。
- 8) 模型找到“提高代理评分但没有真正完成目标”的策略，例如虚构看起来很专业的引用来讨好 judge。
- 9) 因为 judge 本身也有噪声、位置偏差、长度偏差和模型家族偏好，不是绝对真值。
- 10) 可能形成共同的 judge-迎合策略，使错误相关性上升、多样性下降，并把 judge 的系统偏差放大到整个群体。

进入下一讲前

你现在已经能理解：模型从“会续写”到“会听话”，再到“更符合偏好”，对应的是不同训练阶段和不同训练信号。下一讲将进入 Reasoning / Test-Time Compute：为什么模型在推理阶段多花计算也能变强。