

第17讲 · Preference Learning / RLHF / RLAIIF / DPO 速查卡

一、核心链路

SFT → 生成多个候选 → 收集 chosen/rejected → Reward Model (可选) → PPO 或 DPO
→ 行为进一步塑形

二、四个概念

RLHF: 反馈主要来自人类偏好; 经典管线常含 RM + PPO。

RLAIIF: 反馈主要由 AI judge / critique 产生。

PPO: 一种 RL 更新算法, 奖励高的方向多走, 但限制更新幅度。

DPO: 直接用 preference pairs 提高 chosen 的相对概率, 无需显式 RM + PPO。

三、关键公式直觉

Pairwise RM:

$$L = -\log \sigma(r(\text{chosen}) - r(\text{rejected}))$$

DPO: 比较 policy 与 reference 对 chosen/rejected 的相对 log-prob 差。

四、科研检查清单

1. 谁产生 feedback?
2. 偏好 rubric 是什么?
3. Judge 是否有 bias?
4. 用什么 objective 更新?
5. 是否有独立 test set / human eval?
6. 是否存在 reward hacking?

一句话记忆

SFT = 学 “怎么答” ; Preference Learning =
学 “多个能答的答案里, 人/评审更喜欢哪一个” ; Reward/Judge
只是代理测量, 不等于真实目标。