

第17讲 · 练习题与答案

Preference Learning / RLHF / RLAIIF / DPO

A. 基础概念

1. SFT 与 Preference Learning 的监督信号有什么不同？
2. chosen/rejected pair 为什么比要求标注者写“唯一标准答案”更容易扩展？
3. Reward Model 为什么只需要学相对排序，不一定需要绝对分数？
4. PPO 为什么通常需要限制 policy 偏离 reference？
5. RLAIIF 的优势和主要风险分别是什么？
6. DPO 的输入数据通常是什么？
7. 为什么 DPO 不等于“没有 reward 概念”？
8. Judge model 的 position bias / verbosity bias 是什么？
9. reward hacking 与普通模型错误有什么不同？
10. Agent 系统里 environment reward 为什么可能比纯语言偏好更可靠？

B. 场景判断

场景1: 研究者让同一个 LLM Judge 给所有多 Agent 对话打分, 发现经过多轮优化后所有 Agent 的写作风格越来越一致。请指出至少两个可能机制。

场景2: 一个模型在 DPO 后 human preference 胜率提高, 但数学可验证题准确率下降。你会如何解释?

场景3: 代码 Agent 的 reward 只看“输出中是否包含 Done”。可能出现什么 reward hacking? 更合理的 reward 应如何设计?

场景4: 两种模型对比时, 一个使用更强的 Judge 过滤训练数据, 另一个没有。为什么不能简单把最终差异都归因于模型架构?

参考答案

1. SFT 用示范回答作为 token 级监督; Preference Learning 用候选间相对偏好作为主要信号。
2. 很多开放任务没有唯一写法, 但人更容易做二选一比较。
3. 优化只需知道 chosen 应高于 rejected; 绝对 0-100 分并非必要。
4. 防止为 reward 过度漂移, 破坏语言能力和原有行为。
5. 优势: 便宜、可扩展; 风险: judge 偏差、错误相关、迎合 judge。
6. prompt + chosen response + rejected response, 通常还需要 reference policy。
7. DPO 可以从偏好概率模型推导出隐式 reward 结构, 只是不显式训练独立 RM。
8. Position bias 是偏爱前/后位置; verbosity bias 是偏爱更长答案。
9. Reward hacking 是模型针对代理评分机制形成策略性高分行为, 真实目标却未改善。
10. 如果环境能客观验证任务完成、工具调用成功或测试通过, 它更接近真实结果。

场景1: 共享 Judge 会形成共同选择压力; Judge

可能偏好某种格式; 模型之间错误相关性会被放大; 多样性下降。

场景2: 偏好训练优化了人类/评审偏好的行为分布, 但可能牺牲基础数学能力; 也可能 human eval 更看表达而非 correctness。需要可验证数学集独立评测。

场景3: Agent 可能只打印 Done

而不执行任务。应以真实环境状态、测试是否通过、文件是否正确生成等作为 reward。

场景4: 训练数据筛选/反馈质量本身就是干预变量, 属于 confounder, 需要控制或做消融。