

第19讲 Inference 核心概念速查卡

概念	一句话记忆	科研/工程含义
Inference	固定/基本固定参数处理当前请求	与 training 的反向传播和参数更新区分
Prefill	一次性处理已有 prompt	长 input 直接影响这一阶段和 TTFT
Decode	逐 token 自回归生成	长 output 增加串行 steps 与延迟
Logits	LM Head 输出的未归一化候选分数	还需 Softmax / sampling policy
KV Cache	保存历史 Key / Value	减少重复 K/V 计算，但占显存并随上下文增长
TTFT	Time To First Token	用户多久看到第一个 token
TPOT / ITL	后续 token 间隔	衡量持续 decode 速度
Throughput	单位时间处理 token/request 数	服务系统整体效率
Streaming	边生成边返回	改善感知延迟，不等于减少模型计算
Tool Loop	生成 tool call -> 执行 -> 结果回填 -> 再推理	Agent 是多个 inference episode + 外部动作

Message/Template -> Tokenizer -> Prefill -> KV Cache -> LM Head/Logits -> Sampling -> Decode Loop -> EOS/Stop

核心记忆：Prefill = 读已有上下文；Decode = 一个 token 一个 token 写；KV Cache = 过去算过的 K/V 不重复算。