

第20讲

Temperature、Top-k、Top-p

模型为什么同一个问题可以回答得不一样？

本讲主线

从 LM Head 输出 logits 开始，理解 Softmax、Greedy、Sampling、Temperature、Top-k 与 Top-p 如何共同决定 next token。



注意：不同推理框架的具体处理顺序可能略有差异

学习定位：把“模型为什么有随机性”从模糊感觉变成可计算、可控制、可做实验的概率机制。

1. 本讲学完，你应该能回答什么？

Logits 为什么不是概率？Softmax 做了什么？

Greedy Decoding 和 Sampling 的根本区别是什么？

Temperature 为什么能让概率分布变尖或变平？

Top-k 为什么是“固定候选数”？Top-p 为什么是“动态候选集合”？

为什么 Temperature 很低仍不一定保证系统级绝对确定性？

为什么多次独立采样能用于 Self-Consistency / Best-of-N？

为什么多 Agent 中简单提高 Temperature 不等于形成“真正功能性异质性”？

做论文实验时，为什么必须固定并报告 sampling 参数？

一句话预告

模型每一步先给整个词表打分；解码策略决定“从这些分数里怎样选出下一个 token”。

2. 回到第19讲：LM Head 输出的是 Logits

假设词表只有 6 个 token。模型最后一个 hidden state 经过 LM Head 后得到：

token	logit
model	4.2
system	3.4
agent	2.8
data	2.1
tool	1.6
banana	0.3

这些数字只是未归一化分数。它们可以为正、为负，也不需要相加等于 1。

logits = [4.2, 3.4, 2.8, 2.1, 1.6, 0.3]

关键

Logit 排名告诉你模型“更偏向谁”，但只有经过概率变换之后，才能进行概率采样。

3. Softmax：把一组任意分数变成概率分布

Softmax 的基本形式：

$$p_i = \exp(z_i) / \sum_j \exp(z_j)$$

它做三件事：

把每个值变成正数；

保留“高分更大”的相对关系；

让所有候选概率之和变成 1。

例如最高 logit 的 token 往往拥有最大概率，但不是必然等于

100%。所以即使“model”概率最高，Sampling 仍有可能选到“system”或“agent”。

不要误解

Softmax 不是在判断“事实真伪概率”。它只是把当前上下文下的 next-token 分数转成一个归一化分布。

4. Greedy Decoding: 每一步都选最高概率

最简单的解码方法是:

$$\text{next_token} = \text{argmax}_i p_i$$

如果当前概率最高的是“model”，就直接选择“model”。下一步再根据新的上下文重新计算。

优点: 简单、稳定、无需随机采样;

缺点: 局部最优不一定产生整体最优序列;

缺点: 对开放式写作可能显得单一;

缺点: 无法自然获得多个候选用于投票或搜索。

直觉

Greedy 像每个岔路都选眼前评分最高的路，但一连串“局部最好”不保证整条路径最后最好。

5. Sampling：按概率“抽签”，但不是乱选

Sampling 的意思是：如果当前分布是：

token	概率
model	0.50
system	0.25
agent	0.15
data	0.06
tool	0.03
banana	0.01

就按照这些概率抽取 next token。概率越高越容易被选，但低概率 token 仍可能偶尔出现。

这就是为什么同一个 prompt 多跑几次，可能出现不同回答。

重要

随机性发生在 token 选择阶段；模型参数和 logits 本身可以完全相同，但一次随机抽样就会让后续整条序列分叉。

6. 一个 Token 不同，后面整段都可能不同

自回归生成有“路径依赖”：

Prompt -> token A -> □□□□ A -> ...

Prompt -> token B -> □□□□ B -> ...

即使 A 和 B 只在第一个生成 token 上不同，从第二步开始它们已经拥有不同上下文，因此 logits 会继续变化。

所以“随机性”不是只影响某个局部词，而可能通过自回归循环逐渐放大，最后形成完全不同的段落、推理路径甚至工具选择。

Agent 连接

Agent 的早期一步 Action/Tool Choice

如果由采样导致分叉，后面的环境状态也会变化，差异会比普通文本生成更大。

7. Temperature：不是增加随机数，而是重塑概率分布

Temperature 的标准数学形式是：

$$p_i(T) = \exp(z_i / T) / \sum_j \exp(z_j / T), T > 0$$

它作用在 Softmax 之前的 logits 上。

Temperature	分布变化	直觉
T < 1	更尖锐，最高分 token 更占优势	更保守、更集中
T = 1	原始 Softmax	基准
T > 1	更平坦，次高概率候选得到更多机会	更多样、更分散
一个容易误解的点 Temperature 本身不直接“制造新知识”。它只是改变已有候选 token 的相对采样概率。		

8. 为什么除以 T 会产生这种效果？

假设两个 logits 是 4 和 2。它们原来的差距是 2。

设置	变换后的 logits	差距
$T = 0.5$	8 和 4	4 (差距放大)
$T = 1$	4 和 2	2
$T = 2$	2 和 1	1 (差距缩小)

Softmax 对分数差距非常敏感：差距越大，最大项越容易“吃掉”大部分概率；差距越小，概率会更平均。

因此：

低 T = 放大相对差距；高 T = 压缩相对差距。

9. Temperature 的极限直觉

$T \rightarrow 0+$: 分布越来越接近只选择最大 logit; 很多 API 会把 $\text{temperature}=0$ 特殊处理为近似 greedy, 而不是代入除法公式。

$T = 1$: 保持原始 Softmax 的相对尺度。

T 很大: 分布逐渐变平; 极限上更接近均匀, 但真实系统还可能有过滤、惩罚等其他处理。


对于确定性要求高的抽取、格式化、单元测试类任务, 经常希望更低随机性; 对于创意候选、搜索、Best-of-N, 通常会保留一定多样性。

注意

“低温 = 正确” “高温 = 错误” 都不成立。最优设置取决于任务、模型、解码策略和评价目标。

10. Top-k：只允许概率最高的 k 个候选参与

Top-k 的步骤可以理解成：



例如 $k=3$ 时，不管词表有 100,000 个 token，当前这一步只允许排名最高的 3 个 token 参与最终采样。

如果前三名是 model / system / agent，那么 data / tool / banana 本步概率直接变成 0。

特点

Top-k 的候选集合大小固定，但不关心“这 k 个概率总和到底覆盖了多少质量”。

11. Top-p：不是固定数量，而是覆盖足够概率质量

Top-p 又叫 Nucleus Sampling。它先按概率从高到低排序，然后选择“累计概率达到 p 所需的最小候选集合”。

例如当前概率：0.45, 0.25, 0.15, 0.08, 0.05, 0.02；如果 $p=0.80$ ：

候选	概率	累计
A	0.45	0.45
B	0.25	0.70
C	0.15	0.85 -> 到这里停止
D	0.08	不再保留

所以这一步会保留 A、B、C 三个 token。换一个上下文，可能只保留 2 个，也可能保留 30 个。

一句话

Top-k 固定“人数”；Top-p 固定“累计概率覆盖率”。

12. 为什么 Top-p 往往比固定 Top-k 更自适应？

考虑两种上下文：

场景	概率分布	Top-k=5	Top-p=0.9
模型非常确定	0.90, 0.05, 0.02, ...	仍保留5个	可能只保留很少候选
模型很不确定	0.08, 0.07, 0.06, ...	仍只保留5个	可能保留很多候选

因此 Top-p 会根据当前分布的“尖锐程度”动态改变候选集合大小。

但它也不是自动最优。p 太低会把合理候选过早砍掉；p 太高则可能允许很长的概率尾部参与。

13. Temperature、Top-k、Top-p 到底谁先谁后？

在工程实现中，解码器可能包含多个 logits processor / warper。常见高层逻辑是：



但是不同框架/API 的具体顺序、默认值和特殊情况可能不完全一样。

有一个数学细节值得知道：对于正 Temperature，Top-k 的排名通常不变；但 Temperature 会改变概率的相对集中程度，因此会影响 Top-p 需要保留多少 token。

科研规范

论文或可复现实验中，不要只写“使用默认采样”。最好明确记录 model/version、temperature、top_p、top_k（若有）、seed（若可控）、max tokens 等。

14. 一个完整的采样流程例子

假设模型 logits 为:

[4.2, 3.4, 2.8, 2.1, 1.6, 0.3]

设置: $T=1.0$, $\text{top-k}=4$, $\text{top-p}=0.85$ 。可以想成:

Step 1: Softmax 得到初始概率;

Step 2: Top-k 只保留前4个候选;

Step 3: 在剩余候选中按累计概率执行 Top-p;

Step 4: 把保留下来的概率重新归一化到和为1;

Step 5: 随机采样一个 token;

Step 6: 把 token 追加回上下文, 下一步重新计算全新的 logits。

核心

这些参数不是“一次设置后决定整段答案的词库”, 而是每生成一个 token 都会重新在新的分布上执行。

15. 为什么同样的参数，多跑几次仍然会不同？

只要最后一步是随机采样，就像按照加权骰子掷点：同一个概率分布可以产生不同结果。

如果每一步都有若干合理候选，那么几十、几百个 decode steps 串起来后，可能形成非常大量的可能序列。

这也是为什么开放式问答、写作和 Agent 规划往往存在明显的 run-to-run variance。

科研意义

只跑一次得到的结果，可能只是随机轨迹之一。研究 Agent 稳定性时应重复多次、报告均值/方差/成功率分布，而不是只展示“最好的一次”。

16. “设置 Temperature=0，就完全可复现吗？”

不能把它当成绝对保证。低温或 greedy 能消除主要的随机采样来源，但系统层面仍可能存在：

模型服务后端版本变化；

浮点运算与并行归约的非确定性；

MoE 路由、动态 batching 或 serving 实现差异；

API 提供方内部更新；

隐藏的 system prompt、tool schema 或上下文变化。

因此更准确的说法是：

Greedy / low-temperature 可以显著提高输出稳定性，但“严格逐 token 完全一致”还取决于整个推理栈。

实验建议

如果 API 支持 seed，记录 seed；同时保存原始 prompt、完整参数、模型版本标识和时间。即使如此，也要把真正可复现程度当成需要验证的经验事实。


17. Temperature 和 “创造力” 是什么关系？

把 Temperature 简单叫作“创造力旋钮”很方便，但不严谨。它直接控制的是概率分布尖锐程度，而不是某个可测量的创造力变量。

低温更常见	高温更常见
答案集中、措辞稳定	措辞和路径更多样
格式遵循更稳定	偏离最常见模式的机会更大
适合确定性任务的概率更高	适合候选探索的机会更高
也可能固执地重复同一种错误	也可能引入更多低概率错误
底层原理 Temperature 只是改变 token 分布；“创意更好”还是“错误更多”，必须由任务层评价指标决定。	

18. Sampling 为什么对 Reasoning / Best-of-N 有价值？

上一讲我们学到：Best-of-N 需要多个不同候选。如果每次都完全 Greedy，同一个 prompt 往往只给出同一路径，很难形成搜索空间。



适量 sampling 可以创造多个 reasoning trajectories，然后由 verifier、规则、执行器或投票机制进行选择。

但不要忘记

候选数量增加不等于有效信息增加。如果多个样本高度相关或共享同一错误，Best-of-N 的边际收益会迅速下降。

19. Self-Consistency: 同一模型多采样，然后投票

在一些可验证任务上，可以让模型生成多条 reasoning path，再对最终答案进行多数投票。

这背后的关键不是“多说几遍一定更正确”，而是：

单次采样存在随机错误；

不同轨迹若具有一定多样性，正确答案可能多次独立出现；

聚合可以过滤一部分偶然错误。

但如果错误高度相关，10次采样可能只是“同一个错误换了10种说法”。

科研连接

这直接连接你关注的 error correlation。Sampling diversity、model diversity、experience diversity 不是一回事，必须分开测量。

20. Multi-Agent：提高 Temperature 能不能制造“Agent 异质性”？

可以制造行为多样性，但不能直接证明形成了稳定、功能性的异质性。

来源	能产生什么差异	是否持久
同模型 + 不同随机种子	采样轨迹不同	通常不稳定
同模型 + 不同 Temperature	分布探索程度不同	参数设定层面稳定
不同 Persona / Role	行为偏置不同	取决于 prompt
不同工具/记忆/长期经历	信息与能力路径不同	可能形成更持久差异
不同模型/训练	内部参数与能力不同	通常更结构化

所以多 Agent 研究中要区分：

sampling diversity != functional heterogeneity != error independence	
重要	如果3个 Agent 全部使用同一模型、同一上下文，只是随机采样，错误仍可能高度相关。不能把“答案文字不一样”直接当成独立智能来源。

21. Sampling 参数会成为实验中的混杂变量

假设论文比较: Single Agent vs 5-Agent Debate。

如果 Single Agent 使用 $T=0$, 而每个 Debate Agent 使用 $T=1.0$, 那么系统差异同时包含:

Agent 数量变化;

通信结构变化;

总 token / model calls 变化;

sampling diversity 变化。

即使最终 Debate 更好, 也很难把提升明确归因到“讨论机制”。

更严谨的做法

增加 Single Agent + matched sampling / Best-of-N; 控制总预算; 报告每个设置的 temperature/top-p; 重复多个随机种子; 测 error correlation。

22. 常见误区

误区	更准确的理解
Temperature 越高越聪明	只是在概率分布上给低排名候选更多机会
Temperature=0 一定完全可复现	主要去掉采样随机性，但系统仍可能不完全确定
Top-p=0.9 就是保留90%的 token	是保留累计概率达到0.9所需的最小集合
Top-k=50 每步都会随机选50个	是先固定保留概率最高的50个，再在其中采样
多次采样互相独立	随机抽样可以独立，但错误来源仍可能高度相关
回答措辞不同=Agent能力不同	可能只是同一分布上的随机路径差异

23. 实际任务怎么选参数？先用任务目标，而不是背固定数值

任务类型	典型倾向	为什么
结构化抽取 / 格式转换	低随机性	更重视一致性和格式遵循
数学/代码 + verifier	可生成多个候选	用额外候选换搜索空间
创意写作 / brainstorm	允许更高多样性	需要探索不同表达和思路
Agent 工具调用	通常先重视稳定性	随机 action 可能引发环境级连锁差异
科研评测	参数固定 + 多 seed	估计均值、方差和稳定性

这里故意不提供“所有任务通用的最佳 temperature=0.7”这类口诀，因为不存在跨模型、跨任务都可靠的固定值。

执行原则	先明确你要的是稳定、探索、候选多样性还是可复现性，再用验证集/开发实验选择参数。
------	--

24. 配套实验：看概率分布怎样真的变化

材料包中的 `04_sampling_temperature_topk_topp_demo.py` 使用同一组 logits:

[4.2, 3.4, 2.8, 2.1, 1.6, 0.3]

然后分别计算:


Temperature = 0.3、1.0、2.0;

Top-k = 3;

Top-p = 0.80;

每种分布进行 10,000 次随机抽样，比较频率。

你会直接看到：低温时最高 logit 几乎垄断概率；高温时尾部候选显著获得更多机会；Top-k 会把集合外 token 清零；Top-p 的保留数由累计概率动态决定。



25. 建议你亲手改三个参数

把 Temperature 从 0.3 改成 0.05，观察分布是否更接近 `argmax`；

把 `top-k` 从 3 改成 1，理解它为什么近似 `greedy`；

把 `top-p` 从 0.80 改成 0.95，观察候选集合是否扩大；

再把 `logits` 改得很平，比如 `[2.0,1.9,1.8,1.7,1.6,1.5]`，看看同样 `top-p` 会保留几个候选。

真正要建立的直觉不是记一个 API 参数，而是：

解码参数改变的是每一步“概率质量如何被重分配、过滤和抽样”。

26. 把本讲和前两讲串起来



第18讲讲“为什么要多算”；第19讲讲“模型服务怎样跑”；第20讲讲“每一步 next token 到底怎样选”。三讲合起来，你已经能从系统层理解一个现代 LLM 推理轨迹为什么既有能力，也有随机性。

27. 本讲小结

Logits 是未归一化候选分数，Softmax 把它们变成概率分布。

Greedy 每步选择最高概率；Sampling 按概率抽取，因此会产生 run-to-run variance。

Temperature < 1 让分布更尖；Temperature > 1 让分布更平。

Top-k 固定保留最高的 k 个候选；Top-p 动态保留累计概率达到 p 的最小集合。

Sampling 参数每一个 decode step 都会重新作用于新的 logits。

低温通常提高稳定性，但不保证整个服务栈严格确定。

多次采样能提供候选多样性，但错误仍可能高度相关。

Agent 研究必须把 sampling diversity 与真正的功能性异质性分开。

论文评测必须固定并报告 sampling 参数，并使用多次重复估计方差。

核心句：

模型先给候选打分；Temperature 改分布形状；Top-k / Top-p 删候选；Sampling
最终抽出一个 token。

28. 练习题

- 1) Logits 为什么不能直接当概率?
- 2) Temperature=0.5 为什么通常会让分布比 $T=2.0$ 更尖?
- 3) Top-k=5 和 Top-p=0.9 的候选集合有什么根本不同?
- 4) 为什么随机 Sampling 会让一处早期 token 差异逐渐放大成整段不同回答?
- 5) 为什么 “Temperature 越高越有创造力” 只是粗略说法?
- 6) 为什么同模型重复采样 10 次不能保证得到 10 个独立错误来源?
- 7) Multi-Agent 实验里, 怎样避免把 sampling diversity 误认为协作机制收益?
- 8) 为什么研究论文最好报告多个 seed 或重复运行, 而不是只展示一次结果?

答案见独立《练习题与答案》PDF。