

第20讲 练习题与答案

Temperature、Top-k、Top-p: 模型为什么每次回答不一样?

使用建议

先独立做前两页, 再看答案。每一道题都要求解释因果, 而不是背参数定义。

1. Logits

为什么 $[4.2, 3.4, 2.8]$ 不能直接说成 420%、340%、280% 的概率?

2. Softmax

Softmax 至少保证概率分布满足哪两个基本条件?

3. Temperature

给定 logits $[4, 2]$, $T=0.5$ 与 $T=2$ 时, 哪一个会让最高 token 优势更大? 为什么?

4. Top-k

如果词表10万个 token, top-k=3 后有多少个 token 可能被采样?

5. Top-p

当前排序概率为 $[0.45, 0.25, 0.15, 0.08, 0.05, 0.02]$, $p=0.80$ 时保留几个 token? 为什么?

6. Path Dependence

为什么第一步只差一个 token, 最终回答可能完全不同?

7. Reproducibility

为什么 temperature=0 仍不应被当成整个云端 API 的“绝对可复现保证”?

8. Self-Consistency

为什么多采样并投票能提高某些任务表现, 但不是必然有效?

9. Multi-Agent

3个 Agent 使用同模型、同prompt, 只换随机种子。它们算不算已经形成稳定功能性异质性? 解释。

10. 科研设计

比较 Single-Agent 与 Multi-Agent 时, 采样参数应该怎样控制和报告?

答案与解释

1.

Logit 是未归一化实数分数，不要求落在0到1，也不要求总和为1。需要经过 Softmax 等变换后才成为概率分布。

2.

每个概率非负，并且所有候选概率之和为1。

3.

$T=0.5$ 。因为 logits 会除以更小的 T ，4和2变成8和4，分数差距被放大，Softmax 更集中于最高项； $T=2$ 会把差距压小。

4.

最多3个。Top-k 会把除最高3个以外的候选概率置零，再在剩余候选中采样。

5.

3个。 $0.45+0.25=0.70$ ，还没达到0.80；再加入0.15后累计0.85，所以选择最小集合 A/B/C。

6.

自回归生成把已经生成的 token 作为下一步条件。第一步不同会改变下一步 logits，差异可以在后续不断累积和放大。

7.

temperature=0/greedy 主要消除采样随机性，但服务后端版本、浮点非确定性、动态 batching、MoE 路由、隐藏上下文变化等仍可能造成差异。

8.

如果多条轨迹有一定独立性，投票能抵消部分偶然错误；但若错误高度相关，多采样只是重复同一种错误，而且会增加成本。

9.

通常不能直接这样下结论。它们表现上的差异可能只是随机轨迹差异，不代表持久的工具、记忆、经验、参数或专门化结构不同。

10.

尽量在主比较中固定模型、temperature、top-p/top-k、max tokens 等；若研究 sampling diversity，要把它作为显式变量；用多个seed/重复运行，报告均值方差；最好增加 matched sampling / compute baseline。

加餐：手算一个极小例子

假设 $\text{logits} = [3, 2, 1]$ 。不用精确计算小数，只回答趋势：

$T=0.5$ 后，三个候选的概率差距会变大还是变小？

$T=2$ 后，概率会更接近均匀还是更远离均匀？

$\text{top-k}=1$ 后还需要随机抽样吗？

$\text{top-p}=0.95$ 与 $\text{top-p}=0.5$ 哪个通常允许更多候选？

参考：低温放大差距；高温压平差距； $\text{top-k}=1$ 退化为只剩最高候选；更高 top-p 通常需要覆盖更大的概率质量，因此往往保留更多候选。