

第21讲 Context Window / Long Context / Memory 核心概念速查卡

概念	一句话记忆	不要混淆
Context Window	一次推理当前可见的 token 工作区	不是永久记忆
Conversation History	应用保存的旧消息	只有重新放进 prompt 才当前可见
KV Cache	本次推理缓存历史 K/V	不是长期用户记忆
Long Context	更大的单次工作区	容量大 != 利用稳定
Lost in the Middle	表现可能随证据位置变化	不是所有模型必然在中间失败
RAG	先检索相关片段再放入 Context	不是必须把整个知识库塞进去
External Memory	长期保存事件/事实/状态	需要 retrieval 才进入工作区
Context Bloat	无关/重复 token 不断累积	增加成本并可能稀释关键信息
Agent 研究	把 Context 当有限系统资源	报告长度、成本、延迟、信息保留率

System + History + Tools + Retrieved Docs + Current Query + Output Reserve <= Context Budget

核心记忆：Context 是工作台；Memory 是仓库；Retrieval 是搬运；Compression 是压缩；Agent Runtime 负责决定这一轮桌面上放什么。