

第22讲速查卡：KV Cache / Prefill / Decode / Serving

概念	一句话	常见误区
Prefill	批量处理已有 prompt，建立历史 K/V	不是逐 token 慢慢“读”
Decode	每步新增一个 token，时间步串行推进	不能把长回答当作一次矩阵就全部生成
KV Cache	保存过去 token 的 K/V，避免重复计算	不是长期记忆数据库
TTFT	从请求到第一个输出 token	和 TPOT 不是同一个指标
TPOT / ITL	连续输出 token 的间隔	首 token 快不代表长回答一定快
Throughput	单位时间系统总体处理量	吞吐高不等于单请求延迟最低
GQA	多 Q heads 共享较少 K/V heads	不是简单删除所有多头
MQA	所有 Q heads 共用 1 组 K/V	缓存最省，但有能力/架构折中
Continuous batching	请求结束后动态插入新请求	这是 serving 调度，不改变 Transformer 数学

最重要公式

$$\text{KV bytes} \approx \text{batch} \times \text{seq_len} \times \text{layers} \times 2 \times \text{kv_heads} \times \text{head_dim} \times \text{bytes_per_element}$$

Agent 研究条件反射

看到多 Agent / 多轮工具调用结果时，同时问：input/output tokens、model calls、TTFT/latency、tool result size、总成本是多少？