

第22讲 · 练习题

建议先独立完成，再看答案。

1. 概念题

为什么 Prefill 可以高度并行，而 Decode 在单条序列时间轴上必须逐步进行？

2. 判断题

“KV Cache 就是模型的长期记忆。”对还是错？说明原因。

3. 推理题

为什么上下文从 4K 扩展到 32K 时，即使模型权重完全不变，显存压力也可能大幅增加？

4. 计算题

某教学模型：24 层、8 个 KV heads、head_dim=128、BF16=2 bytes、batch=1、seq_len=8192。用简化公式估算 KV Cache 大小。

5. 对比题

MHA、GQA、MQA 最核心的区别是什么？为什么 GQA 常被视为质量与推理效率之间的折中？

6. 指标题

TTFT=800ms、TPOT=40ms。若生成 101 个 token，粗略估算从请求开始到完整回答的时间（忽略其他开销）。

7. 服务题

为什么 Static Batching 遇到不同长度输出时可能浪费计算槽位？Continuous Batching 如何缓解？

8. Agent 题

一个单 Agent 调用模型 2 次；一个 5-Agent 系统每个 Agent 调 4 次，再加 1 次中央汇总。两者至少应该记录哪些资源指标，才能公平比较？

9. 研究设计题

如果你要研究“选择性通信能否降低多 Agent 成本而不损失准确率”，请给出最少 4 个实验变量/指标。

10. 综合题

请用自己的话解释：Context、KV Cache、External Memory、Prefix Cache 四者有什么区别。

参考答案

第1题

Prefill 时整个 prompt 已经已知，可作为矩阵并行计算；Decode 的下一个 token 取决于上一步实际生成的 token，因此时间步之间存在因果依赖。

第2题

错。KV Cache 保存当前推理过程中历史 token 的 Key/Value 中间张量，用来减少重复计算；长期记忆通常存放在数据库、文件、向量库或应用状态中，需要再次检索进入 Context。

第3题

KV Cache 大小近似正比于 sequence length；8 倍长度会带来约 8 倍 K/V 存储，同时 prefill 与 Attention 工作也增大。

第4题

bytes $\approx 1 \times 8192 \times 24 \times 2 \times 8 \times 128 \times 2 = 805,306,368$ bytes，约 0.75 GiB。真实系统还会有其他开销。

第5题

区别主要在 K/V head 的共享：MHA 通常每个 Q head 有自己的 K/V；GQA 让一组 Q heads 共享较少 K/V；MQA 所有 Q heads 共享 1 个 K/V。GQA 能显著降低 cache / 带宽，同时保留比 MQA 更丰富的 K/V 表示。

第6题

完整时间 $\approx \text{TTFT} + (101-1) \times \text{TPOT} = 0.8\text{s} + 100 \times 0.04\text{s} = 4.8\text{s}$ 。

第7题

固定 batch 常被最长序列拖住，短序列结束后槽位可能空闲；连续批处理允许完成的序列退出，并在后续 step 插入新请求。

第8题

至少记录总 model calls、input tokens、output tokens、总 latency / TTFT、tool calls（如有）、API cost 或 GPU time；还应控制模型、采样、任务和随机种子。

第9题

例如：通信策略（全广播/选择性）、准确率、总 input/output tokens、通信 token、model calls、wall-clock latency、成本、消息冗余率、不同 seed 下方差。

第10题

Context 是本轮模型当前可见 token；KV Cache 是当前 Attention 的计算缓存；External Memory 是可长期保存并检索的数据仓库；Prefix Cache 是 serving 层对重复前缀计算结果的复用。