

第23讲速查卡：Quantization / Distillation / MoE

概念	一句话	不要误解成
FP32 / BF16 / INT4	参数/张量的数值表示位宽	位宽本身不是模型规模
Quantization	降低权重/激活/KV 的表示精度	不是把参数数量删掉
PTQ	模型训练后再量化	不需要重新从头预训练
QAT	训练时显式适应量化误差	不是简单保存成 INT4 文件
Distillation	Teacher 教较小 Student	不是同一个模型降精度
MoE	多个 Expert + Router; 每 token 只激活少数 Expert	总参数都在每个 token 上运行
Total Params	模型拥有的全部参数	等同于每 token FLOPs
Active Params	某 token 实际经过的稀疏参数规模直觉	精确端到端计算量
Runtime Memory	Weights + KV + workspace + overhead	只有模型 checkpoint 大小

70B 权重数量级

FP32≈280GB; FP16/BF16≈140GB; INT8≈70GB; 理想 INT4≈35GB。真实运行还要加 scale/metadata、KV Cache 与其他显存。

一句辨析

量化: 每个数更省; 蒸馏: 学生模型更小; MoE: 每个 token 只激活部分专家。