

第23讲 · 练习题

建议先独立完成，再看答案。

1. 概念题

为什么说“4-bit 量化”通常并没有把一个 70B 模型变成 17.5B 参数？

2. 计算题

一个 13B 参数模型，仅看权重：FP16 理论需要多少 GB（十进制）？理想 INT4 需要多少 GB？

3. 判断题

“INT4 的权重只有 FP16 的 1/4，因此推理速度一定是 4 倍。”对还是错？说明原因。

4. 对比题

PTQ 与 QAT 的核心区别是什么？

5. 蒸馏题

为什么蒸馏与量化不是同一种压缩？请用 Teacher / Student 解释。

6. MoE 计算题

一个 toy MoE: 3B shared + 16 个 0.8B experts, 每 token Top-2。总参数和 toy active parameters 分别约多少 B？

7. 系统题

为什么 MoE 即使 active parameters 较少，部署仍可能遇到很重的通信开销？

8. Agent 题

两个 Agent 使用同一基础模型，一个 FP16，一个 INT4。它们行为不同，能否直接说明形成了“功能性异质性”？为什么？

9. 研究设计题

如果你要研究 4-bit 量化是否改变 LLM 的错误模式，至少应控制或报告哪些变量？

10. 综合题

请分别用一句话解释：Quantization、Distillation、MoE 各自主要改变什么。

参考答案

第1题

因为参数数量通常仍是 70B；只是每个参数从例如 16 bit 变成约 4 bit 表示，并附带 scale 等元数据。

第2题

FP16: $13B \times 2 \text{ bytes} \approx 26GB$ ；理想 INT4: $13B \times 0.5 \text{ bytes} \approx 6.5GB$ 。真实 checkpoint/运行时更多。

第3题

错。权重存储可约降到 1/4，但速度还受硬件低位算子、解包/反量化、KV cache、Attention、batch、memory bandwidth 和框架实现影响。

第4题

PTQ 是模型训练好以后再校准并量化；QAT 在训练/微调阶段模拟量化误差，让参数主动适应低位表示。

第5题

量化通常保留同一模型参数个数，只改变精度；蒸馏训练一个更小的 Student 去模仿 Teacher，因此 Student 的参数数量/结构可以真正不同。

第6题

总参数 $\approx 3 + 16 \times 0.8 = 15.8B$ ；toy active $\approx 3 + 2 \times 0.8 = 4.6B$ 。注意 active params 不是精确 FLOPs。

第7题

专家可能分布在不同 GPU 上；Router 选完专家后 token hidden states 需要跨设备发送、执行专家计算再汇聚，All-to-All、负载不均和网络带宽都可能成为瓶颈。

第8题

不能。输出差异可能只是量化噪声/精度退化，不等于形成稳定、互补、可复现的功能角色。还需要验证错误相关性、跨任务一致性和系统收益。

第9题

至少控制基础模型、prompt/chat template、sampling、context、benchmark、serving backend/hardware；报告量化算法、bits、group size、校准数据、accuracy、error overlap、latency、memory、tokens 和多个随机种子。

第10题

Quantization: 降低每个数的表示位宽；Distillation: 训练较小 Student 模仿 Teacher；MoE: 保留大量专家，但让每个 token 只激活少数专家。