

第24讲：Hallucination 核心概念速查卡

最重要的关系： $P(\text{next token} \mid \text{context})$ 不是 $P(\text{statement is true})$ 。

核心概念

概念	一句话
Hallucination	输出与事实/证据不一致或无依据
Grounding	用可核验证据约束生成
RAG	先检索证据，再基于证据回答
Verifier	独立检查候选答案
Calibration	置信与真实正确率是否匹配
Abstention	证据不足时允许不回答
Error Correlation	多个 Agent 是否倾向一起错
Error Propagation	错误是否进入计划、工具和 Memory

四层错误来源

数据层 → 模型层 → Context / Retrieval 层 → Decode / Tool / Agent 系统层。科研时先定位错误发生在哪一层。

可靠性闭环

步骤	目的
1. 取证	Retrieval / Tool 获取外部事实
2. 检查证据	来源、时间、冲突、完整性
3. Grounded Generation	要求回答受证据约束
4. Verification	检查关键原子事实
5. Abstention	证据不足则不强行断言

五个高频误区

误区	正确理解
Temperature=0 无幻觉	可能稳定地错
长 Context=长期记忆	Context 只是当前工作台
RAG 一定正确	检索也会失败
多 Agent 一定可靠	错误相关时会一起错
Self-Reflection=验证	无新证据时独立性有限

科研最值得测

Factual Accuracy · Faithfulness · Citation Precision · Abstention · Calibration · Error Correlation

一句话：生成器负责提出候选，外部证据和 Verifier 负责让“像真的”尽可能变成“可验证地是真的”。