

第24讲：练习题与答案

建议先独立作答，再看答案。

1. 为什么 next-token prediction 与事实真值判断不是同一个目标？

先写下你的答案：_____

参考答案：前者优化的是“在当前上下文下哪个 token 更符合训练分布”，后者要求判断整个命题与现实证据是否一致。二者相关但不等价。

2. 为什么 Temperature=0 仍然可能稳定地产生错误答案？

先写下你的答案：_____

参考答案：如果模型分布中最高概率的答案本来就是错的，Greedy/近 Greedy 解码会稳定重复这个错误。降低随机性不等于增加事实来源。

3. Context Window 变大为什么不能直接等价于幻觉变少？

先写下你的答案：_____

参考答案：更大窗口只扩大可放入的信息量。关键证据仍可能没有被检索到、被无关内容稀释、与其他证据冲突，或被模型错误使用。

4. RAG 可以把哪类问题变得更容易验证？它又引入了什么新失败点？

先写下你的答案：_____

参考答案：它把依赖参数记忆的问题部分转化为“从外部来源取证并基于证据回答”。新失败点包括召回失败、错误文档、过期来源、检索排序错误和模型不忠于证据。

5. 为什么“模型自己反思一次”不是独立 verifier？

先写下你的答案：_____

参考答案：同一个模型、同一上下文和同一内部盲点可能被再次使用。没有新证据或独立规则时，第二次推理可能只是把第一次错误改写得更完整。

6. 什么叫 Abstention？它与 Coverage / Accuracy 有什么关系？

先写下你的答案：_____

参考答案：Abstention 是在证据不足或置信不足时选择不回答。通常弃答更多会降低 Coverage，但可提高已回答部分的 Accuracy。

7. 多 Agent 投票在什么条件下更可能有效？

先写下你的答案：_____

参考答案：当 Agent 的错误较低相关、信息源或工具互补，而且聚合机制不被同一系统性偏差控制时，多数或交叉验证更可能有价值。

8. 如果一个 Agent 把错误事实写入长期 Memory，后面可能发生什么？

先写下你的答案: _____

参考答案: 错误可能被后续任务检索出来, 影响计划、工具选择和判断, 并跨 episode 持续传播; 若共享给其他 Agent, 还可能形成错误同步和共识。

9. 设计一个最小实验, 区分多 Agent 协作效果和单纯更多 test-time compute。

先写下你的答案: _____

参考答案: 比较: 单 Agent 一次回答; 单 Agent 在同等总 token/call 预算下 Best-of-N; 多 Agent 在相同总预算下协作。只有 compute-matched 条件下仍有增益, 才更能支持“协作机制贡献”。

10. 为什么做 Agent 可靠性论文时应该报告 error correlation?

先写下你的答案: _____

参考答案: 集体系统能否通过投票、互审获得收益, 不只取决于单体准确率, 还取决于是否在同样的问题上一致错。高相关错误会削弱集体收益。

附加实验题

运行 `04_hallucination_grounding_demo.py`, 比较 `Prior-only`、`Retrieval-grounded`、`Noisy retrieval`。回答: 为什么引入 `Grounding` 后正确率显著提高? 为什么 `noisy retrieval` 又让错误重新出现?

参考: `Grounding`

把生成从“语言先验”约束到“外部事实表”; 但当检索本身错误时, 生成器会忠实使用错误证据。因此 RAG 并没有消灭可靠性问题, 而是把一部分瓶颈转移到检索、证据质量和验证层。