

第25讲：LLM Memory 核心概念速查卡

工作台 vs 仓库：Context 决定本轮看什么；外部 Memory 决定未来还能找回什么；参数决定模型本身已经练会什么。

五种“记忆”不要混

机制	位置	最短理解
参数记忆	权重	练进模型的长期模式
Context	当前 token	当前工作台
KV Cache	推理缓存	已算好的 K/V
RAG	外部存储	先检索再注入
Agent Memory	Runtime	长期经历管理系统

Agent Memory 生命周期

Experience → Write → Store → Retrieve → Inject → Update → Forget / Compact

真正要设计的策略

策略	核心问题
Write	什么值得记？原文还是摘要？
Retrieval	相关 + 最近 + 重要 + 可信？
Update	新旧冲突怎么办？
Forget	什么时候降权、压缩、删除？
Audit	错误能否追溯到具体记忆？

多 Agent 科研连接

Experience Divergence → Memory Divergence → Retrieval Context Divergence → Behavior/Error Divergence → Error Decorrelation → Collective Gain

高频误区

KV Cache ≠ 长期记忆；Memory 越大 ≠ 越好；不同 Memory ≠ 必然更强；写进数据库 ≠ 写进模型参数。

可靠性提醒：未经验证的幻觉一旦写入长期 Memory，可能在未来反复被检索，形成错误自我强化。