

第26讲：RAG 核心概念速查卡

一句话：先从大库里找证据，再让 LLM 基于少量、相关、可追溯的证据回答。

RAG 主流程

Documents → Parse → Chunk → Embed/Index → Query → Retrieve → Rerank → Context → LLM → Grounded Answer

核心指标

指标	意义
Recall@k	关键证据有没有进前 k
Precision@k	前 k 里多少是真的相关
MRR	第一条正确证据有多靠前
Faithfulness	回答是否被证据支持
Citation Precision	引用是否真的支撑断言

三个关键折中

变量	太小	太大
Chunk	语义碎裂	噪声/稀释
Top-k	漏证据	Context Bloat
Overlap	边界断裂	重复/成本

失败定位

Parse → Chunk → Embedding → Retrieve → Rerank → Context → Generate → Citation。先找到哪一层失败，再修，不要只换 LLM。

Agent 科研连接

Retriever / Memory / Knowledge Source 的长期差异也会形成 Agent 可见信息差异；但只有在降低 Error Correlation 并带来 compute-matched Collective Gain 时，才算有意义的功能性异质性。

研究原则：最终答案错，不代表一定是 LLM 错。先看正确证据有没有被召回；再看是否被正确排序、放入 Context、忠实使用。