

第26讲：练习题与答案

建议先独立作答，再看答案。

1. 为什么 RAG 不等于“模型把数据库学进参数”？

你的答案：_____

参考答案：因为外部文档仍存储在模型外。只有检索到的证据被注入当前 Context 后，模型这一轮才可使用；模型参数通常没有因此更新。

2. Chunk 太小和太大分别有什么问题？

你的答案：_____

参考答案：太小会切碎语义、把定义和条件分开；太大会混入无关信息、稀释相似度并增加 Context 成本。

3. Dense Retrieval 和 BM25 各擅长什么？为什么 Hybrid Retrieval 常见？

你的答案：_____

参考答案：Dense 擅长语义近似，BM25/稀疏检索擅长精确词、ID、错误码、函数名等。真实任务同时包含两类信号，因此混合检索常更稳。

4. Recall@k 低意味着什么？为什么生成器很难补救？

你的答案：_____

参考答案：意味着真正需要的证据没有进入前 k 候选。若证据根本没有进 Context，生成器只能靠参数知识或猜测，无法使用缺失证据。

5. Retriever 和 Reranker 为什么要分成两级？

你的答案：_____

参考答案：Retriever 面向大规模索引，需要快并追求高 Recall；Reranker 只处理少量候选，可以更慢但更准确地提高 Precision。

6. 什么叫 Faithfulness？它和 Answer Correctness 有什么区别？

你的答案：_____

参考答案：Faithfulness 看回答是否被提供证据支持；Correctness 看答案是否最终事实正确。回答可能碰巧正确但证据不支持，也可能忠实总结了错误证据。

7. 为什么 Long Context 与 RAG 不是二选一？

你的答案：_____

参考答案：Long Context 增大可读材料量，RAG 负责从更大知识库筛选候选。真实系统常先 RAG，再把若干候选交给长 Context 深读。

8. RAG 与 Agent Memory 有什么共同点和区别？

你的答案：_____

参考答案：两者都可能使用 Embedding + Retrieval; RAG 更偏外部知识/文档, Agent Memory 更强调 Agent 自己的长期经历、状态、写入、更新与遗忘。

9. 多 Agent 共用同一个 Retriever 为什么可能导致错误相关性升高?

你的答案: _____

参考答案：因为它们会收到高度相似的证据；若 Retriever 漏掉或误排同一关键信息，所有 Agent 可能基于同一错误 Context 得出相同错误。

10. 设计一个 RAG 实验，判断性能下降到底来自 Chunk、Retriever 还是 Generator。

你的答案: _____

参考答案：先固定生成器，比较不同 Chunk 的 Recall@k; 再固定 Chunk 比较 Retriever/Reranker; 最后只在“gold evidence”直接注入 Context 的条件下测 Generator。这样可以分层定位上限与瓶颈。

附加实验题

运行 `04_toy_rag_retrieval_demo.py`。观察 Top-k 从 1 增加到 3 时 Recall@k 的变化，并查看哪些无关 chunk 也开始进入候选集。

参考：增大 k 往往提高 Recall，但也会带入更多噪声。这就是为什么很多系统使用“较大候选集 + Reranker + 较小最终 Context”的两阶段结构。