

第28讲：从 LLM 到 Agent 核心概念速查卡

一句话：LLM 是模型；Agent 是把模型放进“状态 - 行动 - 环境反馈”循环中的系统。

Agent 主闭环

Observe → Update State → Plan/Decide → Act/Tool → Environment Feedback → repeat / stop

组件	一句话
Goal	要到哪里
State	现在在哪里
Planning	准备怎么走
LLM/Policy	下一步选什么
Tools	能做哪些动作
Environment	动作真正发生的世界
Memory	过去有哪些经历
Stop	什么时候结束

Agent ≠ LLM

普通 LLM	Agent
Prompt → Response	Goal → Loop → Actions
主要生成文本	会读取环境反馈
通常不维护显式状态	持续维护 State
本身不执行工具	Runtime 可执行工具

科研要测

Task Success · Steps · Tool Calls · Tokens/Cost · Latency · Recovery · Invalid Actions · State Accuracy · Trajectory

AI Systems 视角

Agent 是状态转移系统。研究重点从“单题答对率”扩展到错误传播、恢复、资源、长期经历和交互效应。

研究原则：保存 trajectory。最终失败必须能回溯到 Goal、State、Planning、Tool、Observation、Memory 或 Stop 中的具体环节。