

第30讲：LLM -> Agent Systems 总地图

一句话：模型是系统中的一个组件；论文要解释“哪一层变化，通过什么机制，带来什么可复现结果”。

五层知识地图

层	关键词
表示	Token / Embedding / Gradient
架构	Attention / MHA / Position / Block
训练	Pretrain / SFT / Preference / Scaling
推理	Sampling / Context / KV / Cost
系统	RAG / Memory / Tool / Agent / MAS

科研闭环

Observe → Question → Search → Experiment → Measure → Explain → Reproduce/Ablate/Falsify

Agent 研究最常测

对象	指标
Planning	Success / Steps / Recovery
Memory	Hit / Stale / False Memory
Tool	Selection / Argument / Execution
Communication	Messages / Info Gain / Cost
Collective	Error Corr / Gain / Budget

五个实验警报

Compute 不匹配 · 模型不同 · Prompt/Context 预算不同 · Tool 权限不同 · Judge/Data leakage

最低闭环：能定义任务、跑模型/API、保存 trajectory、算指标、重复 seeds、做公平基线、看失败案例、给出边界明确的结论。