

第31讲：LLM Evaluation 核心速查卡

一句话：先定义你要测的能力，再选任务、协议和指标；不要反过来。

指标怎么选？

任务	指标
明确对错	Accuracy / EM
分类不平衡	Precision / Recall / F1
代码多采样	Pass@k
开放文本	Pairwise / Judge / Human
Agent	Success + Process + Cost
Multi-Agent	Gain + Error Corr + Compute

Pass@k

理论直觉： $1-(1-p)^k$ 。k 越大，机会越多，但 test-time compute 也越大。

LLM Judge 偏差

偏差	含义
Position	偏第一/某位置
Verbosity	偏长答案
Style	偏专业/礼貌
Self-preference	偏自己风格/家族

Agent 评测

Outcome: Task Success; Process: Steps/Recovery/Invalid Actions; Cost: Tokens/Calls/Tools/Latency/USD。

研究纪律

测试集尽量封闭; Judge prompt/version 固定; 多 Agent 做 compute-matched baseline; 保留 failure cases。

评测陷阱: Benchmark contamination · Judge bias · Metric gaming · More test-time compute · Test-set tuning。